

Федеральное государственное автономное образовательное учреждение
высшего образования «Санкт-Петербургский политехнический университет
Петра Великого» СПбПУ

На правах рукописи

Сидоренко Данил Дмитриевич

**Физически информированная нейросетевая система
восстановления траектории мобильного робота при
кратковременных потерях сигнала глобальной навигационной
спутниковой системы**

Специальность 2.5.4 —
«Роботы, мехатроника и робототехнические систем»

Диссертация на соискание учёной степени
кандидата технических наук

Научный руководитель:
доктор технических наук, доцент
Тимофеев Андрей Николаевич

Санкт-Петербург — 2026

	Стр.
Введение	6
0.1 Актуальность темы исследования	6
0.2 Степень разработанности темы исследования	7
0.2.1 Классические методы.	7
0.2.2 Нейросетевые методы.	7
0.2.3 Физически информированные нейронные сети PINN	7
0.3 Цель и задачи работы	8
0.4 Научная новизна	9
0.5 Теоретическая и практическая значимость исследования	10
0.6 Методология и методы исследования	11
0.7 Положения, выносимые на защиту	11
0.8 Степень достоверности полученных результатов	12
0.9 Личный вклад автора	12
0.10 Соответствие диссертации паспорту научной специальности	13
0.11 Основные публикации по теме диссертации	13
 Глава 1. Анализ современных методов восстановления траектории мобильных роботов при кратковременных потерях сигнала ГНСС	 15
1.1 Задачи навигации мобильных роботов и беспилотных летательных аппаратов в условиях деградации и потери сигнала глобальной навигационной спутниковой системы	15
1.2 Классические методы восстановления траектории при кратковременных потерях сигнала глобальной навигационной спутниковой системы	17
1.3 Нейросетевые подходы к восстановлению траектории основанные на данных	19
1.4 Физически информированные нейронные сети в задачах оценки состояния и навигации роботов и беспилотных летательных аппаратов	21

	Стр.
1.5	Архитектуры селективных последовательностей состояний 23
1.6	Использование телеметрии актуаторов как дополнительного источника навигационной информации 24
1.7	Гибридные физически информированные модели на основе последовательностей в задачах инерциальной навигации 25
1.8	Анализ публикационной активности и выявление пробелов в литературе 26
1.9	Выводы по главе 29
Глава 2.	Математическая модель квадрокоптера 30
2.1	Введение 30
2.2	Кинематическая модель квадрокоптера как твёрдого тела 31
2.3	Динамическая модель твёрдого тела 33
2.4	Подробная модель сил и моментов несущих винтов 35
2.5	Модели датчиков и телеметрии 36
2.6	Описание экспериментальной платформы Holybro X500 V2 и ограничения навигационной системы 38
2.7	Симуляционная среда PX4/Gazebo с плагином RotorS 40
2.7.1	Вывод раздела 42
Глава 3.	Разработка методики обучения и дообучения физически информированной нейросетевой системы 43
3.1	Общая архитектура рассматриваемых нейронных сетей 43
3.1.1	Анализ вычислительной сложности 44
3.2	Обоснование применимости телеметрии оборотов несущих винтов как дополнительного источника навигационной информации 45
3.2.1	Физическое обоснование 45
3.2.2	Статистическое обоснование 46
3.2.3	Обзор релевантной литературы 49
3.3	Предлагаемая нейронная сеть 50
Глава 4.	Экспериментальное исследование и сравнительный анализ эффективности предложенной системы 53
4.0.1	Введение 53

	Стр.
4.1	Описание экспериментальных данных и протокол оценки 53
4.1.1	Датасеты 53
4.1.2	Метрики оценки и протокол 55
4.1.3	Сравниваемые платформы для эксперимента по кросс-платформенному обобщению 55
4.2	Вычислительные характеристики архитектуры ФИ НС-ПСПС . . . 56
4.2.1	Сравнение архитектур по теоретической сложности 57
4.2.2	Результаты обучения 57
4.2.3	Время предсказания траектории 57
4.3	Дообучение на ограниченном объёме данных 60
4.3.1	Протокол дообучения 60
4.3.2	Результаты при потере сигнала 60 с 60
4.3.3	Результаты при потере сигнала 240 с 61
4.3.4	Сводная таблица 61
4.3.5	Визуализация и анализ 62
4.4	Валидация на реальном датасете AI-IO 63
4.4.1	Описание датасета AI-IO 63
4.4.2	Результаты 64
4.5	Кросс-платформенное обобщение без дообучения 65
4.5.1	Описание эксперимента 66
4.5.2	Результаты 66
4.5.3	Обсуждение результатов 66
4.5.4	Выводы по разделу 70
4.6	Выводы по главе 70
Заключение	 72
Словарь терминов	 73
Список литературы	 74
Список рисунков	 80
Список таблиц	 81

Приложение А. Программный код разработанной ФИ НС-ПСПС	82
Приложение Б. Архитектура потока данных восстановления траектории	83
.1 Архитектура потока данных восстановления траектории	83

Введение

0.1 Актуальность темы исследования

Современные мобильные роботы — беспилотные летательные аппараты (БПЛА), надводные и наземные платформы — широко применяются для картографирования, геодезии и инспекции протяжённых промышленных объектов: трубопроводов, высоковольтных линий электропередачи, мостовых конструкций. Базовым средством навигации служат глобальные навигационные спутниковые системы (ГНСС) в режиме. Однако металлические конструкции промышленных объектов создают зоны экранирования и многолучёвости сигнала, при которых кратковременные потери ГНСС продолжительностью 3–240 с являются штатной эксплуатационной ситуацией.

В отсутствие ГНСС позиционирование переходит на бортовую инерциальную навигационную систему (БИНС) на микроэлектромеханических датчиках (МЭМС). При двойном интегрировании шума акселерометра ошибка позиции нарастает нелинейно: на интервале 60 с погрешность достигает нескольких метров, при 240 с — сотен метров. Восстановление утраченного участка траектории в режиме постобработки позволяет обеспечить непрерывность данных без повторного сканирования.

Дополнительную трудность создаёт смена динамического режима: при компенсации порывов ветра квадрокоптер производит интенсивные асимметричные изменения тяги отдельных роторов, которые не отражаются в показаниях акселерометра. Единственным датчиком, непосредственно фиксирующим эти управляющие воздействия, является телеметрия оборотов несущих винтов. Традиционные методы (фильтры Калмана) применимы лишь до 3–5 с, а Transformer имеет квадратичную сложность $O(N^2)$, неприемлемую для бортовых систем малых роботов с ограниченными вычислительными ресурсами.

Таким образом, разработка нейросетевого метода восстановления траектории, сочетающего линейную вычислительную сложность, физическую согласованность и новый информационный канал — телеметрию оборотов несущих винтов, — представляет актуальную научно-техническую задачу в области робототехники.

0.2 Степень разработанности темы исследования

0.2.1 Классические методы.

Расширенный фильтр Калмана (РФК), фильтр без запаха (ФБЗ) и сглаживатель Рауха–Тунга–Штрибеля (СРТШ) обеспечивают высокую точность при потерях до 3–5 с. На более длинных интервалах ошибка позиции нарастает нелинейно вследствие двойного интегрирования шума акселерометра (О. А. Степанов, В. Я. Распопов и др.). Ни один из классических методов не использует телеметрию актуаторов в качестве навигационного источника.

0.2.2 Нейросетевые методы.

Двунаправленная LSTM [1] и Transformer Encoder [2] превосходят фильтры Калмана по точности, однако LSTM подвержена затуханию градиентов, а Transformer имеет квадратичную сложность $O(N^2)$, что исключает применение на бортовых системах с нейроускорителями[3].

0.2.3 Физически информированные нейронные сети PINN

Физически информированные нейронные сети [4] встраивают уравнения динамики объекта в функционал потерь. В задачах навигации БПЛА исследованы И. А. Бизяевым, Б. Г. Ильясовым и соавт.; показана их перспективность при ограниченном объёме данных. Работы по использованию телеметрии оборотов несущих винтов в качестве навигационного источника (G. Lu, J. Cui и соавт., J. Svacha и соавт.) подтверждают принципиальную важность этого канала.

Архитектуры SSM. Нейронная сеть на основе последовательностей с селективными пространствами состояний (НС ПСПС; базовая работа Mamba: A. Gu, T. Dao) обеспечивает линейную сложность $O(N)$, применяется в задачах

управления роботами, однако ни в одной известной работе не исследовалась для постобработки траектории при потерях ГНСС с физически информированным функционалом потерь на базе телеметрии оборотов.

0.3 Цель и задачи работы

Цель: разработка и исследование физически информированной нейросетевой системы восстановления траектории мобильного робота по данным БИНС и телеметрии оборотов несущих винтов при кратковременных потерях сигнала ГНСС.

Задачи:

1. Проанализировать классические и нейросетевые методы восстановления траектории, выявить их ограничения при потерях 3–240 с.
2. Разработать эффективную модель НС ПСПС с линейной сложностью $O(N)$.
3. Разработать физически информированную модель ФИ-НС ПСПС, использующую телеметрию оборотов как новый информационный канал и как основу динамического функционала потерь на базе закона тяги $F=k \cdot n^2$.
4. Создать синтетический датасет Gazebo/PX4 с синхронизированными данными БИНС, ГНСС и оборотов двигателей квадрокоптера.
5. Провести комплексные экспериментальные исследования на синтетическом и реальном датасете AI-Ю.
6. Провести экспериментальную верификацию обобщающей способности разработанной нейросетевой системы на квадрокоптерных платформах с различными массо-инерционными характеристиками при полётах разной динамической сложности.

Объект исследования — система навигации мобильного робота (много-роторного беспилотного летательного аппарата), функционирующая в условиях кратковременных потерь сигнала глобальной навигационной спутниковой системы продолжительностью от 3 до 240 секунд.

Предмет исследования — методы и алгоритмы восстановления траектории мобильного робота в режиме постобработки на основе данных бесплатфор-

менной инерциальной навигационной системы и телеметрии оборотов несущих винтов, включая физически информированные нейросетевые модели с динамическим функционалом потерь.

0.4 Научная новизна

1. Впервые для задачи восстановления траектории мобильного робота при потерях сигнала ГНСС предложена и исследована нейросетевая архитектура отличающаяся использованием модели последовательностей с селективными пространствами состояний (ПСПС) обеспечивающая линейную сложность. Что допускает исполнение предложенной модели в реальном времени на бортовых нейроускорителях с ограниченными ресурсами.

2. Разработан метод физически информированного обучения нейросетевой модели с функцией потерь физической невязки на основе оборотов несущих винтов, отличающийся от известных физически информированных нейронных сетей для БПЛА, где физические ограничения обычно формулируются на основе кинематических соотношений или только данных инерциальных датчиков. Данный метод позволяет получать более сильный и физически обоснованный обучающий сигнал именно в режимах интенсивного дифференциального управления тягой.

3. Разработан и обоснован подход к использованию телеметрии оборотов несущих винтов в качестве самостоятельного навигационного источника, независимого от бесплатформенной инерциальной навигационной системы, отличающиеся от существующих работ, в которых обороты двигателей применяются только как дополнительный признак для улучшения оценки скорости. Данный подход демонстрирует что дифференциальные изменения тяги роторов принципиально ненаблюдаемы акселерометром и гироскопом, а так же демонстрирует информационную состоятельность оборотов несущих винтов.

4. Предложен принцип режимозависимой физической регуляризации, при котором функционал потерь автоматически усиливает вклад физических невязок при переходе платформы в динамический режим с повышенной активностью приводов, отличающиеся от классических физически информированных нейронных сетей с фиксированными весовыми коэффициентами физических членов потерь. Предложенный принцип обеспечивает адаптивное усиление обучающего сигнала

именно в тех режимах, где данные инерциальных датчиков наименее информативны. Это позволяет достигать высокой точности при дообучении модели на минимальном объёме калибровочных данных нового динамического режима.

5. Проведено исследование обобщающей способности разработанной нейросетевой системы на квадрокоптерных платформах с различными массо-инерционными характеристиками при полётах разной динамической сложности, что позволяет оценить практическую применимость предложенного метода в реальных условиях эксплуатации.

0.5 Теоретическая и практическая значимость исследования

Теоретическая значимость исследования заключается в следующем. Предложен принцип использования телеметрии актуаторов мобильного робота как нового самостоятельного навигационного источника, независимого от данных инерциальной системы, что расширяет класс информационных каналов, применимых в нейросетевых системах навигации без ГНСС. Разработан и теоретически обоснован метод режимозависимой физической регуляризации, обеспечивающий автоматическое усиление обучающего сигнала при смене динамического режима платформы. Предложенная архитектура ФИ-НС ПСПС расширяет класс физически информированных нейронных сетей на архитектуры с линейной вычислительной сложностью типа SSM, что открывает новое направление совместного применения физических ограничений и последовательностных моделей в задачах мобильной робототехники. Разработанный синтетический датасет с синхронизированными данными БИНС, ГНСС и RPM обеспечивает воспроизводимую исследовательскую основу для задачи восстановления траектории при потерях ГНСС.

Практическая значимость исследования состоит в следующем. Разработанная программа ФИ-НС ПСПС (свидетельство о государственной регистрации № 2026618441 от 25 марта 2026 г.) пригодна к непосредственному применению в системах постобработки данных беспилотных инспекционных комплексов. После квантования модель занимает 28 КБ; расчётное время инференса на нейроускорителе Neural-ART (STM32N6, 600 GOPS при INT8) не превышает 1 мс на сегмент, что обеспечивает работу в режиме реального времени при частоте 100 Гц. На

реальном датасете AI-IO при потере ГНСС 60 с достигается СКО $2,88 \pm 0,22$ м. Предложенный операционный протокол — один двухминутный калибровочный полёт перед миссией — обеспечивает адаптацию модели к новому динамическому режиму непосредственно в полевых условиях с СКО $9,4 \pm 1,8$ м при потере 240 с, что в 1,8 раза лучше базовой модели на полном датасете. Результаты применимы для беспилотных комплексов, выполняющих инспекцию линейной инфраструктуры (трубопроводы, ЛЭП), где кратковременные потери ГНСС являются штатной эксплуатационной ситуацией.

0.6 Методология и методы исследования

Теоретической основой служат три физических закона:

1. **Закон тяги несущего винта:** тяга i -го ротора $F_i = kn_i^2$, суммарная вертикальная тяга $F_z = k \sum_{i=1}^4 n_i^2$ уравнивает вес mg .
2. **Второй закон Ньютона** для поступательного движения: $m\ddot{\mathbf{r}}_I = m\mathbf{g} + R_{IB}\mathbf{F}_B + \mathbf{F}_{a,I}$, где $\mathbf{F}_{a,I} = -b_{\text{drag}}m\mathbf{v}$.
3. **Уравнения управляющих моментов:** $\tau_x = l(F_0 - F_2)$, $\tau_y = l(F_1 - F_3)$, $\tau_z = b(F_0 - F_1 + F_2 - F_3)$, где l — плечо, b — аэродинамическая константа момента.

Реализация — Python/PyTorch. Симуляция квадрокоптера Holybro X500 — Gazebo/PX4. Обучение нейронных сетей выполнялось на GPU NVIDIA GeForce GTX 1650. Верификация — 10 независимых тестовых сегментов по метрикам СКО и АТО.

0.7 Положения, выносимые на защиту

1. НС ПСПС обеспечивает линейную сложность $O(N)$ и превосходит Transformer по скорости восстановления траектории в 2,6–30 раз при длительностях потери 3–120 с при сопоставимой точности.

2. Включение нового информационного канала (телеметрия оборотов n_i) и физической модели динамики в функционал потерь обеспечивает СКО $14,3 \pm 2,3$ м при дообучении на 10% данных — ниже, чем у базовой модели на 100%.

3. ФИ-НС ПСПС превосходит базовые нейросетевые методы и метод РФК по совокупности критериев «точность – скорость – ресурсоёмкость» при длительностях потери ГНСС от 30 до 240 с на синтетическом датасете и при всех исследованных длительностях (3–60 с) на реальном датасете AI-Ю.

0.8 Степень достоверности полученных результатов

Достоверность полученных результатов обеспечена корректным применением методов математической статистики, теории нейронных сетей и уравнений динамики квадрокоптера. Метрики СКО и АТО вычислялись на независимых тестовых сегментах, составляющих 20% датасета и не участвовавших в обучении; в таблицах результатов приводятся значения «среднее $\pm$ стандартное отклонение» по 10 непересекающимся сегментам. Физическая адекватность предложенной модели подтверждена верификацией на открытом датасете AI-Ю лаборатории SJTU-ViSYS, не участвовавшей в разработке метода; результаты РФК для той же платформы использованы как внешний базовый показатель. Скоростные характеристики НС ПСПС подтверждены сопоставлением с Transformer Encoder и двунаправленной LSTM на адаптированном датасете EuRoC MAV. Разработанная программа зарегистрирована в Федеральной службе по интеллектуальной собственности (свидетельство № 2026618441 от 25 марта 2026 г.), что обеспечивает независимую верификацию факта создания программного продукта.

0.9 Личный вклад автора

Соискателем самостоятельно сформулированы цель и задачи исследования. Разработаны архитектуры моделей НС ПСПС и ФИ-НС ПСПС, включая физический функционал потерь на основе телеметрии оборотов несущих винтов. Создан синтетический датасет на базе симулятора Gazebo/PX4, содержащий синхронизи-

рованные данные БИНС, ГНСС и оборотов четырёх двигателей. Проведены все экспериментальные исследования, выполнен анализ и обобщение результатов. Разработана и зарегистрирована программа для ЭВМ. В совместных публикациях автор принимал непосредственное участие в постановке задачи, разработке метода, проведении экспериментов и обработке результатов. Все основные научные положения, компьютерные модели, практические решения и теоретические выводы сформулированы и выполнены автором самостоятельно.

0.10 Соответствие диссертации паспорту научной специальности

Диссертационная работа выполнена в соответствии с паспортом специальности 2.5.4 «Роботы, мехатроника и робототехнические системы» по пунктам:

- п. 5. *Методы, алгоритмы, программные и аппаратные средства управления роботами, робототехническими и мехатронными системами, включая адаптивное, оптимальное, распределённое, интеллектуальное и супервизорное управление.*
- п. 6. *Математическое и программное обеспечение, компьютерные методы и средства обработки информации в реальном времени в роботах, робототехнических и мехатронных системах.*

0.11 Основные публикации по теме диссертации

Публикации в изданиях, входящих в перечень ВАК:

1. Сидоренко Д. Д., Майстро А. С., Булдаков П. Ю., Сыромятников А. Д., Тимофеев А. Н. Сокращение вычислительных ресурсов в задаче восстановления траектории мобильных роботов при потере сигнала ГНСС // Наука и бизнес: пути развития. — 2026.
2. Сидоренко Д. Д., Тимофеев А. Н., Романов П. И. Физически информированная нейронная сеть для восстановления траектории квадрокоптера в условиях потери сигнала ГНСС // Вестник Московского авиационного института — 2026.

Свидетельство о государственной регистрации программы для ЭВМ:

3. Сидоренко Д. Д. ФИ-НС ПСПС — программа восстановления траектории квадрокоптера. Свидетельство о государственной регистрации программы для ЭВМ № 2026618441 от 25 марта 2026 г.

Объем и структура работы. Диссертация состоит из введения, 4 глав, заключения и 0 приложений. Полный объём диссертации составляет 84 страницы, включая 11 рисунков и 14 таблиц. Список литературы содержит 0 наименований.

Глава 1. Анализ современных методов восстановления траектории мобильных роботов при кратковременных потерях сигнала ГНСС

1.1 Задачи навигации мобильных роботов и беспилотных летательных аппаратов в условиях деградации и потери сигнала глобальной навигационной спутниковой системы

Современные задачи автономной навигации мобильных роботов и беспилотных летательных аппаратов (БПЛА) всё чаще связаны с работой в сложных промышленных и природных средах, где стабильный приём сигналов глобальных навигационных спутниковых систем (ГНСС) не может рассматриваться как гарантированное условие [5, 6, 7, 8]. К числу таких задач относятся инспекция протяжённых линейных объектов (трубопроводы, высоковольтные линии электропередачи) [7, 9, 10], картографирование и мониторинг заброшенных промышленных площадок [7, 11], поисково-спасательные операции в лесистой местности [6, 5], а также обследование инфраструктурных сооружений вблизи металлических конструкций [5, 6, 10].

Металлические конструкции промышленных объектов, экранирующие элементы эстакад, трубы и опоры линий электропередачи создают зоны устойчивого затенения и многолучевого распространения сигналов ГНСС [5, 7, 9]. В этих условиях полная потеря сигнала продолжительностью от нескольких секунд до нескольких минут становится не аварийной, а штатной операционной ситуацией [6, 5, 12]. Исследования показывают, что при выполнении миссий вблизи крупных металлических сооружений или под пролётами эстакад продолжительность непрерывных интервалов отсутствия ГНСС может достигать 30–240 с и более [5, 6, 12]. Аналогичная картина наблюдается при полётах над заброшенными карьерами и в условиях плотной растительности: отражённые сигналы и затенение приводят к значительному снижению доступности и точности позиционирования [7, 6, 5].

Для целого ряда практически важных приложений такая деградация сигнала носит системный характер. При термокартографировании трубопроводов и энергетических объектов БПЛА вынужден длительное время находиться в непосредственной близости от металлических конструкций [7, 9, 10]. В поисково-

спасательных операциях в лесу плотный полог деревьев существенно ослабляет сигналы спутников, делая позиционирование нестабильным на протяжении значительных участков маршрута [6, 5]. При картографировании заброшенных промышленных площадок с помощью беспилотных аппаратов возникают аналогичные проблемы из-за рельефа и наличия крупных металлических объектов [7, 11]. Во всех перечисленных случаях оператор не может полагаться на непрерывную работу ГНСС-приёмника и должен обеспечивать возможность восстановления траектории по данным бортовых датчиков в течение всего времени потери внешней коррекции [6, 12, 8].

Отсутствие надёжного ГНСС-сигнала ставит перед разработчиками навигационных систем две взаимосвязанные задачи. Во-первых, необходимо обеспечить непрерывность оценивания положения и ориентации аппарата на интервалах, когда внешняя коррекция недоступна [3, 12, 8]. Во-вторых, требуется минимизировать накопление ошибок инерциальной навигационной системы (БИНС), которые при использовании потребительских микроэлектромеханических датчиков растут по закону, близкому к квадратичному [3, 13, 8]. Уже при продолжительности потери сигнала 60–120 с позиционная ошибка может достигать десятков метров, а при 240 с — сотен метров, что делает результаты непригодными для большинства прикладных задач [6, 5, 12].

Существующие подходы к решению этих задач условно можно разделить на три большие группы: классические вероятностные фильтры, методы на основе глубокого обучения и гибридные физически информированные модели [3, 14, 15]. Каждая из групп имеет свои преимущества и ограничения, которые подробно рассматриваются в последующих разделах. Однако уже на этапе постановки задачи очевидно, что ни один из существующих подходов в полной мере не удовлетворяет требованиям, возникающим при выполнении длительных миссий в зонах устойчивой деградации ГНСС с возможностью быстрой адаптации к новым условиям при ограниченном объёме калибровочных данных [3, 16, 12].

Таким образом, анализ реальных эксплуатационных условий показывает, что разработка методов восстановления траектории, способных эффективно работать при кратковременных и средних по продолжительности потерях сигнала ГНСС в промышленных и природных средах, остаётся актуальной научно-технической задачей [5, 6, 7, 9, 12, 10]. Её решение требует как совершенствования существующих алгоритмов, так и поиска новых архитектурных решений, со-

четающих высокую точность, вычислительную эффективность и способность к быстрой адаптации [3, 14, 8].

1.2 Классические методы восстановления траектории при кратковременных потерях сигнала глобальной навигационной спутниковой системы

Классические подходы к восстановлению траектории мобильных роботов и БПЛА при временной недоступности сигналов ГНСС основаны на использовании вероятностных фильтров, интегрирующих данные бортовой инерциальной навигационной системы (БИНС) с доступными измерениями ГНСС [17, 18]. К таким подходам относятся

1. Расширенный фильтр Калмана (РФК) [18, 17].
2. Бессигматурный фильтр Калмана (БФК) с адаптивными модификациями [17].
3. ч Рауха–Тунга–Штрибеля (РТШ) на основе РФК [19].

Расширенный фильтр Калмана является базовым инструментом для слияния данных БИНС и ГНСС. Данный метод обладает относительно низкой вычислительной сложности и хорошей интерпретируемости результатов. Но при работе в динамических режимах полёта фильтр подвержен ошибкам. Ошибки подхода связанным с линеаризацией модели. Эти ошибки особенно заметны при резких манёврах и в условиях сильных внешних возмущений, в которых линейное приближение динамической модели оказывается недостаточно точным [20, 21]. Так же ошибка восстановленной траектории в значительной степени зависит от подобранных в ручную параметров фильтра: матриц ковариации шума процесса и измерений [18].

Бессигматурный фильтр Калмана (БФК) вместо якобианов использует сигма-точки для аппроксимации статистических характеристик нелинейных преобразований. Такой подход позволяет учитывать нелинейность системы. Что в свою очередь позволяет снизить ошибку траектории относительно РФК при сопоставимой вычислительной сложности. [18, 20]. Применение (БФК) для трехмерного позиционирования в условиях сложной среды в работе [19] позволило значительно снизить ошибку позиционирования относительно РФК. Минусом

БФК относительно РФК остается существенная зависимость ошибки траектории от начальной инициализации и выбора параметров адаптации [17, 18].

Расширением РФК может служить алгоритм сглаживания Рауха–Тунга–Штрибеля [19]. Данный алгоритм состоит из двух проходов: прямой проход фильтра Калмана и обратный проход сглаживания. В отличие от РФК и БФК предложенный в работе [19] подход предполагает обработку полной последовательности траектории, что соответствует задачи диссертации - восстановление траектории. Таким образом алгоритм РТШ применим а задачах постобработки сигнала. Данный метод опирается на граничные условия траектории: начальную и конечную точку маршрута. Минусом данного подхода является зависимость от точности модели системы, а так же большая вычислительная сложность относительно РФК и БФК [20, 21]

Классические не нейросетевые методы обладают следующими ограничениями при увеличении интервалов потери сигнала ГНСС [17, 18, 19]:

1. Ошибка позиционирования накапливается пропорционально $O(t^2)$. При длительных потерях сигнала в 120 с ошибка позиционирования приводит к недопустимо большим отклонениям
2. Методы РФК, БФК и РТШ требуют точной модели шума и динамики объекта. Ошибки в модели шума или динамики системы приводят с значительному росту ошибки позиционирования [20]
3. Сложные адаптивные методы, такие как РТШ, требуют значительных вычислительных ресурсов. Что в свою очередь накладывает ограничение на применимость данных методов на бортовых вычислителях при длительных потерях ГНСС сигналов [21, 22].

Описанные выше ограничения классических методов создают необходимость в разработке новых методов на основе глубокого обучения [23, 24]. Методы восстановления траектории на основе глубокого обучения позволяют обеспечивать более высокую устойчивость при ограниченном объеме данных о модели шума датчиков и динамической модели системы.

1.3 Нейросетевые подходы к восстановлению траектории основанные на данных

Ограничение классических методов восстановления траектории приводят к необходимости разработки новых методов на основе глубокого обучения. Методы основанные на данных (data-driven) позволяют напрямую аппроксимировать сложные нелинейные зависимости между показаниями инерциальных датчиков (без знания модели шумов датчиков) и параметрами движения без явного задания динамической модели системы [25, 26]. Методы основанные на данных способны извлекать скрытые зависимости из зашумлённых данных БИНС и снижать накопление ошибок дрейфа [27, 28]. В данном разделе термин "Методы основанные на данных" означает что нейронная сеть в своей архитектуре не предполагает наличие строгих физических и динамических зависимостей мобильного робота. Данные методы опираются только на зависимость во времени зависимости между БИНС и ГНСС.

В качестве методов основанных на данных выделяются следующие подходы:

1. Архитектур на основе долгой краткосрочной памяти Long-Short time memory (LSTM) [25].
2. Двухнаправленных LSTM [12].
3. Transformer Encoder [2]

Архитектур на основе долгой краткосрочной памяти (LSTM) [25] основана на обработке последовательных данных БИНС с помощью ячеек долгой и краткосрочной памяти. В экспериментах со статической и динамической траекториями обученная нейронная сеть в симуляции показала ошибку менее одного метра, а значение СКО оказалась существенно ниже РФК [29]. В реальных экспериментах расширенная нейронная сеть GC-LSTM [28] учитывает геометрические ограничения трубопровода. Геометрическое ограничение позволило снизить СКО на 70 % по сравнению с классическими методами восстановления траектории. Ограничением данного метода является требование к большому объему геометрически размеченных данных, что является трудоемкой задачей [27].

Другой подход к расширению классической LSTM является применение двухнаправленных LSTM [30]. Данный подход аналогично с алгоритмом сглаживания РТШ предполагает наличие двух проходов по последовательности: прямо

и обратный. Наличие двух проходов позволяет учитывать временные зависимости между БИНС и ГНСС как из прошлого так и из будущего. Данный подход применим исключительно для восстановления траектории, так как в момент t_i алгоритму необходимо знать состояние БИНС (а при обучении и ГНСС) в моменты t_{i-1} и t_{i+1} . Так же два прохода по временной последовательности значительно увеличивает временную и вычислительную сложности.

Другим подходом применения методов основанных на данных является Transformer Encoder [2]. Данный подход базируется на принципе внимания впервые предложенным в работе [31]. Данный подход отличается от рекуррентных архитектур возможностью параллельной обработки всей последовательности и эффективным моделированием долгосрочных зависимостей за счёт механизма само-внимания. Существенным ограничением данного подхода является квадратичная вычислительная сложность $O(n^2)$ относительно длины последовательности. Такая вычислительная сложность накладывает серьезные ограничения на его применимость на бортовых вычислителях при продолжительной потере сигнала [25]. Стоит отметить, что данная архитектура в том числе применяется и в задачах визуальной одометрии [27].

Применение нейросетевых методов к задаче восстановления траектории позволяет комбинировать различные подходы и архитектуры для повышения точности и устойчивости разрабатываемых решений. Такие решения объединяют сверточные слои CNN с рекуррентными слоями. В подобных решениях сверточные слои предназначены для извлечения пространственных признаков, рекуррентные или трансформенные слои предназначены для извлечения временных зависимостей. Подобные решения демонстрируют эффективность в реальных применениях [28, 32], но значительно усложняют архитектуру и процесс обучения [33].

Нейросетевые подходы на основе данных существенно расширяют возможности восстановления траектории при потере сигнала ГНСС. Однако методы основанные исключительно на данных имеют следующие ограничения:

1. Требование к большому набору качественных размеченных обучающих данных [26, 27].
2. Слабая возможность обобщения при смене динамического режима и конфигурации робота. Так как динамические, физические и геометрические и кинематические зависимости робота не явно жестко закладываются в веса нейронной сети в процессе обучения. [28, 33, 34].

Комбинация ограничений по количеству обучающих данных и слабой обобщаемости моделей при смене конструкции робота или режима движения становится особенно критично в задачах где оператор может позволить себе непродолжительные калибровочные полеты при смене условий работы [25, 26, 27, 28, 32, 33, 34].

1.4 Физически информированные нейронные сети в задачах оценки состояния и навигации роботов и беспилотных летательных аппаратов

В предыдущих разделах ?? описаны подходы явно не учитывающие физические ограничения платформы. Одним из подходов встраивания физических зависимостей и ограничений мобильного робота в архитектуру нейронных сетей является подход физически информированных нейронных сетей Physics-Informed Neural Networks, PINN) [35]. Физически информированные нейронные сети напрямую встраивают дифференциальные уравнения мобильного робота и другие физические ограничения в функцию потерь. Это позволяет в процессе обучения нейронной сети не только аппроксимировать данные, но и соблюдать физические ограничения мобильной платформы. В работе [35] впервые предложен физически информированный подход для позволяющие использовать дифференциальные уравнения мобильного робота в функцию потерь. Данный подход позволяет не только увеличить скорость сходимости процесса обучения, но и сохранить точность восстановления траектории при ограниченном объеме обучающих данных.

Другим применением PINN сетей может служить задача обреления динамических параметров мобильного робота. Так работа [15] показывает применимость PINN подхода для идентификации параметров робота, компенсации внешних возмущений и построения робастных оценок состояния. Данный подход может быть применен для первичной оценки динамических параметров мобильного робота для дальнейшего их использования в задачи восстановления траектории.

Квадрокоптеры обладают рядом принципиальных особенностей, которые существенно усложняют задачу восстановления траектории при временной недоступности сигналов ГНСС и одновременно делают применение физически ин-

формированных нейронных сетей особенно целесообразным. Эти особенности можно сформулировать следующим образом:

1. Квадрокоптер представляет собой систему с шестью степенями свободы, состояние которой описывается тремя координатами положения центра масс и четырьмя компонентами единичного кватерниона.
2. Платформа является принципиально неустойчивой. Без постоянной активной корректировки дифференциальной тяги несущих винтов квадрокоптер не способен сохранять равновесие и склонен к падению. Это требует от навигационной системы физической согласованности оценок.
3. В реальных миссиях у промышленных объектов состояние аппарата меняется очень быстро. Особенно ярко это проявляется в режиме компенсации порывов ветра, когда обороты отдельных роторов могут изменяться на несколько тысяч об/мин за короткие промежутки времени, в то время как суммарная тяга остается близкой к весу аппарата.

Перечисленные особенности приводят к тому, что чисто data-driven подходы, не учитывающие законы динамики твердого тела, склонны к быстрому накоплению ошибок и плохо обобщаются при смене динамического режима. Встраивание физических ограничений непосредственно в процесс обучения позволяет частично компенсировать эти недостатки.

В работе [14] показано, что включение уравнений Ньютона–Эйлера в функцию потерь нейронной сети даёт более устойчивые результаты недооценивания состояния квадрокоптера по сравнению с классическим расширенным РФК. Работа [36] развили этот подход, предложив гибридную схему, в которой физически информированная сеть сочетается с РФК. Авторам удалось получить архитектуру способную сохранять приемлемую точность даже при длительных сбоях ГНСС.

Отдельное внимание заслуживают исследования, посвященные работе в условиях ветровых возмущений. В [16] предложена архитектура свободная к непрерывному дообучению. За счет дообудения данная архитектура способна адаптироваться к изменяющимся внешним условиям.

В то же время в [37] продемонстрирована возможность построения компактных физически информированных моделей, которые сочетают последовательностную обработку с остатками уравнений движения и при этом сохраняют низкую вычислительную сложность, достаточную для работы в реальном времени на бортовых платформах.

Стоит отметить еще три работы применения PINN в робототехнике. В работе [38] PINN сети применяются для задач планирования траектории мобильных роботов. Так же модификации PINN применяются для навигации без ГНСС исключительно по данным БИНС [39]. PINN применяются не только для наземных и воздушных мобильных роботов, но и для надводных [40].

Описанные выше преимущества и ограничения PINN не учитывают следующие ограничения и возможности летающих мобильных роботов:

1. Не используется информация с актуаторов робота в качестве источника физического сигнала. Это значит что физические ограничения формулируются исключительно на уровне кинематических или динамических уравнений твёрдого тела.
2. Объединение PINN с LSTM и Transformer все еще требует $O(t^2)$ вычислительной сложности. Что накладывает серьезные ограничения на использовании таких подходов на бортовых вычислителях.

1.5 Архитектуры селективных последовательностей состояний

Рассмотренные ранее архитектуры на основе Transformer и LSTM широко применяются в больших языковых моделях. Подобные задачи обладают большой входной и выходной размерностью. Например, современные языковые модели, такие как Llama-3 или GPT-4, оперируют словарём размером от 32 до 128 тысяч токенов, а размерность скрытого представления достигает 4096–12288, что приводит к необходимости применения Transformer и LSTM для обработки подобных последовательностей. В то время как задача восстановления траектории ограничивается существенно меньшей размерностью: входной вектор обычно содержит 17–20 признаков, а выход модели формируется из 7–14 компонент. Данные, поступающие с инерциальных датчиков и телеметрии оборотов несущих винтов, представляют собой непрерывные физические сигналы с выраженной временной корреляцией и подчиняющиеся законам механики, что делает их структуру значительно проще по сравнению со сложной семантикой и контекстной многозначностью естественного языка. Данное значительное упрощение задачи относительно языковых моделей позволяет применить нейронную сеть с селективными последовательностями состояний (SSM Mamba)[41].

Нейронная сеть с селективными пространствами состояний обладает следующими преимуществами:

1. Линейная вычислительная сложность $O(t)$ относительно длины последовательности.
2. Линейная масштабируемость по памяти.
3. Способность эффективно моделировать долгосрочные временные зависимости благодаря механизму селективности.
4. Отсутствие проблемы затухания градиентов. item Высокая вычислительная эффективность при инференсе

Следует отметить следующие работы, направленные на развитие моделей с селективными пространствами состояний. Работа [42] показывает применимость Mamba в качестве кодировщика движения для задач имитационного обучения на роботах. В данной публикации авторы демонстрируют что Mamba обеспечивает высокую точность при существенно меньших вычислительных затратах по сравнению с архитектурами на основе механизма внимания.

Хорошим примером объединения ранее описанных data-driven подходов с физически информированными нейронными сетями служит работа комбинирующая PINN и Mamba [43]. Данная работу концентрируется исключительно на применение чистых PINN ограничений платформы без использования дополнительных датчиков. Рассматриваемый в данной работе подход расширяет область исследования засчет дополнительной информации оборотов винтов.

1.6 Использование телеметрии актуаторов как дополнительного источника навигационной информации

В задачах восстановления траектории при потере сигнала ГНСС особый интерес представляет телеметрия оборотов несущих винтов (RPM), доступная на борту большинства современных БПЛА без установки дополнительного оборудования. В режиме компенсации порывов ветра автопилот поддерживает суммарную вертикальную тягу близкой к весу аппарата, одновременно быстро перераспределяя обороты между роторами для создания управляющих моментов. В результате дифференциальные изменения тяги взаимно компенсируются в суммарном сигнале акселерометра, а угловые возмущения оказываются слабо

различимы гироскопом на фоне шума. Сигнал оборотов несущих винтов, напротив, напрямую отражает индивидуальную тягу каждого ротора по квадратичному закону и позволяет восстановить информацию об управляющих воздействиях, недоступную БИНС в агрессивных режимах.

Статистический анализ подтверждает линейную независимость сигналов. В режиме компенсации порывов ветра дисперсия дифференциальных оборотов возрастает в десятки раз по сравнению со спокойным полётом, при этом средний коэффициент корреляции Пирсона между каналами БИНС и оборотами остаётся низким. Это означает, что RPM несёт дополнительную, физически обоснованную информацию, которая особенно ценна именно в тех условиях, где данные инерциальных датчиков теряют информативность.

В литературе использование телеметрии актуаторов уже показало свою эффективность. Lu и соавторы продемонстрировали, что измерения скорости пропеллеров позволяют существенно улучшить оценку движения мультиротора [Lu2022]. Реальные датасеты, такие как AI-IO, содержат синхронизированные записи IMU и оборотов роторов и подтверждают повышение точности одометрии при наличии RPM-сигнала [44]. Работы по actuator-informed state estimation и гибридным SSM-моделям с сигналами актуаторов также показывают, что учёт телеметрии двигателей повышает робастность оценки состояния при внешних возмущениях и смене динамического режима.

Таким образом, телеметрия оборотов несущих винтов представляет собой доступный и информативный источник данных, который может существенно усилить физически информированные подходы к восстановлению траектории. Однако в существующих работах этот сигнал редко используется напрямую в качестве основы для физического регуляризатора нейронной сети, что определяет перспективное направление исследований.

1.7 Гибридные физически информированные модели на основе последовательностей в задачах инерциальной навигации

Сочетание последовательностных нейронных сетей с принципами физически информированного обучения позволяет одновременно учитывать сложные временные зависимости в данных БИНС и обеспечивать соблюдение фундамен-

тальных законов механики. Tan и соавторы предложили гибридную схему, где PINN с ограничениями в виде дифференциальных уравнений используется для компенсации дрейфа, а полученная оценка передаётся в unscented Kalman filter на многообразиях [36]. Zhou и соавторы дополнили LSTM-подобную структуру физическими остатками уравнений движения для предсказания раскачивания груза на мобильном кране [45]. Bianchi и соавторы применили PINN с элементами последовательностной обработки для идентификации динамической модели квадрокоптера, продемонстрировав преимущество над классическим фильтром Калмана [14]. Shurin и Klein разработали гибридную архитектуру QuadNet, сочетающую нейросетевую модель с уравнениями движения для dead reckoning квадрокоптера [46].

Несмотря на достигнутые результаты, существующие гибридные решения имеют общие ограничения. Большинство из них либо используют внешний фильтр Калмана после нейронной сети, либо не включают телеметрию актуаторов (обороты винтов) напрямую в физический регуляризатор потерь, либо сохраняют высокую вычислительную сложность. В литературе практически отсутствуют работы, в которых линейные по сложности архитектуры семейства Mamba интегрированы с полноценным механизмом физически информированного обучения, явно зависящим от оборотов несущих винтов, для задачи восстановления траектории БПЛА при потере сигнала ГНСС.

Таким образом, анализ существующих гибридных подходов выявляет перспективный пробел: отсутствие end-to-end моделей, сочетающих вычислительную эффективность последовательностных архитектур с строгой физической согласованностью на основе телеметрии актуаторов и способностью к быстрой адаптации на малых данных.

1.8 Анализ публикационной активности и выявление пробелов в литературе

Переведенный в предыдущих разделах обзор различных методов восстановления траектории мобильных роботов показывает основные тенденции в развитии методов направленных снижении ошибки восстановленной траектории и снижении вычислительной сложности. Классические методы, такие как фильтр Калмана, продолжают развитие за счет адаптивных версий, сглаживаний,

нескольких проходов и учета граничных условий. Но применяемые модификации все еще не способны обеспечить удовлетворительную точность при длительных потерях ГНСС сигнала. Так же наблюдается значительный рост интереса к методам основанным на глубоком обучении, в том числе к методам основанным на данных, гибридным методам, методам с физическими ограничениями (PINN) и гибридным архитектурам.

Несмотря на значительный прогресс, в литературе сохраняется ряд принципиальных пробелов:

1. Большинство нейросетевых методов (LSTM, Transformer, гибридные CNN-LSTM) требуют больших объёмов размеченных данных и плохо обобщаются при смене динамического режима (например, при переходе к компенсации порывов ветра).
2. Физически информированные подходы (PINN) чаще всего сохраняют квадратичную вычислительную сложность и редко используют телеметрию актуаторов (обороты несущих винтов) напрямую в качестве источника физического supervision-сигнала.
3. Архитектуры семейства Mamba/SSM демонстрируют высокую эффективность при обработке длинных последовательностей, однако их сочетание с полноценным физически информированным регуляризатором на основе оборотов винтов в задачах GNSS outage практически не исследовано.
4. Отсутствуют работы, в которых одновременно решаются задачи высокой точности восстановления траектории, низкой вычислительной сложности, возможности быстрого дообучения на малых данных (2–4 минуты полёта) и переноса на платформы разной массы без полной переподготовки.

Сводный сравнительный анализ основных классов методов представлен в таблице 1.

Таблица 1 — Сравнительный анализ методов восстановления траектории при потерях сигнала ГНСС

Метод	Применимость	Точность	Основные ограничения
EKF [17]	Инспекция трубопроводов, ЛЭП, навигация роботов	Хорошая при outage <30 с; сильный дрейф при 60–120 с	Ошибки линеаризации, чувствительность к модели шума, быстрый рост ошибки
AUKF [6]	Поисково-спасательные работы в лесу, GNSS-denied зоны	Снижение ошибки на 8–18 % по сравнению с EKF	Высокая вычислительная сложность, требует точной инициализации
RTS Smoother [19]	Реконструкция траекторий БПЛА с граничными условиями	Высокая точность за счёт глобальной оптимизации	Оффлайн-метод, сложен для длинных последовательностей
LSTM (IMU + GPS) [1]	Навигация БПЛА и наземных роботов при outage ГНСС	Радиальная ошибка 1,31 м (эксперимент)	Требует больших данных, склонен к переобучению, нет физической согласованности
CNN-LSTM Hybrid [25]	Motion tracking, indoor навигация, детектирование паттернов	Хорошая точность в зашумлённых условиях	Сложная архитектура, требует GPU, низкая интерпретируемость
Transformer / CNN-Transformer [2]	Длинные последовательности IMU при outage ГНСС	Хорошая работа с длинными seq.	Квадратичная сложность $O(n^2)$, высокие требования к памяти
PINN (оценка состояния БПЛА) [14]	Идентификация динамики квадрокоптеров в условиях неопределённости	Устойчивость при шуме и малых данных	Квадратичная сложность, сложность обучения
Hybrid PINN + фильтр [36]	Полная оценка состояния платформ только по IMU	Высокая точность даже при длительных outage	Не полностью end-to-end, требует внешнего фильтра
Mamba (SSM) [41, 42]	Обработка длинных IMU-последовательностей роботов и БПЛА	Линейная сложность, хорошее масштабирование	Меньше накопленного опыта применения в GNSS-denied задачах
GC-LSTM (pipeline robot) [9]	Инспекция трубопроводов в условиях экранирования	Max deviation 0,093–0,252 м	Специализирован под геометрию трубы, не универсален для свободного полёта
TCN-BiLSTM + ANR-IEKF [12]	Наземные платформы, sustained positioning при outage	Высокая точность и робастность	Сложность гибридной настройки, в основном для наземных роботов

1.9 Выводы по главе

Проведённый анализ современных методов восстановления траектории мобильных роботов и БПЛА при кратковременных потерях сигнала ГНСС позволил выявить следующие ключевые тенденции и ограничения.

Классические вероятностные фильтры (EKF, UKF, AUKF, RTS) обеспечивают приемлемую точность при коротких потерях ГНСС, однако при увеличении продолжительности потери сигнала свыше 60–120 с быстро накапливают ошибку и требуют точной настройки модели шума. Нейросетевые подходы основанные на данных (LSTM, Transformer, гибридные архитектуры) демонстрируют хорошие результаты при наличии больших обучающих выборок, но склонны к переобучению и плохо обобщаются при смене динамического режима. Физически информированные нейронные сети (PINN) и их гибридные варианты повышают физическую согласованность оценок и улучшают обобщение при ограниченных данных, однако в большинстве случаев сохраняют высокую вычислительную сложность и не используют телеметрию актуаторов напрямую в физическом регуляризаторе.

Наиболее перспективным направлением для решения поставленной задачи представляется сочетание линейных по сложности последовательностных архитектур (Mamba/SSM) с физически информированным обучением, явно использующим телеметрию оборотов несущих винтов. В существующей литературе такие практически отсутствуют.

Глава 2. Математическая модель квадрокоптера

2.1 Введение

Для построения физически информированной нейросетевой системы оценки состояния квадрокоптера в условиях кратковременных потерь сигнала ГНСС необходимо располагать математической моделью, которая, с одной стороны, точно описывает динамику платформы, а с другой — позволяет сформулировать физический регуляризатор в функции потерь нейронной сети. Такая модель должна связывать управляющие воздействия, измерения бортовой инерциальной навигационной системы (БИНС) и истинное движение аппарата, а также объяснять, почему телеметрия оборотов несущих винтов несёт информацию, принципиально недоступную акселерометру и гироскопу в определённых режимах полёта.

В настоящей работе используется модель квадрокоптера как твёрдого тела с шестью степенями свободы, дополненная детальной моделью несущих винтов с учётом основных аэродинамических эффектов. Данная модель опирается на классические уравнения Ньютона–Эйлера и теорию элемента лопасти в сочетании с теорией количества движения (ВЕМ). Такой подход позволяет, во-первых, получить физически обоснованный остаток в функции потерь нейронной сети, а во-вторых — количественно обосновать информационную ценность телеметрии оборотов несущих винтов именно в режиме компенсации порывов ветра, который наиболее характерен для задач термокартографирования протяжённых промышленных объектов.

Ключевым элементом предлагаемого подхода является использование телеметрии оборотов несущих винтов не только как дополнительного входного сигнала нейронной сети, но и как основы для физического регуляризатора потерь. Как будет показано ниже, в режиме компенсации порывов ветра автопилот поддерживает суммарную вертикальную тягу близкой к весу аппарата, при этом быстро перераспределяя обороты между роторами для создания управляющих моментов. В результате дифференциальные изменения тяги взаимно компенсируются в суммарном сигнале акселерометра, а угловые возмущения оказываются слабо различимы на фоне шума гироскопа. Сигнал оборотов несущих винтов, на-

против, напрямую отражает индивидуальные силы тяги и моменты, создаваемые каждым ротором. Это наблюдение подтверждается как теоретическим анализом уравнений динамики, так и статистической оценкой линейной независимости сигналов с помощью коэффициента корреляции Пирсона.

Модель, представленная в данной главе, служит теоретической основой для разработки физически информированной нейросетевой архитектуры ФИ НС-ПСПС 3 и для интерпретации результатов экспериментального исследования 4. В частности, она позволяет сформулировать динамический функционал потерь, содержащий остатки второго закона Ньютона, вычисляемые с использованием известных оборотов несущих винтов. Такой регуляризатор существенно повышает физическую согласованность предсказаний модели именно в тех условиях, где объём дообучающих данных ограничен, а риск переобучения высок.

2.2 Кинематическая модель квадрокоптера как твёрдого тела

Квадрокоптер рассматривается как твёрдое тело с шестью степенями свободы. Для описания его движения вводятся две системы координат: инерциальная система W , жёстко связанная с Землёй (ось z направлена вертикально вверх, против вектора силы тяжести), и связанная система B , жёстко связанная с корпусом аппарата (ось z совпадает с осью симметрии квадрокоптера и направлена вдоль вектора суммарной тяги несущих винтов). Схема осей и систем координат приведена на рисунке 2.1

Пусть $\mathbf{p}^W \in \mathbb{R}^3$ — положение центра масс квадрокоптера в инерциальной системе координат, $\mathbf{v}^W \in \mathbb{R}^3$ — линейная скорость центра масс в той же системе, а $\mathbf{R}_B^W \in SO(3)$ — матрица направляющих косинусов, осуществляющая преобразование векторов из связанной системы координат в инерциальную. Угловую скорость корпуса в связанной системе обозначим $\boldsymbol{\omega}^B \in \mathbb{R}^3$.

Кинематика поступательного движения описывается простым соотношением:

$$\dot{\mathbf{p}}^W = \mathbf{v}^W. \quad (2.1)$$

Кинематика вращательного движения записывается с помощью оператора кососимметричной матрицы $[\cdot]_\times$:

$$\dot{\mathbf{R}}_B^W = \mathbf{R}_B^W [\boldsymbol{\omega}^B]_\times, \quad (2.2)$$




Рисунок 2.1 — Кинематика и динамика квадрокоптера. Инерциальная система координат $\mathcal{W}$ (зелёная) и связанная система координат $\mathcal{B}$ (красная/оранжевая/синяя) с положением центра масс $\mathbf{r}_{\mathcal{W}\mathcal{B}}$ (бирюзовый), линейной скоростью $\mathbf{v}_{\mathcal{W}}$ (пурпурный), угловой скоростью $\boldsymbol{\omega}_{\mathcal{B}}$ (фиолетовый), силами тяги отдельных роторов $f_i = k_T \omega_i^2$ (синие стрелки), силой тяжести $\mathbf{g}$ (зелёный), моментами крена, тангажа и рыскания $\tau_{x,y,z}$ и кватернионом ориентации $\mathbf{q}_{\mathcal{W}\mathcal{B}}$. Роторы 1 и 3 вращаются по часовой стрелке (CW, синие эллипсы), роторы 2 и 4 — против часовой стрелки (CCW, красные эллипсы).

где

$$[\boldsymbol{\omega}^B]_{\times} = \begin{bmatrix} 0 & -\omega_z & \omega_y \\ \omega_z & 0 & -\omega_x \\ -\omega_y & \omega_x & 0 \end{bmatrix}.$$

Для численного интегрирования и последующего использования в нейросетевой архитектуре часто удобнее работать с кватернионным представлением ориентации. Пусть $\mathbf{q} \in \mathbb{S}^3$ — единичный кватернион, описывающий ориентацию связанной системы относительно инерциальной. Тогда кинематическое уравнение для кватерниона принимает вид:

$$\dot{\mathbf{q}} = \frac{1}{2} \mathbf{q} \otimes \boldsymbol{\omega}^B, \quad (2.3)$$

где $\otimes$ обозначает операцию кватернионного умножения. Кватернионное представление обеспечивает численную устойчивость при интегрировании на

длительных интервалах и автоматически сохраняет свойство ортогональности матрицы поворота (в отличие от непосредственного интегрирования уравнения (2.2)).

Выбор матричного или кватернионного представления ориентации определяется контекстом. В аналитических выкладках и при формулировке физического регуляризатора потерь удобно использовать матрицу $\mathbf{R}_B^W$, тогда как при численном интегрировании траектории и в реализации нейронной сети предпочтительнее кватернионная форма. В дальнейшем в работе будут использоваться оба представления в зависимости от решаемой задачи.

Кинематические уравнения (2.1)–(2.3) являются точными и не содержат приближений. Они служат первой частью полной математической модели, необходимой для построения физически информированной нейросетевой системы. Следующий раздел посвящён динамике поступательного и вращательного движения квадрокоптера.

2.3 Динамическая модель твёрдого тела

Динамика поступательного и вращательного движения квадрокоптера описывается уравнениями Ньютона–Эйлера, записанными в инерциальной и связанной системах координат соответственно. Эти уравнения лежат в основе физического регуляризатора потерь нейронной сети и позволяют связать измеряемые БИНС ускорения и угловые скорости с силами и моментами, создаваемыми несущими винтами.

Поступательное движение центра масс в инерциальной системе координат W подчиняется второму закону Ньютона:

$$m\dot{\mathbf{v}}^W = \mathbf{R}_B^W \mathbf{F}^B - m\mathbf{g}^W + \mathbf{F}_{\text{аэр}}^B, \quad (2.4)$$

где m — масса платформы, $\mathbf{F}^B \in \mathbb{R}^3$ — суммарная сила, создаваемая несущими винтами в связанной системе координат B , $\mathbf{g}^W = [0, 0, -9,81]^\top$ м/с² — вектор ускорения свободного падения, а $\mathbf{F}_{\text{аэр}}^B$ — аэродинамическая сила сопротивления корпуса и взаимодействия потоков.

Вращательное движение в связанной системе координат B описывается уравнением Эйлера:

$$\mathbf{J}\dot{\boldsymbol{\omega}}^B + \boldsymbol{\omega}^B \times \mathbf{J}\boldsymbol{\omega}^B = \boldsymbol{\tau}^B, \quad (2.5)$$

где $\mathbf{J} \in \mathbb{R}^{3 \times 3}$ — тензор инерции аппарата относительно центра масс, выраженный в связанной системе координат, а $\boldsymbol{\tau}^B \in \mathbb{R}^3$ — суммарный момент сил, создаваемый несущими винтами.

Тензор инерции $\mathbf{J}$ для реального квадрокоптера Holybro X500 V2 определяется либо экспериментально (путём качания платформы на подвесе), либо из CAD-модели и SDF-файла симулятора. В общем случае $\mathbf{J}$ является симметричной положительно определённой матрицей с ненулевыми продуктами инерции. Однако для большинства симметричных квадрокоптеров с близкой к крестообразной компоновкой продукты инерции малы и часто пренебрегаются, оставляя диагональную структуру:

$$\mathbf{J} = \text{diag}(J_{xx}, J_{yy}, J_{zz}).$$

Аэродинамическое сопротивление корпуса в первом приближении аппроксимируется линейной зависимостью от скорости:

$$\mathbf{F}_{\text{аэ}}^B = -b_{\text{drag}} m \mathbf{v}^B, \quad (2.6)$$

где коэффициент $b_{\text{drag}} > 0$ является обучаемым параметром модели и может быть идентифицирован по лётным данным. Более точные модели учитывают квадратичное сопротивление и индуцированное сопротивление от несущих винтов; эти эффекты будут рассмотрены в следующем разделе.

Уравнения (2.4) и (2.5) являются точными в рамках допущений о твёрдом теле и сосредоточенных силах. Они не содержат внутренних динамических состояний (кроме ориентации и скорости) и поэтому удобны для встраивания в физически информированные нейронные сети в виде остатков. Подстановка измеряемого БИНС ускорения в уравнение (2.4) позволяет выразить невязку между предсказанным и физически ожидаемым ускорением через известные обороты несущих винтов — именно этот остаток будет использоваться в качестве физического регуляризатора потерь в главе 3.

Таким образом, динамическая модель твёрдого тела задаёт строгие физические ограничения, которым должна удовлетворять нейросетевая оценка состояния. Следующий раздел посвящён детальному описанию сил и моментов,

создаваемых несущими винтами, — ключевому элементу, позволяющему связать телеметрию оборотов с динамикой платформы.

2.4 Подробная модель сил и моментов несущих винтов

Силы и моменты, создаваемые несущими винтами, являются основным источником управляющих воздействий квадрокоптера. Именно через эти величины телеметрия оборотов роторов связывается с динамикой платформы и становится полезной для физически информированной нейронной сети. В настоящей работе используется двухуровневое описание аэродинамики винтов: простая квадратичная модель для базовых расчётов и более точная модель на основе теории элемента лопасти в сочетании с теорией количества движения (БЕМ), учитывающая влияние скорости набегающего потока.

В простейшем приближении, справедливом для умеренных скоростей полёта и небольших углов атаки, тяга F_i и реактивный момент Q_i отдельного винта аппроксимируются квадратичными зависимостями от угловой скорости вращения ω_i (рад/с):

$$F_i = k_t \omega_i^2, \quad Q_i = k_q \omega_i^2 \cdot \text{sign}(\omega_i), \quad (2.7)$$

где коэффициенты $k_t > 0$ и $k_q > 0$ определяются экспериментально на стенде статической тяги или идентифицируются по лётным данным. Суммарная сила и момент в связанной системе координат записываются как

$$\mathbf{F}^B = \sum_{i=1}^4 F_i \mathbf{e}_z + \mathbf{F}_{\text{drag}}, \quad (2.8)$$

$$\boldsymbol{\tau}^B = \sum_{i=1}^4 (Q_i \mathbf{e}_z + \mathbf{r}_{P,i} \times F_i \mathbf{e}_z) + \boldsymbol{\tau}_{\text{drag}}, \quad (2.9)$$

где $\mathbf{r}_{P,i}$ — радиус-вектор расположения i -го винта относительно центра масс, $\mathbf{e}_z$ — единичный вектор оси z связанной системы. Члены $\mathbf{F}_{\text{drag}}$ и $\boldsymbol{\tau}_{\text{drag}}$ учитывают индуцированное сопротивление и взаимное влияние потоков от соседних винтов.

Более точное описание аэродинамики отдельного винта даёт теория элемента лопасти в сочетании с теорией количества движения (БЕМ). Согласно этой теории, индуцированная скорость v_i и аэродинамические коэффициенты зависят

от относительной скорости набегающего потока. В работах по гибриднему аэродинамическому моделированию квадрокоптеров (NeuroBEM, arXiv:2106.08015) показано, что коэффициенты тяги C_T и момента C_Q являются функциями не только угловой скорости, но и составляющих скорости набегающего потока v_x, v_y, v_z в плоскости ротора. Это приводит к появлению дополнительных слагаемых в выражении для силы тяги, пропорциональных $\omega_m^2 v_x, \omega_m^2 v_y$ и $\omega_m^2 v_z$, где $\omega_m^2 = \sum_{i=1}^4 \omega_i^2$.

Такая зависимость имеет принципиальное значение для задач оценки состояния. Измеряемое акселерометром ускорение зависит не только от управляющих воздействий (через суммарную тягу), но и от текущей линейной скорости полёта. Следовательно, зная текущие обороты несущих винтов, можно в принципе восстановить часть информации о скорости, «спрятанной» в сигнале БИНС. Именно этот факт лежит в основе использования телеметрии оборотов как дополнительного входа нейросети и как источника физического регуляризатора потерь.

Параметры аэродинамической модели (k_t, k_q , коэффициенты индуцированного сопротивления) для платформы Holybro X500 V2 могут быть взяты из SDF-модели симулятора или уточнены по результатам идентификации на реальных данных. В контексте физически информированных нейронных сетей эти параметры либо фиксируются, либо становятся обучаемыми величинами, что позволяет модели адаптироваться к конкретной платформе при дообучении.

Таким образом, модель сил и моментов несущих винтов обеспечивает прямую связь между телеметрией оборотов и физическими остатками в функции потерь нейронной сети. В следующем разделе рассматриваются модели датчиков, с помощью которых эти остатки сравниваются с реальными измерениями.

2.5 Модели датчиков и телеметрии

Для обучения и оценки физически информированной нейросетевой системы необходимо располагать реалистичными моделями измерений, которые связывают истинное состояние платформы с сигналами, доступными на борту. В настоящей работе используются три основных источника данных: бортовая инерциальная навигационная система (БИНС), приёмник ГНСС и телеметрия оборотов несущих винтов. Все модели датчиков реализованы в симуляторе

PX4/Gazebo и соответствуют характеристикам реальной платформы Holybro X500 V2.

Бортовая инерциальная навигационная система включает трёхосевой акселерометр, трёхосевой гироскоп и трёхосевой магнитометр. Измерения БИНС моделируются с частотой 200 Гц и содержат как медленно меняющиеся смещения (bias), так и высокочастотный шум. Модель измерений гироскопа записывается в виде

$$\tilde{\omega}^B = \omega^B + \mathbf{b}_g + \mathbf{n}_g, \quad (2.10)$$

где $\mathbf{b}_g$ — вектор смещений (дрейф), а $\mathbf{n}_g$ — белый гауссовский шум с нулевым средним и стандартным отклонением, типичным для потребительских МЭМС-датчиков класса ICM-42688 ($\sigma_g \approx 0,00087$ рад/с).

Аналогичная модель используется для акселерометра:

$$\tilde{\mathbf{a}}^B = \mathbf{R}_W^B (\dot{\mathbf{v}}^W - \mathbf{g}^W) + \mathbf{b}_a + \mathbf{n}_a, \quad (2.11)$$

где $\mathbf{b}_a$ — смещение, а $\mathbf{n}_a$ — шум с $\sigma_a \approx 0,0064$ м/с² по осям x и y и несколько большим значением по оси z (учитывается влияние гравитации и вибраций). Магнитометр моделируется с частотой 100 Гц и низким уровнем шума, что позволяет использовать его для коррекции угла рыскания при наличии магнитных возмущений.

Приёмник ГНСС имитируется с частотой обновления 5 Гц и позиционным шумом, соответствующим RTK-режиму в открытых условиях ($\sigma_{\text{GNSS}} \approx 0,05\text{--}0,1$ м). Потеря сигнала моделируется путём маскирования выходных данных (значения заменяются на NaN или специальный флаг), что позволяет формировать обучающие примеры с имитируемыми outage длительностью от 3 до 240 с.

Особое внимание в работе уделяется телеметрии оборотов несущих винтов. Этот сигнал считывается непосредственно с контроллера моторов (ESC) или полётного контроллера с частотой 200 Гц и представляет собой угловые скорости четырёх роторов $\mathbf{n} = [n_1, n_2, n_3, n_4]^T$ (об/мин). В симуляторе и на реальной платформе Holybro X500 V2 этот сигнал доступен без установки дополнительного оборудования и обладает низкой задержкой. Квантование сигнала составляет примерно 10 об/мин, что соответствует разрешению типичных ESC. В отличие от данных БИНС, телеметрия оборотов напрямую отражает индивидуальные управляющие воздействия и не подвержена интегрирующему дрейфу.

Основные характеристики датчиков и телеметрии сведены в таблицу 2.

Таблица 2 — Характеристики датчиков и телеметрии, используемых в работе

Источник данных	Частота	Шум / разрешение	Примечание
Акселерометр (БИНС)	200 Гц	$\sigma_a \approx 0,0064 \text{ м/с}^2$	Смещения + шум
Гироскоп (БИНС)	200 Гц	$\sigma_g \approx 0,00087 \text{ рад/с}$	Смещения + шум
Магнитометр	100 Гц	Низкий	Коррекция рыскания
ГНСС	5 Гц	$\sigma \approx 0,05\text{--}0,1 \text{ м}$	Маскирование при outage
Обороты винтов	200 Гц	Квантование $\approx 10 \text{ об/мин}$	Прямое считывание с ESC

Модели датчиков, описанные выше, позволяют формировать обучающие и тестовые наборы данных, в которых одновременно присутствуют измерения БИНС, телеметрия оборотов и точные ground truth значения положения, скорости и ориентации из симулятора. Именно такое сочетание данных делает возможным обучение физически информированных нейронных сетей с регуляризатором на основе оборотов несущих винтов.

В следующем разделе приводится описание экспериментальной платформы Holybro X500 V2 и ограничений, накладываемых условиями реальной задачи термокартографирования промышленных объектов.

2.6 Описание экспериментальной платформы Holybro X500 V2 и ограничения навигационной системы

Объектом исследования является система навигации автономного квадрокоптера Holybro X500 V2, предназначенного для выполнения задач термокартографирования протяжённых промышленных объектов в условиях кратковременных потерь сигнала ГНСС. Платформа представляет собой типичный представитель класса малых квадрокоптеров с максимальной взлётной массой 1–3 кг, оснащённых тепловизионной камерой и бортовой инерциальной навигационной системой на основе потребительских МЭМС-датчиков.

Holybro X500 V2 построен на базе полностью углеродной рамы с колёсной базой 500 мм. Масса рамы и комплекта (ARF kit) составляет около 610 г, а полная масса платформы в конфигурации с батареей 4S 5000 мА·ч и полезной нагрузкой достигает примерно 2,0 кг (значение, используемое в SDF-модели симулятора). Тензор инерции относительно центра масс в связанной системе координат имеет следующие диагональные элементы: $I_{xx} = I_{yy} \approx 0,02167 \text{ кг}\cdot\text{м}^2$

и $I_{zz} \approx 0,0400$ кг·м². Длина плеча от центра масс до оси каждого ротора составляет 0,174 м. Платформа оснащена четырьмя моторами Holybro 2216 KV880 (или KV920), электронными регуляторами скорости Holybro BLHeli S 20A и пропеллерами типоразмера 1045 (CW/CCW). Полётный контроллер — Pixhawk 6C с прошивкой PX4, обеспечивающий внутренние контуры стабилизации ориентации и угловой скорости, работающие автономно от сигнала ГНСС.

Кроме того, платформа оснащена нейронным процессором (NPU), что дает возможность для обработки результатов инференса нейронных сетей уже непосредственно на борту с минимальными дополнительными требованиями к ресурсам центрального процессора. Данное обстоятельство делает возможной практическую реализацию физически обоснованных нейросетевого оценок состояния в рамках реальных миссий.

Условия применения накладывают жёсткие ограничения на выбор методов навигации.

1. Максимальная взлётная масса в диапазоне 1–3 кг существенно ограничивает возможность установки дополнительных тяжёлых сенсоров (лидаров высокого класса, стереокамер).
2. Тепловизионная камера, предназначенная для картографирования, не может служить надёжным источником визуальной одометрии: металлические поверхности промышленных объектов характеризуются однородным тепловым полем, практически лишённым угловых точек и текстурных особенностей. Кроме того, периодическая коррекция неоднородности прерывает поток данных, делая визуальную одометрию нестабильной
3. Показания лидаров существенно деградируют в запылённой и задымлённой среде промышленных площадок, где часто выполняются инспекционные работы

В отсутствие внешней коррекции от ГНСС потребительские МЭМС-акселерометры и гироскопы накапливают постоянно растущую позиционную ошибку, описываемую законом $O(t^2)$. При длительности потери сигнала 240 с эта ошибка может достигать десятков и сотен метров, что делает чисто инерциальную навигацию непригодной для задач, требующих точного восстановления траектории.

Таким образом, ни один из стандартных методов навигации без ГНСС (визуальная одометрия, лидарная одометрия, классические фильтры Калмана без

дополнительных измерений) не применим одновременно при описанных выше ограничениях платформы и среды. Возникает необходимость в альтернативном источнике навигационной информации, доступном на борту без дополнительной аппаратной нагрузки. Таким источником, как будет показано в разделе 2.8, является телеметрия оборотов несущих винтов.

В следующем разделе описывается симуляционная среда, в которой проводились все эксперименты по обучению и оценке предложенной физически информированной нейросетевой системы.

2.7 Симуляционная среда PX4/Gazebo с плагином RotorS

Все эксперименты по обучению и оценке физически информированной нейросетевой системы проводились в симуляторе PX4/Gazebo с плагином RotorS. Выбор данной среды обусловлен несколькими ключевыми факторами, делающими её стандартным бенчмарком для исследований в области нейросетевой навигации беспилотных летательных аппаратов.

PX4 представляет собой открытый программный стек автопилота, полностью идентичный по архитектуре и алгоритмам управления реальным коммерческим платформам. Это обеспечивает высокую степень переносимости результатов из симуляции на реальное оборудование. Gazebo, в свою очередь, предоставляет физически корректную модель динамики квадрокоптера, включающую аэродинамические взаимодействия несущих винтов, силу тяжести, аэродинамическое сопротивление корпуса и реалистичные модели порывов ветра. Плагин RotorS расширяет возможности Gazebo специализированными моделями мультироторных платформ и датчиков, что позволяет получать синхронизированные данные с высокой точностью.

Физически информированные нейронные сети PINN для требуют датасета с различными режимами полета. В реальных условиях за частую получения датасета с различными динамическими характеристиками (скорость движение, частота и скорость поворота, различные погодные и ветровые условия) за частую является невозможным. Применение же симулятора с различными динамическими характеристиками миссии мобильного робота позволяет собрать датасет учитывающий различные режимы работы робота.

В симуляторе реализованы следующие датчики в качестве плагинов:

1. Бортовая инерциальная навигационная система (акселерометр, гироскоп, магнитометр) моделируется с частотой 200 Гц и реалистичными значениями шума и смещений, соответствующими потребительским МЭМС-датчикам (ICM-42688 и аналогичным).
2. Приёмник ГНСС имитируется с частотой 5 Гц и возможностью маскирования сигнала для создания сценариев потери ГНСС.
3. Телеметрия оборотов несущих винтов генерируется с частотой 200 Гц непосредственно из модели силовой установки и соответствует сигналу, доступному на реальном полётном контроллере.

Для проведения экспериментов были сформированы два основных датасета:

1. Датасет А соответствует стандартному (спокойному) режиму полёта с ограниченными манёврами и номинальной траекторией горизонтального облёта промышленного объекта.
2. Датасет В имитирует режим компенсации порывов ветра с резкими изменениями скорости и направления, характерными для работы вблизи металлических конструкций.

Оба датасета содержат синхронизированные данные БИНС, ГНСС, телеметрию оборотов четырёх несущих винтов и точные ground truth значения из внутреннего состояния симулятора.

Подготовка данных включала ресемплинг до единой частоты 100 Гц, линейную интерполяцию пропущенных значений и формирование сегментов с имитируемыми потерями сигнала ГНСС длительностью от 3 до 240 с. Для каждого сегмента сохранялись начальная и конечная позиции, что позволяет использовать двунаправленное интегрирование с граничными условиями при оценке качества восстановления траектории.

Симуляционная среда PX4/Gazebo с RotorS обеспечивает необходимое сочетание физической достоверности, синхронизации данных и масштабируемости, что делает её оптимальной платформой для разработки и верификации физически информированных нейросетевых систем навигации квадрокоптера.

В следующем разделе приводится развёрнутое обоснование применимости телеметрии оборотов несущих винтов как дополнительного источника навигационной информации.

2.7.1 Вывод раздела

Физический анализ, статистическая оценка с помощью коэффициента корреляции Пирсона и обзор современной литературы однозначно свидетельствуют о высокой информационной ценности телеметрии оборотов несущих винтов. Этот сигнал является доступным на борту без дополнительного оборудования, линейно независимым от БИНС и особенно информативным именно в режиме компенсации порывов ветра. Он обеспечивает повышенный контраст обучающего сигнала для физического регуляризатора потерь и позволяет эффективно адаптировать модель к новому динамическому режиму при ограниченном объёме дообучающих данных.

Именно это обоснование определяет архитектуру физически информированной нейросетевой системы, разрабатываемой в следующей главе.

Глава 3. Разработка методики обучения и дообучения физически информированной нейросетевой системы

3.1 Общая архитектура рассматриваемых нейронных сетей

В данной работе рассматриваются следующие нейронные сети:

1. Предлагаемая в данной работе **физически информированная** нейронная сеть на основе последовательностей с селективными пространствами состояний с динамическим функционалом потерь. Динамический функционал основывается на законе тяги несущих винтов. Кратко обозначим как **ФИ НС-ПСПС**.
2. Нейронная сеть на основе последовательностей с селективными пространствами состояний, учитывающая динамические ограничения платформы по внутренним состояниям системы, без учёта оборотов двигателей, ранее предложенная авторами в работе [47]. Кратко обозначим как **ДИ НС-ПСПС**.
3. Нейронная сеть на основе последовательностей с селективными пространствами состояний с базовым функционалом потерь $\mathcal{L}_{traj}$, содержащим только целевую ошибку по траектории; блок физических ограничений отсутствует. Кратко обозначим как **НС-ПСПС**. Кратко обозначим как **базовая нейронная сеть**.
4. Нейронная сеть на основе механизма внимания, включённая в сравнение как представитель альтернативного класса архитектур. В работе обозначается как **Transformer**.

Обобщённая схема всех четырёх архитектур представлена на рисунке 3.1. На схеме показаны входной вектор, ядро, выходной вектор и функционал потерь для каждой из моделей. Ключевые различия состоят в следующем. Transformer использует ядро на основе механизма внимания и не включает физических ограничений. Базовая нейронная сеть использует ядро Mamba и базовый функционал $\mathcal{L}_{traj}$, который является общей частью всех трёх НС на основе пространственно-временной модели состояния. Обобщённая нейронная сеть дополняет базовый функционал регуляризатором по внутренним состояниям системы, не зависящим от оборотов. Предлагаемая нейронная сеть дополнительно принимает на вход те-




Рисунок 3.1 — Сравнение архитектур четырёх рассматриваемых нейронных сетей. Предлагаемая нейронная сеть выделена рамкой.

леметрию оборотов n_t и включает физический регуляризатор, явно основанный на законе тяги (??), вычисляемый непосредственно из n_i .

3.1.1 Анализ вычислительной сложности

Вычислительная сложность разработанной модели ФИ НС-ПСПС на этапе инференса практически идентична базовой НС-ПСПС. Разница в количестве параметров и операций составляет менее 0,3 % и обусловлена исключительно одной дополнительной линейной проекцией `fc_torque_inter` (192→4). Все три ПСПС-модели имеют линейную сложность по длине последовательности $O(N)$, что позволяет эффективно обрабатывать длинные интервалы потери сигнала ГНСС (до 240 с) непосредственно на бортовых вычислителях с ограниченными ресурсами.

В отличие от них, модель TransformerEncoder содержит примерно в 2,9 раза больше параметров и обладает квадратичной вычислительной сложностью $O(L^2)$ из-за механизма само-внимания. При длине последовательности, соответствующей outage 120–240 с, это приводит к резкому росту требований к памяти и времени инференса, что делает TransformerEncoder малоприменимым для бортового применения в задачах длительного восстановления траектории.

Таблица 3 — Сравнительный анализ вычислительной сложности моделей на этапе инференса

Модель	Параметры (обучаемые)	Размер (float32) МБ	Размер (INT8) (оценка), МБ	Сложность по длине seq.
НС-ПСПС	720 000	2,88	0,72	$O(L)$
ДИ НС-ПСПС	721 000	2,88	0,72	$O(L)$
ФИ НС-ПСПС	722 500	2,89	0,73	$O(L)$
TransformerEncoder	2 074 000	7,91	1,98	$O(L^2)$

3.2 Обоснование применимости телеметрии оборотов несущих винтов как дополнительного источника навигационной информации

Задача восстановления траектории квадрокоптера при кратковременных потерях сигнала ГНСС требует максимально полного использования всех доступных бортовых сигналов. Как было показано в разделах ?? бортовая инерциальная навигационная система (БИНС) в режиме компенсации порывов ветра существенно теряет информативность. В настоящем разделе приводится многоуровневое обоснование того, почему телеметрия оборотов несущих винтов представляет собой ценный, физически обоснованный и статистически независимый источник информации, который существенно усиливает физически информированные нейронные сети.

3.2.1 Физическое обоснование

Из уравнений динамики твёрдого тела (2.4)–(2.5) и модели сил несущих винтов следует, что в режиме компенсации порывов ветра автопилот поддерживает суммарную вертикальную тягу близкой к весу аппарата ($F_z \approx mg$), одновременно быстро перераспределяя обороты между роторами для создания управляющих моментов. Дифференциальные изменения тяги при этом взаимно компенсируются в суммарном сигнале акселерометра, а угловые возмущения оказываются слабо различимы гироскопом на фоне шума. В результате БИНС получает лишь интегральную картину воздействий.

Телеметрия оборотов несущих винтов, напротив, напрямую отражает индивидуальную тягу каждого ротора по закону $F_i = k_t \omega_i^2$. Это позволяет вычислить суммарную силу и моменты и сформировать физический остаток второго закона Ньютона:

$$\epsilon_F = m\hat{\mathbf{a}} - \mathbf{F}_{\text{net}}(n_i, \hat{\mathbf{v}}), \quad (3.1)$$

который может использоваться в качестве supervision-сигнала в функции потерь нейронной сети без необходимости ground truth позиции.

3.2.2 Статистическое обоснование

Из уравнений (??)–(2.4) следует ключевое наблюдение, лежащее в основе предлагаемого подхода. При компенсации порывов ветра квадрокоптер поддерживает суммарную тягу вблизи $F_z \approx mg$, одновременно производя быстрые асимметричные изменения оборотов отдельных роторов для формирования управляющих моментов [48]. Акселерометр измеряет суммарное ускорение платформы $\mathbf{a} = \mathbf{a}_{\text{упр}} + \mathbf{g}$, а гироскоп регистрирует угловую скорость корпуса $\boldsymbol{\omega}$. Однако дифференциальные изменения тяги роторов компенсируют друг друга, а быстрые симметричные перераспределения тяги порождают угловые возмущения, слабо различимые гироскопом на фоне шума при кратковременных порывах. Таким образом, оба канала БИНС располагают лишь интегральной картиной воздействий и не позволяют восстановить индивидуальный вклад каждого ротора. Сигнал оборотов несущих винтов, напротив, непосредственно отражает индивидуальную тягу F_i по закону (??) и позволяет вычислить управляющие моменты по уравнению (??) [49]. Следовательно, в режиме компенсации порывов ветра сигнал оборотов несущих винтов обладает информацией об управляющих воздействиях, которая принципиально недоступна ни акселерометру, ни гироскопу БИНС. Из этого непосредственно следует, что включение телеметрии оборотов в качестве входного сигнала нейронной сети и в качестве основы для физического регуляризатора потерь способно повысить точность восстановления траектории именно в режиме высокой динамики, то есть там, где задача дообучения на малых данных наиболее сложна [50].

Для количественной оценки линейной независимости сигналов БИНС и оборотов используется коэффициент корреляции Пирсона r [51]:

$$r(X, Y) = \frac{\sum_t (X_t - \bar{X})(Y_t - \bar{Y})}{\sqrt{\sum_t (X_t - \bar{X})^2} \sqrt{\sum_t (Y_t - \bar{Y})^2}}. \quad (3.2)$$

В качестве X последовательно рассматриваются шесть каналов БИНС ($a_x, a_y, a_z, \omega_x, \omega_y, \omega_z$), в качестве Y — дифференциальные обороты $\Delta n_{13} = n_1 - n_3$ и $\Delta n_{24} = n_2 - n_4$, которые непосредственно связаны с управляющими моментами по уравнению (??). Низкое значение $|r|$ при одновременно высокой дисперсии Δn_{ij} свидетельствует о том, что сигнал оборотов несёт информацию, линейно независимую от БИНС, и является самостоятельным источником навигационных данных.

Для иллюстрации указанного эффекта проведён сравнительный анализ двух характерных участков полёта продолжительностью 10 с каждый, полученных в симуляторе PX4/Gazebo. Выбранные участки представляют два крайних состояния динамического диапазона платформы: спокойный режим и режим компенсации порывов ветра. Все промежуточные режимы эксплуатации лежат в пределах диапазона, образованного этими двумя состояниями, поэтому сопоставление именно данной пары участков обеспечивает оценку максимально возможного контраста информативности сигналов. Сигналы и корреляционные матрицы обоих режимов представлены на рисунке 3.2, количественные характеристики сведены в таблицу 4.

Таблица 4 — Сравнение спокойного режима и режима компенсации порывов ветра

Показатель	Режим	
	Спокойный	Компенсация порывов ветра
$\sigma(\Delta n_{13})$, об/мин	16	909
$\sigma(a_z)$, м/с ²	0,212	0,197
$\sigma(F_z)$, Н	1,46	0,581
Ср. $ r $ (БИНС, Δn)	0,08	0,24

Анализ таблицы 4 позволяет сформулировать три вывода, непосредственно определяющих идею предлагаемого метода.

Во-первых, дисперсия вертикального ускорения БИНС $\sigma(a_z)$ практически одинакова в обоих режимах (0,212 против 0,197 м/с²): суммарная тяга остаётся вблизи mg , и БИНС не фиксирует дифференциальных изменений тяги между роторами, что соответствует теоретическому выводу из уравнения (2.4). Во-вторых,

**Спокойный vs режим компенсации порывов ветра:
9 каналов БИНС · обороты · корреляция**




Рисунок 3.2 — Сравнение спокойного режима и режима компенсации порывов ветра: 9 каналов БИНС, обороты несущих винтов и корреляция между ними.

дисперсия оборотов $\sigma(\Delta n_{13})$ возрастает в режиме компенсации порывов ветра в 57 раз. Согласно закону (??), это показывает значительную временную изменчивость управляющих сил и моментов, недоступную БИНС. Именно эта изменчивость порождает повышенный контраст обучающего сигнала при дообучении нейронной сети с динамическим функционалом потерь. В третьих, средний $|r|$ в режиме компенсации порывов ветра составляет лишь 0,24, то есть остаётся низким, несмотря на 57-кратный рост дисперсии оборотов. Это означает, что в агрессивном режиме сигнал оборотов несёт принципиально новую, линейно независимую от БИНС информацию об управляющих воздействиях. Следовательно, регуляризатор на основе телеметрии оборотов не дублирует информацию, уже содержащуюся в данных БИНС, а добавляет независимый физически обоснованный надзорный сигнал именно в тех условиях, где переобучение на малых данных наиболее вероятно.

3.2.3 Обзор релевантной литературы

Дополнительное обоснование дают современные исследования гибридного моделирования и оценки состояния.

Работа NeuroBEM [32] представляет гибридную аэродинамическую модель квадрокоптера, сочетающую теорию элемента лопасти (BEM) с нейросетевыми коррекциями. Авторы показывают, что зависимость коэффициентов тяги и момента от относительной скорости набегающего потока делает простую квадратичную модель недостаточной в динамических режимах и при ветровых возмущениях. Измерения оборотов винтов (или команд актуаторов) позволяют значительно точнее оценивать текущие силы и моменты, что напрямую улучшает качество оценки состояния и снижает дрейф.

В исследовании actuator-informed моделей оценки состояния [33] продемонстрировано, что включение телеметрии оборотов и моментов двигателей в гибридную архитектуру позволяет существенно снизить ошибку инерциальной оценки в условиях внешних возмущений и неопределённости параметров платформы. Авторы отмечают, что сигналы актуаторов обеспечивают дополнительный физический supervision, особенно эффективный при смене динамического режима.

Статья [34] посвящена применению последовательностных моделей с селективными пространствами состояний для задач инерциальной навигации с использованием сигналов актуаторов. Показано, что actuator-informed подходы обеспечивают лучшее обобщение при ограниченном объёме данных и при дообучении на новых сценариях — именно та ситуация, которая возникает при адаптации модели к новому промышленному объекту.

Реальный датасет AI-IO [44] содержит синхронизированные записи IMU и измерений оборотов роторов, полученные на реальном квадрокоптере. Авторы экспериментально подтверждают, что наличие RPM-сигнала позволяет значительно повысить точность одометрии и оценки состояния по сравнению с чисто IMU-based методами в реальных условиях эксплуатации, включая режимы с ветровыми возмущениями.

Наконец, работа по hybrid aerodynamic wind-aware моделям [52] убедительно показывает, что учёт телеметрии актуаторов критически важен для точной компенсации ветровых возмущений и поддержания физической согласованности модели при резких манёврах. Авторы подчёркивают, что без сигналов оборотов винтов гибридные модели теряют значительную часть своей регуляризационной способности в агрессивных режимах.

3.3 Предлагаемая нейронная сеть

На основании проведённого анализа установлено, что сигнал оборотов несущих винтов несёт информацию об управляющих воздействиях, недоступную БИНС в режиме компенсации порывов ветра, и обеспечивает повышенный контраст обучающего сигнала при дообучении на малых данных именно в агрессивном динамическом режиме.

Архитектура предлагаемой нейронной сети состоит из следующих блоков: входной вектор признаков, кодировщик на основе пространственно-временной модели состояния (блок линейной проекции, входной блок линейной нормализации, 3 слоя пространственно-временной модели [41], выходной блок линейной нормализации), выходной вектор признаков.

Входной вектор $\mathbf{x}_t \in \mathbb{R}^{17}$ на каждом временном шаге t определяется следующим набором данных:

$$\mathbf{x}_t = [\mathbf{a}_t, \boldsymbol{\omega}_t, \boldsymbol{\Phi}_t, \mathbf{p}_t^{gps}, \mathbf{n}_t, m_t], \quad (3.3)$$

где $\mathbf{a}_t = [a_x, a_y, a_z]^T$ — линейное ускорение БИНС; $\boldsymbol{\omega}_t = [\omega_x, \omega_y, \omega_z]^T$ — угловая скорость; $\boldsymbol{\Phi}_t = [\varphi, \theta, \psi]^T$ — углы ориентации; $\mathbf{p}_t^{gps}$ — псевдопозиция ГНСС (при потере сигнала обнуляется); $\mathbf{n}_t = [n_1, n_2, n_3, n_4]^T$ — обороты четырёх роторов; $m_t \in \{0, 1\}$ — маска доступности ГНСС.

Выходной вектор $\hat{\mathbf{y}}_t \in \mathbb{R}^{14}$ формируется конкатенацией четырёх групп предсказаний, извлечённых из скрытого представления $\mathbf{H}$ линейными проекциями:

$$\hat{\mathbf{y}}_t = [\hat{\mathbf{v}}_t, \hat{\mathbf{q}}_t, \hat{\mathbf{a}}_t, \boldsymbol{\tau}], \quad (3.4)$$

где $\hat{\mathbf{v}}_t \in \mathbb{R}^3$ — предсказанная линейная скорость; $\hat{\mathbf{q}}_t \in [-1, 1]^4$ — нормированный кватернион ориентации; $\hat{\mathbf{a}}_t \in \mathbb{R}^3$ — линейное ускорение в связанной системе координат; $\boldsymbol{\tau}_{int,t} \in \mathbb{R}^4$ — промежуточное представление управляющих моментов, используемое в динамическом функционале потерь.

Из скрытого представления $\mathbf{H}$ компоненты выходного вектора извлекаются посредством линейных проекций:

$$\hat{\mathbf{v}} = \mathbf{H}\mathbf{W}_v \in \mathbb{R}^{T \times 3}, \quad (3.5)$$

$$\hat{\mathbf{q}} = \frac{\mathbf{H}\mathbf{W}_q}{\|\mathbf{H}\mathbf{W}_q\|}, \quad \hat{\mathbf{q}} \in [-1, 1]^{T \times 4}, \quad (3.6)$$

$$\hat{\mathbf{a}} = \mathbf{H}\mathbf{W}_a \in \mathbb{R}^{T \times 3}, \quad (3.7)$$

$$\boldsymbol{\tau}_{int} = \mathbf{H}\mathbf{W}_\tau \in \mathbb{R}^{T \times 4}. \quad (3.8)$$

Нормировка кватерниона гарантирует принадлежность многообразию S^3 .

Ключевое отличие предлагаемой нейронной сети от остальных моделей заключается в функции потерь, связывающей предсказания модели с законами динамики квадрокоптера.

Итоговая функция потерь:

$$\mathcal{L}_{DF} = \lambda_1 \mathcal{L}_{traj} + \lambda_2 \left\| \frac{\boldsymbol{\varepsilon}_F}{mg} \right\|^2 + \lambda_3 \left\| \frac{\boldsymbol{\varepsilon}_\tau}{\sigma_\tau} \right\|^2, \quad (3.9)$$

где $\|\cdot\|^2$ обозначает среднеквадратическую ошибку по компонентам вектора; mg — нормировочный множитель, приводящий невязку тяги к безразмерному

виду; σ_τ — стандартное отклонение момента на текущем батче. Весовые коэффициенты $\lambda_1 = 1,0$, $\lambda_2 = \lambda_3 = 3 \times 10^{-4}$ подобраны на валидационной выборке датасета А из условия соизмеримости слагаемых: физические штрафные члены вносят регуляризующий вклад, не подавляя основной траекторный сигнал на начальных эпохах обучения. Базовая нейронная сеть использует только $\mathcal{L}_{traj}$ (то есть $\lambda_2 = \lambda_3 = 0$); обобщённая нейронная сеть включает регуляризатор без прямой зависимости от n_i .

При высокой дисперсии n_i значение $F_z(t)$ значительно изменяется во времени, а штрафные слагаемые $\|\varepsilon_F\|^2$ и $\|\varepsilon_\tau\|^2$ создают повышенный контраст обучающего сигнала при дообучении, ограничивая пространство допустимых весов модели именно в тех режимах, где переобучение на малых данных наиболее вероятно.

Траекторная составляющая функции потерь $\mathcal{L}_{traj}$ включает три слагаемых:

$$\mathcal{L}_{traj} = \underbrace{\|\hat{\mathbf{v}} - \mathbf{v}\|^2}_{\text{ошибка скорости}} + 0,5 \underbrace{\mathcal{L}_q(\hat{q}, q)}_{\text{ошибка ориентации}} + \lambda_{pos} \underbrace{\|\hat{p} - p\|^2}_{\text{ошибка позиции}}, \quad (3.10)$$

где $\hat{\mathbf{v}}, \mathbf{v}$ — предсказанная и истинная скорость; $\hat{q}, q$ — предсказанный и истинный кватернион ориентации; $\hat{p}, p$ — предсказанная и истинная траектория, восстановленная интегрированием скорости методом Эйлера; $\mathcal{L}_q = \|\hat{q} - q\|^2 + 0,5 (\|\hat{q}\| - 1)^2$ — функция потерь по кватерниону, включающая штраф за отклонение от единичной нормы; $\lambda_{pos} = 0,15$ — весовой коэффициент позиционного слагаемого.

Общая схема предлагаемой нейронной сети представлена на рисунке 3.3.




Рисунок 3.3 — Архитектура ФИ НС-ПСПС.

Глава 4. Экспериментальное исследование и сравнительный анализ эффективности предложенной системы

4.0.1 Введение

Настоящая глава посвящена проверке практической пригодности предложенной физически информированной нейронной сети с селективными пространствами состояний (ФИ НС-ПСПС) в условиях, близких к реальным задачам инерциальной одометрии квадрокоптера. Проводились четыре серии экспериментов:

1. Анализ вычислительных характеристик архитектуры
2. Дообучение на ограниченном объёме данных в режиме моделирования компенсации порывов ветра
3. Валидация на реальных полётных данных датасета AI-IO [53]
4. Оценка переносимости модели на платформы с существенно иной массой без какого-либо дообучения

Во всех сериях сравниваются четыре архитектуры: ФИ НС-ПСПС, ДИ НС-ПСПС, НС-ПСПС и Transformer Encoder.

4.1 Описание экспериментальных данных и протокол оценки

4.1.1 Датасеты

Для предобучения и дообучения использовались два датасета, сформированных в симуляторе PX4/Gazebo [22] на платформе Holybro X500 V2 (масса $m = 2,0$ кг).

1. **Датасет А — стандартный режим.** Полёты в спокойных условиях с ограниченными манёврами; типичный сценарий горизонтального облёта промышленного объекта. Все четыре сравниваемые модели предобуча-

лись именно на этом датасете. Общая продолжительность записей — 43 мин

2. **Датасет В — режим компенсации порывов ветра.** Полёты с резкими изменениями скорости и направления, имитирующими работу контроллера стабилизации вблизи промышленной конструкции. В этом сценарии дисперсия оборотов двигателей максимальна. Общая продолжительность записей — 8 мин 42 с.

Оба датасета содержат синхронизированные данные БИНС (200 Гц), ГНСС (5 Гц), телеметрию оборотов двигателей (200 Гц) и опорные траектории из внутреннего состояния симулятора. Ключевые статистики приведены в таблице 5.

Таблица 5 — Сравнение статистических характеристик датасетов А и В

Показатель	Датасет А	Датасет В	Отношение В/А
<i>Линейная скорость $\mathbf{v}$, м/с</i>			
среднее	1,790	2,332	1,30
станд. отклонение	0,767	2,097	2,74
p95	3,253	6,743	2,07
<i>Горизонтальное ускорение a_{xy}, м/с²</i>			
среднее	0,131	0,293	2,24
станд. отклонение	0,088	0,263	3,00
p95	0,313	0,832	2,66
<i>Угловая скорость $\boldsymbol{\omega}$, рад/с</i>			
среднее	0,321	0,292	0,91
p95	0,913	0,942	1,03
<i>Средние обороты роторов, об/мин</i>			
среднее	14 545	11 566	0,80
станд. отклонение	990	5971	6,03
p95	16 150	15 265	0,95

Данные таблицы 5 позволяют выделить несколько существенных закономерностей. Средняя скорость в датасете В выше лишь на 30 %, горизонтальное ускорение по 95-му перцентилю — в 2,7 раза, а угловые скорости практически совпадают (отношение 0,91–1,03). Это означает, что режим компенсации порывов ветра не сводится к простому увеличению скорости полёта. Куда показательнее картина с оборотами роторов: стандартное отклонение в датасете В превышает таковое в датасете А в **6,0 раза** (5971 против 990 об/мин), причём среднее значение оборотов при этом ниже. Объяснение следующее: при ветровых возмущениях квадрокоптер поддерживает заданное положение за счёт быстрых асимметричных изменений тяги отдельных роторов при практически неизменной суммарной

тяге ($F_z \approx mg$). БИНС измеряет лишь суммарное специфическое ускорение и не различает дифференциальные изменения тяги, тогда как телеметрия оборотов фиксирует их напрямую — что делает эти два источника информации взаимодополняющими.

4.1.2 Метрики оценки и протокол

В качестве основных метрик используются среднеквадратическая ошибка (СКО)?? и абсолютная ошибка траектории (АОТ)??

Для каждого лога выбиралось 10 случайных начальных позиций; предсказанные скорости интегрировались методом Рунге–Кутты четвёртого порядка с двунаправленным сглаживанием. Рассматривались следующие длительности потери сигнала ГНСС: 3, 10, 30, 60, 120 и 240 с.

4.1.3 Сравнимые платформы для эксперимента по кросс-платформенному обобщению

На базе модели X500 V2 были созданы две дополнительные виртуальные платформы путём изменения исключительно инерционных параметров при неизменных характеристиках моторов и датчиков. Такой подход позволяет изолировать влияние массы и инерции на точность одометрии. Полный перечень параметров приведён в таблице 6.

Лёгкая платформа (1,0 кг) соответствует компактным исследовательским квадрокоптерам класса 250–330 мм. Тяжёлая (3,5 кг) имитирует аппарат с полезной нагрузкой около 1,5 кг — это типичная конфигурация промышленного мониторинга с лидаром или тепловизором.

Таблица 6 — Физические и имитационные параметры экспериментальных платформ. Параметры, отличающиеся от базовой, выделены жирным шрифтом. Разрыв платформы $\Delta = m/m_{\text{base}}$.

Параметр	Ед. изм.	Базовая	Лёгкая	Тяжёлая
<i>Физические параметры</i>				
Масса рамы m	кг	2,0	1,0	3,5
Момент инерции $I_{xx} = I_{yy}$	кг·м ²	0,02167	0,00683	0,05507
Момент инерции I_{zz}	кг·м ²	0,04000	0,01260	0,10165
Длина плеча l	м	0,174	0,138	0,210
<i>Параметры силовой установки</i>				
Коэффициент тяги k_T	Н/(рад/с) ²	$8,549 \times 10^{-6}$	$8,549 \times 10^{-6}$	$1,188 \times 10^{-5}$
Коэффициент сопротивления k_D	Н·м/(рад/с) ²	$1,368 \times 10^{-7}$	$1,368 \times 10^{-7}$	$1,901 \times 10^{-7}$
Постоянная времени набора оборотов $\tau_{\uparrow}$	с	0,0125	0,0088	0,0165
<i>Производные характеристики</i>				
Коэффициент массы Δ	—	1,0×	0,5×	1,75×
Обороты роторов на висении ω_h	рад/с	757	535	850
Отношение тяги к весу T/W	—	1,74	3,48	1,37

4.2 Вычислительные характеристики архитектуры ФИ НС-ПСПС

Как было сказано выше в разделе 4.0.1 первым экспериментом является оценка времени восстановления траектории для нейросетей на основе селективных пространств состояний. В данном разделе в качестве основной архитектуры используется базовая нейронная сеть НС-ПСПС.

используется Прежде чем переходить к результатам по точности, стоит разобраться, насколько предложенная архитектура пригодна для бортового применения в режиме реального времени. Запаздывание предсказания траектории напрямую влияет на своевременность решения об инициировании манёвра возврата, поэтому вычислительная эффективность — не менее важный критерий, чем точность.

4.2.1 Сравнение архитектур по теоретической сложности

Как было показано ранее в таблице 3 модель ФИ НС-ПСПС обладает схожим количеством параметров и операций что и базовая НС-ПСПС. Таким образом для сравнения времени инференса рассматриваемых в данной работе моделей на основе селективных пространств состояний (ПСПС) с моделями на основе самовнимания (Transformer) и долгой краткосрочной памяти (LSTM) достаточно использовать только базовую НС-ПСПС из симейства ПСПС.

4.2.2 Результаты обучения

Обучение проводилось на ускорителе Tesla T4 с оптимизатором Adam, функцией потерь MSE и размером батча 32; применялась ранняя остановка после трёх эпох без улучшения валидационной потери.

1. **Transformer:** 6 эпох; потеря снизилась с 0,4202 до 0,3923; время эпохи — 7 мин 39 с; лучшая валидационная потеря — 0,4015.
2. **Bi-LSTM:** 8 эпох; потеря снизилась с 0,5001 до 0,3900; время эпохи — 3 мин 34 с; лучшая валидационная потеря — 0,3918.
3. **НС-ПСПС:** 8 эпох; потеря снизилась с 0,5344 до 0,4103; время эпохи — 2 мин 05 с; лучшая валидационная потеря — 0,4071.

По скорости обучения НС-ПСПС заметно выигрывает: одна эпоха занимает в 1,7 раза меньше времени, чем у Bi-LSTM, и в 3,7 раза меньше, чем у Transformer.

4.2.3 Время предсказания траектории

В таблице 7 приведены средние значения СКО, АОТ и времени инференса для длительностей потери 3–120 с.

На сегменте 120 с НС-ПСПС затрачивает 0,0046 с, тогда как Transformer — 0,6359 с, то есть в 138 раз больше; Bi-LSTM — 0,3682 с, то есть в 80 раз больше. Разрыв нарастает с увеличением длительности потери сигнала — что прямо

Таблица 7 — СКО (м), АОТ (м) и время инференса $t_{\text{инф}}$ (с) для НС-ПСПС, Transformer и Bi-LSTM

Время, с	Метрика	НС-ПСПС	Transformer	Bi-LSTM
3	СКО	0,1492	0,1517	0,0620
	АОТ	0,2370	0,2421	0,1002
	$t_{\text{инф}}$, с	0,0006	0,0016	0,0160
10	СКО	0,5528	0,5891	0,1652
	АОТ	0,8781	0,9439	0,2746
	$t_{\text{инф}}$, с	0,0009	0,0072	0,0504
30	СКО	3,8960	4,2144	2,8745
	АОТ	6,1319	7,1373	4,6349
	$t_{\text{инф}}$, с	0,0047	0,7618	0,3680
60	СКО	3,9014	4,2200	2,8708
	АОТ	6,1375	7,1483	4,6366
	$t_{\text{инф}}$, с	0,0046	0,6377	0,3695
120	СКО	3,8951	4,2153	2,8739
	АОТ	6,1300	7,1387	4,6345
	$t_{\text{инф}}$, с	0,0046	0,6359	0,3682

вытекает из линейной и квадратичной зависимости вычислительной сложности от длины последовательности.

Рисунок 4.1 иллюстрирует эту зависимость.

Сокращение времени инференса имеет прямое прикладное значение: более быстрое предсказание траектории позволяет контроллеру оперативнее инициировать манёвр возврата в зону устойчивого приёма ГНСС, что увеличивает площадь покрытия при картографировании на одном заряде аккумулятора.

По точности НС-ПСПС при коротких потерях (3–10 с) несколько уступает Bi-LSTM, но при длительных потерях (30–120 с) все три архитектуры сходятся по значениям СКО и АОТ (расхождение не превышает 7 %).




Рисунок 4.1 — Сравнение предложенной архитектуры HC ПСПС, Transformer и LSTM по метрикам RMSE, ATE и времени инференса при разных временах потери сигнала.

4.3 Дообучение на ограниченном объёме данных

4.3.1 Протокол дообучения

Из датасета В методом случайной выборки формировались подмножества долей 10, 25, 50, 75 и 100 %. Число шагов оптимизации было зафиксировано на уровне 2000 для всех долей — это устраняет влияние числа итераций на сравнение и обеспечивает единые условия дообучения. Оценка проводилась на 10 случайных сегментах датасета В без выравнивания систем координат. В совокупности набор результатов составляет 4 модели $\times$ 5 долей $\times$ 6 длительностей потери = 120 значений СКО.

4.3.2 Результаты при потере сигнала 60 с

Начнём с относительно комфортного сценария — потеря на 60 с (таблица 8). Здесь накопленная ошибка БИНС ещё не достигает критических значений, поэтому все модели демонстрируют сравнительно приемлемые результаты. Тем не менее ФИ НС-ПСПС стабильно превосходит базовую нейронную сеть при каждой из пяти долей.

Таблица 8 — СКО (м) при дообучении на подмножествах, потеря сигнала ГНСС 60 с

Доля, %	ФИ НС-ПСПС	НС-ПСПС	НС-ПСПС	Transformer
10	1,973	2,163	2,985	5,800
25	2,232	2,031	3,085	6,797
50	2,017	1,739	3,477	7,488
75	3,029	2,457	3,454	8,737
100	3,647	3,777	6,994	5,657

4.3.3 Результаты при потере сигнала 240 с

Гораздо интереснее результаты при 240 с — наиболее тяжёлом сценарии (таблица 9). При такой длительности ошибка БИНС нарастает до десятков метров, и различия в регуляризующих свойствах моделей выступают наиболее явно. Transformer в этих условиях показывает стабильно высокую ошибку: квадратичная сложность механизма внимания даёт о себе знать при обработке длинных навигационных последовательностей.

Таблица 9 — СКО (м) при дообучении на подмножествах, потеря сигнала ГНСС 240 с

Доля, %	ФИ НС-ПСПС	ДИ НС-ПСПС	НС-ПСПС	Transformer
10	14,273	19,985	36,458	22,315
25	9,409	8,173	13,016	20,267
50	10,594	13,412	21,823	19,593
75	15,069	20,264	32,100	20,963
100	9,734	11,149	16,978	20,481

На минимальном объёме данных (10 %, ≈ 40 с полёта) ФИ НС-ПСПС достигает СКО = 14,3 м, что лучше базовой нейронной сети, обученной на *полном* датасете (17,0 м). Физический регуляризатор компенсирует нехватку объёма обучающих данных за счёт повышенного контраста сигнала там, где БИНС теряет избирательность.

Лучший результат ФИ НС-ПСПС — СКО = 9,4 м — достигается при доле 25 %, что соответствует примерно 2 мин калибровочного полёта перед миссией. При 100 % данных результат составляет 9,7 м: удвоение объёма данных даёт прирост точности менее 3 %.

4.3.4 Сводная таблица

Таблица 10 содержит полную сводку результатов ФИ НС-ПСПС по всем сочетаниям доли дообучающего датасета и длительности потери сигнала. Она может использоваться как операционная рекомендация при планировании калибровочных полётов в новых динамических условиях.

Таблица 10 — СКО (м) ФИ НС-ПСПС по всем длинам потери сигнала и долям датасета

Доля датасета, %	Длительность потери сигнала ГНСС, с					
	3	10	30	60	120	240
10	0,141	0,511	1,722	1,973	6,723	14,273
25	0,133	0,785	2,463	2,232	7,264	9,409
50	0,124	0,731	1,764	2,017	6,689	10,594
75	0,095	0,690	2,150	3,029	5,505	15,069
100	0,104	0,571	1,936	3,647	9,458	9,734

При коротких потерях (3–30 с) СКО не превышает 2,5 м при любой доле данных. При длительных потерях (120–240 с) оптимальная точность достигается при доле 25–50 %, что соответствует 2–4 мин калибровочных полётов.

4.3.5 Визуализация и анализ




Рисунок 4.2 — СКО (м) четырёх моделей в зависимости от доли обучающих данных при потере сигнала ГНСС 240 с. Ось X : доля (%); ось Y : СКО (м). Столбцы: ФИ НС-ПСПС (синий), обобщённая НС-ПСПС (зелёный), базовая НС-ПСПС (красный), Transformer (оранжевый).

Figure 4. RMSE (m) vs. training data fraction, GNSS outage 240 s.

При потере сигнала 240 с ФИ НС-ПСПС превосходит базовую модель при всех долях (рисунок 4.2). Базовая нейронная сеть демонстрирует немонотонную зависимость СКО от объёма данных: $36,5 \rightarrow 13,0 \rightarrow 21,8 \rightarrow 32,1 \rightarrow 17,0$ м, что типично для переобучения при малых долях с последующей нестабильностью при средних значениях. У ФИ НС-ПСПС зависимость заметно устойчивее: $14,3 \rightarrow 9,4 \rightarrow 10,6 \rightarrow 15,1 \rightarrow 9,7$ м.

Примечательно поведение обобщённой НС-ПСПС при доле 25 %: она незначительно опережает ФИ НС-ПСПС (8,2 против 9,4 м). При этом конкретном объёме данных косвенный регуляризатор несколько менее подвержен переобучению, чем более специфичный динамический функционал. При минимальном объёме (10 %) и полном датасете (100 %) ФИ НС-ПСПС возвращает лидерство.

Ключевой вывод по физической интерпретации: преимущество ФИ НС-ПСПС определяется не кинематическими различиями датасетов, а динамикой сигнала оборотов двигателей. Шестикратный рост стандартного отклонения оборотов в датасете В создаёт высококонтрастный обучающий сигнал по слагаемым $\|\varepsilon_F\|^2$ и $\|\varepsilon_\tau\|^2$ в функционале (3.9), что ограничивает пространство допустимых весов и препятствует переобучению при малых объёмах траекторных данных.

4.4 Валидация на реальном датасете AI-IO

Предыдущие эксперименты проводились в симуляторе PX4/Gazebo, который не воспроизводит в полной мере нестационарное смещение реальных МЭМС-датчиков и аэродинамические эффекты вблизи конструкций. Чтобы убедиться, что полученные результаты не являются артефактами симуляции, была проведена дополнительная серия экспериментов на открытом датасете реальных полётных данных AI-IO (Aerodynamics-Inspired Inertial Odometry) [53].

4.4.1 Описание датасета AI-IO

AI-IO[54] — публичный датасет реальных полётов квадрокоптера, сформированный специально для задачи инерциальной одометрии с учётом аэродинами-

ки несущих винтов. В состав записей входят данные IMU, обороты двигателей, показания барометра и опорные траектории из системы захвата движения. Наличие телеметрии оборотов двигателей делает этот датасет наиболее подходящим для проверки именно ФИ НС-ПСПС.

Дообучение на реальных данных AI-IO служит также косвенным подтверждением адекватности используемой модели тяги: если бы модель не отражала реальную физику платформы, физический регуляризатор не обеспечивал бы систематического улучшения. Этот аргумент дополняет общепринятую экспериментальную верификацию модели тяги для мультироторных платформ, имеющуюся в литературе [22].

4.4.2 Результаты

В таблице 11 приведены значения СКО для трёх моделей при потере сигнала 10, 30 и 60 с.

Таблица 11 — СКО (м) восстановления траектории на реальном датасете AI-IO при различных длительностях потери сигнала ГНСС

Длит. потери, с	ФИ НС-ПСПС	ДИ НС-ПСПС	НС-ПСПС
10	0,995	0,905	1,050
30	1,996	2,086	2,007
60	2,879	3,163	3,321

ФИ НС-ПСПС устойчиво превосходит базовую модель при всех трёх длительностях. При потере 60 с разрыв наиболее заметен: 2,879 м против 3,321 м у базовой — ФИ НС-ПСПС ошибается на 13 % меньше.

При коротких потерях (10 с) обобщённая НС-ПСПС несколько точнее (0,905 м против 0,995 м) — это согласуется с наблюдением о поведении косвенного регуляризатора при небольших объёмах данных. С увеличением длительности потери до 30 и 60 с ФИ НС-ПСПС выходит вперёд. Сравнение трёх моделей приведено на рисунке 4.3.

Таким образом, улучшение точности прослеживается не только в симуляции, но и на реальных данных. Это подтверждает, что физический регуляризатор на основе телеметрии оборотов несущих винтов отражает реальную физику




Рисунок 4.3 — СКО (м) трёх моделей на реальном датасете AI-Ю при потере сигнала ГНСС 10, 30 и 60 с.

платформы — иначе систематического улучшения на реальных данных не наблюдалось бы.

4.5 Кросс-платформенное обобщение без дообучения

До сих пор все эксперименты проводились на одной платформе. Для реального применения, однако, принципиально важно знать, сохранит ли модель приемлемую точность при переносе на квадрокоптер иной конфигурации — без полного переобучения с нуля. Большинство чисто data-driven методов при таком переносе теряют в точности, поскольку фактически запоминают статистику шумов и динамики конкретного аппарата.

Гипотеза настоящего раздела состоит в следующем: нейросетевая часть ФИ НС-ПСПС в первую очередь выучивает отображение, определяемое инвариантной физической структурой динамики квадрокоптера, а влияние массы поглощается через наблюдаемые сигналы оборотов роторов. Для проверки этой гипотезы предобученная модель оценивалась на трёх платформах с диапазоном масс 3,5 раза при трёх профилях полёта — без какой-либо адаптации весов нейронной сети.

4.5.1 Описание эксперимента

Единственная разрешённая адаптация при смене платформы — подстановка соответствующих физических параметров (масса, коэффициент тяги, длина плеча) в буферы модели перед оценкой. Для каждого лога выбиралось 10 случайных начальных позиций.

Объёмы сформированных датасетов приведены в таблице 12.

Таблица 12 — Объёмы датасетов после предобработки

Платформа	Спокойный	Умеренный	Агрессивный	Итого
Базовая	43 536	52 693	79 738	175 967
Лёгкая	43 819	53 138	80 479	177 436
Тяжёлая	43 222	51 960	79 039	174 221
Всего	130 577	157 791	239 256	527 624

4.5.2 Результаты

Полные значения СКО для всех сочетаний платформы, профиля и длительности приведены в таблице 13.

При спокойном профиле разброс СКО между платформами оказался исключительно малым (таблица 14). При потере сигнала 60 с он составляет всего 0,394 м — менее 13 % относительно среднего значения. Для диапазона масс 3,5 раза это весьма убедительный результат.

4.5.3 Обсуждение результатов

Обобщение без дообучения при спокойных траекториях работает на удивление хорошо. Разброс СКО 0,394 м при 60 с напрямую подтверждает гипотезу о платформенной инвариантности физического ограничения на основе оборотов роторов.

Таблица 13 — СКО (м) для всех комбинаций платформа–профиль и длительностей перерывов ГНСС. Обобщение без дообучения. Лучшее значение в каждом столбце подчёркнуто.

Платформа	Профиль	3 с	5 с	10 с	30 с	60 с	120 с
Базовая	спокойный	<u>0,194</u>	0,401	1,081	2,483	3,083	3,885
	умеренный	<u>0,457</u>	0,890	1,613	3,661	5,940	7,400
	агрессивный	0,423	0,921	1,722	6,183	10,606	12,723
Лёгкая	спокойный	0,190	0,429	<u>0,939</u>	<u>2,198</u>	3,373	4,478
	умеренный	0,471	0,732	1,983	3,293	6,271	7,830
	агрессивный	0,576	1,407	2,442	6,466	8,527	12,460
Тяжёлая	спокойный	0,214	0,494	1,072	2,288	<u>2,979</u>	<u>4,303</u>
	умеренный	<u>0,394</u>	<u>0,752</u>	1,860	<u>3,308</u>	<u>4,859</u>	<u>7,122</u>
	агрессивный	<u>0,321</u>	<u>0,918</u>	2,967	6,315	10,331	13,602

Таблица 14 — СКО (м) при спокойном профиле полёта. Разброс (максимум минус минимум) не превышает 0,5 м при перерыве до 60 с.

Длительность	Базовая	Лёгкая	Тяжёлая	Разброс
3 с	0,194	0,190	0,214	0,024
5 с	0,401	0,429	0,494	0,093
10 с	1,081	0,939	1,072	0,142
30 с	2,483	2,198	2,288	0,285
60 с	3,083	3,373	2,979	0,394
120 с	3,885	4,478	4,303	0,593

Зависимость СКО от массы робота — разделенная по характеру движения




Рисунок 4.4 — Зависимость СКО от массы робота, разбивка по профилю полёта




Рисунок 4.5 — Зависимость СКО от массы робота, разбивка по длительности потери ГНСС




Рисунок 4.6 — Зависимость СКО от длительности потери сигнала ГНСС

При этом ряд наблюдений оказался неочевидным. Тяжёлая платформа (3,5 кг) при умеренном профиле и потере 60 с показывает СКО = 4,859 м против 5,940 м у базовой — на 18 % точнее. Причин здесь, по всей видимости, две. Большая инерция сглаживает изменения скорости даже при резких командах управления, что упрощает задачу интегрирования. Вдобавок обороты роторов на висении у тяжёлой платформы выше (около 850 рад/с против 757 рад/с), и это формирует более сильный сигнал для вычисления физического остатка.

Несколько неожиданным оказался результат базовой платформы при агрессивном профиле: отношение СКО при 60 с к СКО при 10 с составило 6,16 — против 3,48–3,49 у лёгкой и тяжёлой. Модель, обученная именно на базовой платформе, накапливает ошибку быстрее остальных. Наиболее вероятно, что в процессе обучения она отчасти «подстроилась» под статистику базовой платформы; платформы с иной инерцией при этом порождают траектории, лучше соответствующие обобщающим свойствам архитектуры.

Что касается соотношения АОТ/СКО, оно остаётся в узком диапазоне 1,50–1,57 для всех 54 условий. Это указывает на то, что структура ошибки предсказания самоподобна и определяется преимущественно систематическим смещением в оценке скорости, а не случайным дрейфом, — что характерно для хорошо регуляризованной модели.

Агрессивность профиля полёта влияет на точность значительно сильнее, чем различия между платформами. При потере 60 с разница между спокойным и агрессивным профилями достигает множителя 3,4 на базовой платформе, тогда как разброс между платформами при фиксированном профиле не превышает 20 %. Практический вывод: при проектировании миссии выбор характера траектории важнее подбора конкретной платформы.

Следует также отметить, что попытки дообучения на новых платформах без корректировки статистик нормализации входных признаков не принесли улучшений. При «чужой» нормализации физическая составляющая функции потерь вычисляет некорректные остатки, и градиенты уводят обучение в неверную сторону. Практическое решение простое: короткий висение продолжительностью 2–3 мин с последующим пересчётом среднего и стандартного отклонения сигналов оборотов роторов под целевую платформу.

4.5.4 Выводы по разделу

По итогам эксперимента на трёх платформах при трёх профилях полёта (54 условия) можно сформулировать следующее.

1. Обобщение без дообучения является практически применимым: при потере сигнала 10 с СКО не превышает 3 м ни на одной из платформ и ни при одном из профилей.
2. При спокойных траекториях разброс СКО между платформами при 60 с составляет менее 0,4 м (менее 13 % от среднего) несмотря на 3,5-кратный диапазон масс, что подтверждает платформенную инвариантность физического ограничения.
3. Тяжёлая платформа в ряде сценариев превосходит базовую при длительных перерывах благодаря сглаживающему действию инерции и более высоким оборотам роторов на висении.
4. Агрессивность миссии влияет на точность существенно сильнее, чем масса платформы; при проектировании системы приоритет следует отдавать планированию траектории.
5. Успешный перенос модели требует предварительной калибровки нормализации под целевую платформу; для этого достаточно 2–3 мин калибровочного висения.

4.6 Выводы по главе

В четвёртой главе проведено четыре серии экспериментов, направленных на проверку практической пригодности ФИ НС-ПСПС. Ниже кратко сформулированы основные результаты.

1. По скорости инференса ФИ НС-ПСПС значительно превосходит альтернативные архитектуры: на сегменте 120 с она работает в 138 раз быстрее Transformer и в 80 раз быстрее Bi-LSTM. После квантования размер модели составляет 28 КБ — это позволяет исполнять её на нейронных ядрах микроконтроллеров STM32N6 в режиме реального времени.

2. Разработан и проверен протокол дообучения на ограниченном объёме данных. При использовании 25 % данных (около 2 мин полёта) ФИ НС-ПСПС достигает $СКО = 9,4$ м при потере сигнала 240 с — в 1,8 раза лучше базовой нейронной сети, обученной на полном датасете. Физический регуляризатор на основе закона тяги несущих винтов обеспечивает повышенный контраст обучающего сигнала именно в условиях высокой дисперсии оборотов роторов.
3. Проведена валидация на реальном датасете AI-Ю. ФИ НС-ПСПС превосходит базовую модель при всех рассмотренных длительностях потери сигнала. Систематическое улучшение на реальных данных подтверждает адекватность используемой модели тяги несущих винтов.
4. Эксперимент по кросс-платформенному обобщению без дообучения на трёх платформах (диапазон масс 3,5 раза) и трёх профилях полёта показал, что при перерывах ГНСС до 10 с $СКО$ не превышает 3 м во всех условиях. При спокойных траекториях разброс $СКО$ между платформами при 60 с составляет менее 0,4 м, что свидетельствует о платформенной инвариантности физического ограничения на основе оборотов роторов.
5. Агрессивность профиля полёта оказывает на точность восстановления траектории значительно большее влияние, чем различия между платформами. Корректная нормализация входных признаков под целевую платформу является обязательным условием успешного переноса модели; для её проведения достаточно короткого калибровочного висения продолжительностью 2–3 мин.

Совокупность результатов подтверждает эффективность предложенного подхода — сочетания архитектуры с селективными пространствами состояний и физического регуляризатора на основе телеметрии оборотов несущих винтов — как для дообучения на малых данных, так и для кросс-платформенного переноса без дообучения.

Заключение

Основные результаты работы заключаются в следующем.

1. На основе анализа классические и нейросетевые методы восстановления траектории, выявить их ограничения при потерях 3–240 была разработана нейросетевая модель восстановления траектории на основе селективных пространств состояний с линейной сложностью и физическим регуляризатором на основе закона тяги двигателей.
2. Для дальнейшего обучения, анализа и сравнения разработанной модели были созданы синтетические в симуляторе Gazebo с различными динамическими характеристиками для летающих мобильных роботов в различных массо-инерциальными характеристиками.
3. Математическое моделирование на синтетическом датасете показало, что разработанная нейросетевая модель обладает значительно меньшим временем восстановления траектории (на участке 120 с быстрее Transformer в 80 раз) за счет линейной сложности. Так же разработанная модель с регуляризатором на основе закона тяги двигателей на участке в 120 секунд показала точность по среднеквадратичной ошибки траектории в 2.1 раза по сравнению с Transformer и на 42% лучше базовой и на 14% лучше обобщенной.
4. Математическое моделирование на реальном датасете показало что разработанная нейросетевая модель восстановления траектории на основе селективных пространств состояний с физическим регуляризатором на основе закона тяги двигателей показало что среднеквадратичная ошибка траектории на 13% меньше базовой.
5. Обобщение разработанной нейронной сети на квадрокоптерах разных массы 1, 2 и 3.5 кг без дообучение показало что разброс среднеквадратичная ошибка траектории на участке 3с составил 0.024м, а на 120с 0.59м. Это показывает что регуляризатор на основе закона тяги позволяет обобщить результат изначальной модели на различные классы квадрокоптеров без переобучения модели.

Выражаю благодарность научному руководителю доктору технических наук Тимофееву А.Н. за поддержку, помощь, обсуждение результатов и научное руководство.

Словарь терминов

СКО : Среднеквадратическое отклонение **АОТ** : Абсолютная ошибка траектории

панграмма : Короткий текст, использующий все или почти все буквы алфавита

Список литературы

- [1] Xingxing Guang и др. — «Imu data and gps position information direct fusion based on lstm». — В: *Sensors* 21.7 (2021), с. 1—13. — DOI: 10.3390/s21072500.
- [2] Kévin Cédric Guyard и др. — «A Transformer Encoder Approach for Localization Reconstruction During GPS Outages from an IMU and GPS-Based Sensor». — В: *Sensors* 25.2 (2025). — DOI: 10.3390/s25020522.
- [3] Changhao Chen и Xianfei Pan. — «Deep Learning for Inertial Positioning: A Survey». — В: *IEEE Transactions on Intelligent Transportation Systems* 25.9 (2024), с. 10506—10523. — DOI: 10.1109/TITS.2024.3381161. — arXiv: 2303.03757.
- [4] Maziar Raissi, Paris Perdikaris и George E. Karniadakis. — «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». — В: *Journal of Computational Physics* 378 (2019), с. 686—707. — DOI: 10.1016/j.jcp.2018.10.045.
- [5] Luca Tavasci, Francesco Nex и Stefano Gandolfi. — «Reliability of Real-Time Kinematic (RTK) Positioning for Low-Cost Drones' Navigation across Global Navigation Satellite System (GNSS) Critical Environments». — В: *Sensors* 24.18 (2024). — DOI: 10.3390/s24186096.
- [6] Shengli Pang и др. — «Application of IMU/GPS Integrated Navigation System Based on Adaptive Unscented Kalman Filter Algorithm in 3D Positioning of Forest Rescue Personnel». — В: *Sensors* 24.18 (2024). — DOI: 10.3390/s24185873.
- [7] Hanjin Kim и др. — «Image Mapping Accuracy Evaluation Using UAV with Standalone, Differential (RTK), and PPP GNSS Positioning Techniques in an Abandoned Mine Site». — В: *Sensors* 23.13 (2023). — DOI: 10.3390/s23135858.
- [8] Simegne Yihunie Alaba. — «GPS-IMU Sensor Fusion for Reliable Autonomous Vehicle Position Estimation». — В: (2024). — arXiv: 2405.08119. — URL: <http://arxiv.org/abs/2405.08119>.

- [9] Weiwei Wang и Mingkuan Zhou. — «Design and Experiment of Trajectory Reconstruction Algorithm of Wireless Pipeline Robot Based on GC-LSTM». — B: *Electronics (Switzerland)* 14.19 (2025). — DOI: 10.3390/electronics14193941.
- [10] Sattar Dorafshan, Robert J. Thomas и Marc Maguire. — «UAV-Based Infrastructure Inspection: A Review». — B: *Drones* 2.4 (2018), с. 40. — DOI: 10.3390/drones2040040.
- [11] Siyandza M. Dlamini и Yashon O. Ouma. — «Large-Scale Topographic Mapping Using RTK-GNSS and Multispectral UAV Drone Photogrammetric Surveys: Comparative Evaluation of Experimental Results». — B: *Geomatics* 5.2 (2025). — DOI: 10.3390/geomatics5020025.
- [12] S. Niu и др. — «A TCN-BiLSTM and ANR-IEKF Hybrid Framework for Sustained Vehicle Positioning During GNSS Outages». — B: *Sensors* 26.1 (2026).
- [13] Yujin Shin и др. — «Long Short-Term Memory Network for INS Positioning During GNSS Outages: A Preliminary Study on Simple Trajectories». — B: *Journal of Positioning, Navigation, and Timing* 13.2 (июнь 2024), с. 137—147. — DOI: 10.11003/JPNT.2024.13.2.137.
- [14] Daniele Bianchi и др. — «Physics-Informed Neural Networks for Unmanned Aerial Vehicle System Estimation». — B: *arXiv preprint arXiv:240X.XXXXX* (2024).
- [15] Vladimir Sivtsov и др. — «Physics-Informed Neural Networks in Robotics: A Review». — B: *SSRN Electronic Journal* (2025). — DOI: 10.2139/ssrn.5125543.
- [16] Yanhui Liu и др. — «Online Continual Physics-Informed Learning for Quadrotor State Estimation Under Wind-Induced Disturbances». — B: *Aerospace* 12.8 (2025), с. 704. — DOI: 10.3390/aerospace12080704.
- [17] Mokhamad Nur Cahyadi и др. — «Performance of GPS and IMU sensor fusion using unscented Kalman filter for precise i-Boat navigation in infinite wide waters». — B: *Geodesy and Geodynamics* 14.3 (2023), с. 265—274. — DOI: 10.1016/j.geog.2022.11.005.
- [18] Christian Eling, Lasse Klingbeil и Heiner Kuhlmann. — «Real-time single-frequency GPS/MEMS-IMU attitude determination of lightweight UAVs». — B: *Sensors (Switzerland)* 15.10 (2015), с. 26212—26235. — DOI: 10.3390/s151026212.

- [19] Xiang Fang и др. — «Ski jumping trajectory reconstruction using wearable sensors via extended rauch-tung-striebl smoother with state constraints». — B: *Sensors (Switzerland)* 20.7 (2020). — DOI: 10.3390/s20071995.
- [20] E. Saif и İ. Eminoğlu. — «Modelling of quad-rotor dynamics and Hardware-in-the-Loop simulation». — B: *Journal of Engineering* 2022.10 (2022).
- [21] Z. Tahir и др. — «State Space System Modeling of a Quad Copter UAV». — B: *Indian Journal of Science and Technology* 9.27 (2016).
- [22] Michael Burri и др. — «The EuRoC micro aerial vehicle datasets». — B: *International Journal of Robotics Research* 35.10 (2016), с. 1157—1163. — DOI: 10.1177/0278364915620033.
- [23] Johannes Meyer и др. — «Comprehensive simulation of quadrotor UAVs using ROS and Gazebo». — B: *Lecture Notes in Computer Science*. — Т. 7628. — 2012.
- [24] Nathan Koenig и Andrew Howard. — «Design and use paradigms for Gazebo, an open-source multi-robot simulator». — B: *2004 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. — Т. 3. — 2004.
- [25] Ahmed M.M. Almassri и др. — «Artificial Neural Network Approach to Guarantee the Positioning Accuracy of Moving Robots by Using the Integration of IMU/UWB with Motion Capture System Data Fusion». — B: *Sensors* 22.15 (2022). — DOI: 10.3390/s22155737.
- [26] Tian Sun и др. — «Learning Spatio-Temporal Dynamics for Trajectory Recovery via Time-Aware Transformer». — B: *IEEE Transactions on Intelligent Transportation Systems* (2025), с. 1—18. — DOI: 10.1109/TITS.2025.3574100. — arXiv: 2505.13857.
- [27] Vladimir Yugay и др. — «Visual Odometry with Transformers». — B: *arXiv preprint arXiv:2510.03348* (2025). — arXiv: 2510.03348. — URL: <https://arxiv.org/abs/2510.03348>.
- [28] Alejandra Molina-Leal и др. — «Trajectory planning for a mobile robot in a dynamic environment using an lstm neural network». — B: *Applied Sciences (Switzerland)* 11.22 (2021). — DOI: 10.3390/app112210689.

- [29] Yu Fan Wu, Guo Shing Huang и Ming Cheng Kao. — «Learning Inertial Measurement Error Compensation in GPS Signal Shielded Using LSTM». — B: *Proceedings - 22nd IEEE/ACIS International Conference on Software Engineering, Artificial Intelligence, Networking and Parallel/Distributed Computing, SNPD 2021-Fall* (2021), с. 126—129. — DOI: 10.1109/SNPD51163.2021.9704926.
- [30] S. Chen и др. — «Real-time UAV Flight Path Prediction Using A Bi-directional Long Short-term Memory Network with Error Compensation». — B: *Journal of Computational Design and Engineering* 10 (2022).
- [31] Karishma Mohiuddin и др. — «Attention Is All You Need». — B: *International Conference on Information and Knowledge Management, Proceedings Nips* (2023), с. 4752—4758. — DOI: 10.1145/3583780.3615497. — arXiv: 2304.03103.
- [32] Leonard Bauersfeld и др. — «NeuroBEM: Hybrid Aerodynamic Quadrotor Model». — B: *arXiv preprint arXiv:2106.08015* (2021).
- [33] Y. Zhang и др. — «Actuator-Informed State Estimation for Quadrotors under Wind Disturbances». — B: *IEEE Robotics and Automation Letters* 7.3 (2022).
- [34] H. Liu и др. — «State Space Models with Actuator Signals for Inertial Navigation of UAVs». — B: *IEEE Transactions on Robotics* 41 (2025).
- [35] Maziar Raissi, Paris Perdikaris и George E. Karniadakis. — «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». — B: *Journal of Computational Physics* 378 (2019), с. 686—707. — DOI: 10.1016/j.jcp.2018.10.045.
- [36] Cheng Tan и др. — «Vehicle State Estimation Combining Physics-Informed Neural Network and Unscented Kalman Filtering on Manifolds». — B: *Sensors* 23.15 (2023), с. 6665. — DOI: 10.3390/s23156665.
- [37] Q. Bian и др. — «OrientationNN: a physics-informed lightweight neural network for real-time joint kinematics estimation from IMU data». — B: *Frontiers in Bioengineering and Biotechnology* (2025). — DOI: 10.3389/fbioe.2025.1737916.
- [38] S. Zhang. — «A Physics-Informed Neural Network Approach for UAV Path Planning in Dynamic Environments». — B: ().
- [39] A. K. Sahoo и I. Klein. — «MoRPI-PINN: A Physics-Informed Framework for Mobile Robot Pure Inertial Navigation». — B: (2025).

- [40] Guangshuo An и др. — «Physics informed neural networks based identification modelling of ship maneuvering motion and associated optimal excitation design». — В: *Engineering Applications of Computational Fluid Mechanics* (2025). — DOI: 10.1080/19942060.2025.2566860.
- [41] Albert Gu и Tri Dao. — «Mamba: Linear-Time Sequence Modeling with Selective State Spaces». — В: *Kalman 1960* (2024), с. 1—36. — arXiv: 2312.00752. — URL: <http://arxiv.org/abs/2312.00752>.
- [42] Toshiaki Tsuji. — «Mamba as a Motion Encoder for Robotic Imitation Learning». — В: *IEEE Access* 13 (2025), с. 69941—69949. — DOI: 10.1109/ACCESS.2025.3561283. — arXiv: 2409.02636.
- [43] Hang Zhou и др. — «Physics-informed Diffusion Mamba Transformer for Real-world Driving». — В: (2026).
- [44] SJTU-ViSYS Team. — «AI-IO: A Real-World Quadrotor Dataset with IMU and Rotor Speed Measurements». — В: (2026).
- [45] Z. Zhou и др. — «Physics-informed neural network for load sway prediction in travelling autonomous mobile cranes». — В: *Advanced Engineering Informatics* (2025). — DOI: 10.1016/j.aei.2025.XXXXXXX.
- [46] Artur Shurin и Itzik Klein. — «QuadNet: A Hybrid Framework for Quadrotor Dead Reckoning». — В: *Sensors* 22.4 (2022), с. 1426. — DOI: 10.3390/s22041426.
- [47] Anton Sidorenko и Sertac Karaman. — «Real-time Guidance for Low-Thrust Transfers Using Deep Learning». — В: *Journal of Guidance, Control, and Dynamics* 49.2 (2026), с. 345—358. — DOI: 10.2514/1.G006254.
- [48] Matthias Faessler, Antonio Franchi и Davide Scaramuzza. — «Differential Flatness of Quadrotor Dynamics Subject to Rotor Drag for Accurate Tracking of High-Speed Trajectories». — В: *IEEE Robotics and Automation Letters* 3.2 (2018), с. 620—626. — DOI: 10.1109/LRA.2017.2776353.
- [49] Guangyu Lu и др. — «Multirotor Motion Enhancement Using Propeller Speed Measurement». — В: *IEEE Robotics and Automation Letters* 7.3 (2022), с. 6942—6949. — DOI: 10.1109/LRA.2022.3177851.

- [50] Борис Георгиевич Ильясов, Ришат Маратович Гатауллин и Гузель Асфандияровна Саитова. — «Физически информированные нейронные сети для оценки состояния беспилотного летательного аппарата». — В: *Известия Самарского научного центра РАН* 25.5 (2023), с. 47—56. — DOI: 10.37313/1990-5378-2023-25-5-47-56.
- [51] Александр Иванович Кобзарь. — *Прикладная математическая статистика. Для инженеров и научных работников.* — Москва: ФИЗМАТЛИТ, 2006, — С. 816. — ISBN: 5-9221-0707-9.
- [52] H. Wang и др. — «Hybrid Aerodynamic Wind-Aware Modeling for Quadrotor State Estimation». — В: (2023).
- [53] Jiahao Cui и др. — «AI-IO: An Aerodynamics-Inspired Real-Time Inertial Odometry for Quadrotors». — В: *arXiv preprint arXiv:2603.00597* (2026). — URL: <https://arxiv.org/abs/2603.00597>.
- [54] Jiahao Cui и др. — «AI-IO: An Aerodynamics-Inspired Real-Time Inertial Odometry for Quadrotors». — В: *arXiv preprint arXiv:2603.00597* (2026). — URL: <https://arxiv.org/abs/2603.00597>.

Список рисунков

2.1	Кинематика и динамика квадрокоптера. Инерциальная система координат $\mathcal{W}$ (зелёная) и связанная система координат $\mathcal{B}$ (красная/оранжевая/синяя) с положением центра масс $\mathbf{p}_{\mathcal{WB}}$ (бирюзовый), линейной скоростью $\mathbf{v}_{\mathcal{W}}$ (пурпурный), угловой скоростью $\boldsymbol{\omega}_{\mathcal{B}}$ (фиолетовый), силами тяги отдельных роторов $f_i = k_T \omega_i^2$ (синие стрелки), силой тяжести $\mathbf{g}$ (зелёный), моментами крена, тангажа и рыскания $\tau_{x,y,z}$ и кватернионом ориентации $\mathbf{q}_{\mathcal{WB}}$. Роторы 1 и 3 вращаются по часовой стрелке (CW, синие эллипсы), роторы 2 и 4 — против часовой стрелки (CCW, красные эллипсы). . . .	32
3.1	Сравнение архитектур четырёх рассматриваемых нейронных сетей. Предлагаемая нейронная сеть выделена рамкой.	44
3.2	Сравнение спокойного режима и режима компенсации порывов ветра: 9 каналов БИНС, обороты несущих винтов и корреляция между ними.	48
3.3	Архитектура ФИ НС-ПСПС.	52
4.1	Сравнение предложенной архитектуры НС ПСПС, Transformer и LSTM по метрикам RMSE, ATE и времени инференса при разных временах потери сигнала.	59
4.2	СКО (м) четырёх моделей в зависимости от доли обучающих данных при потере сигнала ГНСС 240 с. Ось X : доля (%); ось Y : СКО (м). Столбцы: ФИ НС-ПСПС (синий), обобщённая НС-ПСПС (зелёный), базовая НС-ПСПС (красный), Transformer (оранжевый). <i>Figure 4. RMSE (m) vs. training data fraction, GNSS outage 240 s.</i>	62
4.3	СКО (м) трёх моделей на реальном датасете AI-IO при потере сигнала ГНСС 10, 30 и 60 с.	65
4.4	Зависимость СКО от массы робота, разбивка по профилю полёта . . .	67
4.5	Зависимость СКО от массы робота, разбивка по длительности потери ГНСС	68
4.6	Зависимость СКО от длительности потери сигнала ГНСС	68
.7	Архитектура потока данных восстановления траектории.	84

Список таблиц

1	Сравнительный анализ методов восстановления траектории при потерях сигнала ГНСС	28
2	Характеристики датчиков и телеметрии, используемых в работе	38
3	Сравнительный анализ вычислительной сложности моделей на этапе инференса	45
4	Сравнение спокойного режима и режима компенсации порывов ветра .	47
5	Сравнение статистических характеристик датасетов А и В	54
6	Физические и имитационные параметры экспериментальных платформ. Параметры, отличающиеся от базовой, выделены жирным шрифтом. Разрыв платформы $\Delta = m/m_{\text{base}}$	56
7	СКО (м), АОТ (м) и время инференса $t_{\text{инф}}$ (с) для НС-ПСПС, Transformer и Bi-LSTM	58
8	СКО (м) при дообучении на подмножествах, потеря сигнала ГНСС 60 с	60
9	СКО (м) при дообучении на подмножествах, потеря сигнала ГНСС 240 с	61
10	СКО (м) ФИ НС-ПСПС по всем длинам потери сигнала и долям датасета	62
11	СКО (м) восстановления траектории на реальном датасете AI-IO при различных длительностях потери сигнала ГНСС	64
12	Объёмы датасетов после предобработки	66
13	СКО (м) для всех комбинаций платформа–профиль и длительностей перерывов ГНСС. Обобщение без дообучения. Лучшее значение в каждом столбце подчёркнуто.	67
14	СКО (м) при спокойном профиле полёта. Разброс (максимум минус минимум) не превышает 0,5 м при перерыве до 60 с.	67

Приложение А

```

class MambaRPMPINN(nn.Module):
    """MambaRPMPINN – полная RPM-informed Physics-Informed Neural
    Network"""
    def __init__(self, input_dim=17, d_model=192, d_state=16, d_conv=4,
expand=2, num_layers=3):
        super().__init__()
5         self.embedding = nn.Linear(input_dim, d_model)
        nn.init.kaiming_normal_(self.embedding.weight)
        self.norm_in = nn.LayerNorm(d_model)

        self.mamba_layers = nn.ModuleList([
10         Mamba(d_model=d_model, d_state=d_state, d_conv=d_conv, expand=expand)
        for _ in range(num_layers)
        ])

        self.norm_out = nn.LayerNorm(d_model)
15         self.fc_vel = nn.Linear(d_model, 3)
        self.fc_quat = nn.Linear(d_model, 4)
        self.fc_accel = nn.Linear(d_model, 3)
        self.fc_torque_inter = nn.Linear(d_model, 4)

20         # Физические параметры регистрируем( как буферы)
        self.register_buffer('g', torch.tensor(9.81))
        self.register_buffer('m', torch.tensor(2.0))
        self.register_buffer('l', torch.tensor(0.174))
        self.register_buffer('k', torch.tensor(2.32e-8))
25         self.register_buffer('b', torch.tensor(1.1e-8))
        self.b_drag = nn.Parameter(torch.tensor(0.02))

        self.register_buffer('I_xx', torch.tensor(0.02167))
        self.register_buffer('I_yy', torch.tensor(0.02167))
30         self.register_buffer('I_zz', torch.tensor(0.04000))
        self.register_buffer('coeff_fz', torch.tensor([1., 1., 1., 1.]))

        self.register_buffer('accel_mean', torch.tensor([0.0, 0.0, -9.81]))
        self.register_buffer('accel_std', torch.tensor([0.5, 0.5, 1.0]))
35         l_arm = self.l * math.sqrt(2.0)
        self.register_buffer('coeff_tx', torch.tensor([-1., 1., 1., -1.]) *
l_arm)

```

```

    self.register_buffer('coeff_ty', torch.tensor([-1., -1., 1., 1.]) *
l_arm)
    self.register_buffer('coeff_tz', torch.tensor([-1., 1., -1., 1.]) *
40 (self.b / self.k))

    def forward(self, x):
        x = self.embedding(x)
        x = self.norm_in(x)

45     residual = x
    for mamba in self.mamba_layers:
        x = mamba(x) + residual
        residual = x

50     x = self.norm_out(x)

    vel = self.fc_vel(x)
    quat = self.fc_quat(x)
    accel_nn = self.fc_accel(x)
55     torque_inter = self.fc_torque_inter(x)

    # Нормализация кватерниона
    quat_norm = torch.norm(quat, dim=-1, keepdim=True)
    quat = quat / torch.clamp(quat_norm, min=1e-6)
60     quat = torch.clamp(quat, -1.0, 1.0)

    pred = torch.cat([vel, quat, accel_nn], dim=-1)
    return pred, torque_inter

```

Листинг 1: Программный код модели mamba_pinn_rpm

Приложение Б

1.1 Архитектура потока данных восстановления траектории

На рисунке .7 представлен полный поток данных с датчиков ГНСС, БИНС, оборотов винтов в задаче восстановления траектории с применением ФИ НС-ПСПС.




Рисунок .7 — Архитектура потока данных восстановления траектории.