

Федеральное государственное автономное образовательное учреждение
высшего образования «Длинное название образовательного учреждения
«АББРЕВИАТУРА»



На правах рукописи

Сидоренко Данил Дмитриевич

**Физически информированная нейросетевая система
восстановления траектории мобильного робота при
кратковременных потерях сигнала глобальной навигационной
спутниковой системы**

Специальность 2.5.4 —
«Роботы, мехатроника и робототехнические системы»

Диссертация на соискание учёной степени
кандидата физико-математических наук

Научный руководитель:
уч. степень, уч. звание
Фамилия Имя Отчество

Город — 2026

Оглавление

	Стр.
Введение	6
0.1 Актуальность темы исследования	6
0.2 Степень разработанности темы исследования	7
0.2.1 Классические методы.	7
0.2.2 Нейросетевые методы.	7
0.2.3 Физически информированные нейронные сети PINN	7
0.3 Цель и задачи работы	8
0.4 Научная новизна	9
0.5 Теоретическая и практическая значимость исследования	10
0.6 Методология и методы исследования	11
0.7 Положения, выносимые на защиту	11
0.8 Степень достоверности полученных результатов	12
0.9 Личный вклад автора	12
0.10 Соответствие диссертации паспорту научной специальности	13
0.11 Основные публикации по теме диссертации	13
 Глава 1. Анализ современных методов восстановления траектории мобильных роботов при кратковременных потерях сигнала ГНСС	 15
1.1 Классические методы восстановления траектории	15
1.2 Нейросетевые методы на основе рекуррентных и трансформерных архитектур	 16
1.2.1 TransformerEncoder	17
1.2.2 Двухнаправленная LSTM	18
1.3 Физически информированные нейронные сети в задачах восстановления траектории	 19
1.4 Гибридные физически информированные модели на основе последовательностей в задачах инерциальной навигации	 20
1.5 Выводы по главе	22
 Глава 2. Математическая модель квадрокоптера	 25

	Стр.
2.1 Введение	25
2.2 Кинематическая модель квадрокоптера как твёрдого тела	26
2.3 Динамическая модель твёрдого тела	28
2.4 Подробная модель сил и моментов несущих винтов	30
2.5 Модели датчиков и телеметрии	32
2.6 Описание экспериментальной платформы Holybro X500 V2 и ограничения навигационной системы	33
2.7 Симуляционная среда PX4/Gazebo с плагином RotorS	35
2.7.1 Вывод раздела	37
Глава 3. Разработка методики обучения и дообучения физически информированной нейросетевой системы	38
3.1 Общая архитектура рассматриваемых нейронных сетей	38
3.2 Обоснование применимости телеметрии оборотов несущих винтов как дополнительного источника навигационной информации	39
3.2.1 Физическое обоснование	40
3.2.2 Статистическое обоснование	40
3.2.3 Обзор релевантной литературы	41
3.3 Предлагаемая нейронная сеть	42
Глава 4. Экспериментальное исследование и сравнительный анализ эффективности предложенной системы	45
4.1 Эксперимент дообучения рассматриваемых нейронных сетей	45
4.1.1 Характеристика экспериментальных данных	45
4.1.2 Результаты дообучения при ограниченных данных	47
4.1.3 Сводная таблица по всем режимам	48
4.1.4 Визуализация результатов	49
4.1.5 Анализ результатов	49
4.2 Обсуждение	51
4.2.1 Физическая интерпретация результатов	51
4.2.2 Сравнение с методами без физического ограничения	51
4.2.3 Практическая применимость	52
4.2.4 Ограничения и направления верификации	52

4.3	Многоплатформенное обобщение одометрии на основе физически информированной нейронной сети с использованием оборотов двигателей	53
4.3.1	Постановка задачи и исследовательские вопросы	53
4.3.2	Описание экспериментальной установки	54
4.3.3	Профили полётных миссий	54
4.3.4	Архитектура нейронной сети и протокол дообучения	55
4.3.5	Протокол оценки	56
4.4	Сходимость обучения	56
4.5	Результаты	57
4.5.1	Влияние длительности потери сигнала	57
4.5.2	Влияние платформенного разрыва (RQ1)	57
4.5.3	Влияние профиля полёта (RQ2)	58
4.5.4	Сравнение стратегий дообучения (RQ3)	59
4.6	Обсуждение	60
4.7	Обобщение без дообучения ФИ-НС-ПСПС на платформы различной массы и динамики	61
4.7.1	Описание экспериментальных платформ	62
4.7.2	Профили полётных заданий	64
4.7.3	Методика проведения эксперимента	64
4.7.4	Результаты эксперимента	65
4.7.5	Обсуждение результатов	68
4.7.6	Выводы по разделу	69
4.8	Заключение	70
4.9	Обобщение без дообучения ФИ-НС-ПСПС на платформы различной массы и динамики	71
4.9.1	Описание экспериментальных платформ	72
4.9.2	Профили полётных заданий	72
4.9.3	Методика проведения эксперимента	74
4.9.4	Результаты эксперимента	75
4.9.5	Обсуждение результатов	78
4.9.6	Выводы по разделу	79
	Заключение	80

	Стр.
Словарь терминов	81
Список литературы	82
Список рисунков	86
Список таблиц	88
Приложение А. Программный код разработанной ФИ НС-ПСПС	91
Приложение Б. Архитектура потока данных восстановления траектории	92
.1 Архитектура потока данных восстановления траектории	92

Введение

0.1 Актуальность темы исследования

Современные мобильные роботы — беспилотные летательные аппараты (БПЛА), надводные и наземные платформы — широко применяются для картографирования, геодезии и инспекции протяжённых промышленных объектов: трубопроводов, высоковольтных линий электропередачи, мостовых конструкций. Базовым средством навигации служат глобальные навигационные спутниковые системы (ГНСС) в режиме. Однако металлические конструкции промышленных объектов создают зоны экранирования и многолучёвости сигнала, при которых кратковременные потери ГНСС продолжительностью 3–240 с являются штатной эксплуатационной ситуацией.

В отсутствие ГНСС позиционирование переходит на бортовую инерциальную навигационную систему (БИНС) на микроэлектромеханических датчиках (МЭМС). При двойном интегрировании шума акселерометра ошибка позиции нарастает нелинейно: на интервале 60 с погрешность достигает нескольких метров, при 240 с — сотен метров. Восстановление утраченного участка траектории в режиме постобработки позволяет обеспечить непрерывность данных без повторного сканирования.

Дополнительную трудность создаёт смена динамического режима: при компенсации порывов ветра квадрокоптер производит интенсивные асимметричные изменения тяги отдельных роторов, которые не отражаются в показаниях акселерометра. Единственным датчиком, непосредственно фиксирующим эти управляющие воздействия, является телеметрия оборотов несущих винтов. Традиционные методы (фильтры Калмана) применимы лишь до 3–5 с, а Transformer имеет квадратичную сложность $O(N^2)$, неприемлемую для бортовых систем малых роботов с ограниченными вычислительными ресурсами.

Таким образом, разработка нейросетевого метода восстановления траектории, сочетающего линейную вычислительную сложность, физическую согласованность и новый информационный канал — телеметрию оборотов несущих винтов, — представляет актуальную научно-техническую задачу в области робототехники.

0.2 Степень разработанности темы исследования

0.2.1 Классические методы.

Расширенный фильтр Калмана (РФК), фильтр без запаха (ФБЗ) и сглаживатель Рауха–Тунга–Штрибеля (СРТШ) обеспечивают высокую точность при потерях до 3–5 с. На более длинных интервалах ошибка позиции нарастает нелинейно вследствие двойного интегрирования шума акселерометра (О. А. Степанов, В. Я. Распопов и др.). Ни один из классических методов не использует телеметрию актуаторов в качестве навигационного источника.

0.2.2 Нейросетевые методы.

Двунаправленная LSTM [1] и Transformer Encoder [2] превосходят фильтры Калмана по точности, однако LSTM подвержена затуханию градиентов, а Transformer имеет квадратичную сложность $O(N^2)$, что исключает применение на бортовых системах с нейроускорителями[3].

0.2.3 Физически информированные нейронные сети PINN

Физически информированные нейронные сети [4] встраивают уравнения динамики объекта в функционал потерь. В задачах навигации БПЛА исследованы И. А. Бизяевым, Б. Г. Ильясовым и соавт.; показана их перспективность при ограниченном объёме данных. Работы по использованию телеметрии оборотов несущих винтов в качестве навигационного источника (G. Lu, J. Cui и соавт., J. Svacha и соавт.) подтверждают принципиальную важность этого канала.

Архитектуры SSM. Нейронная сеть на основе последовательностей с селективными пространствами состояний (НС ПСПС; базовая работа Mamba: A. Gu, T. Dao) обеспечивает линейную сложность $O(N)$, применяется в задачах

управления роботами, однако ни в одной известной работе не исследовалась для постобработки траектории при потерях ГНСС с физически информированным функционалом потерь на базе телеметрии оборотов.

0.3 Цель и задачи работы

Цель: разработка и исследование физически информированной нейросетевой системы восстановления траектории мобильного робота по данным БИНС и телеметрии оборотов несущих винтов при кратковременных потерях сигнала ГНСС.

Задачи:

1. Проанализировать классические и нейросетевые методы восстановления траектории, выявить их ограничения при потерях 3–240 с.
2. Разработать эффективную модель НС ПСПС с линейной сложностью $O(N)$.
3. Разработать физически информированную модель ФИ-НС ПСПС, использующую телеметрию оборотов как новый информационный канал и как основу динамического функционала потерь на базе закона тяги $F=k \cdot n^2$.
4. Создать синтетический датасет Gazebo/PX4 с синхронизированными данными БИНС, ГНСС и оборотов двигателей квадрокоптера.
5. Провести комплексные экспериментальные исследования на синтетическом и реальном датасете AI-Ю.
6. Провести экспериментальную верификацию обобщающей способности разработанной нейросетевой системы на квадрокоптерных платформах с различными массо-инерционными характеристиками при полётах разной динамической сложности.

Объект исследования — система навигации мобильного робота (много-роторного беспилотного летательного аппарата), функционирующая в условиях кратковременных потерь сигнала глобальной навигационной спутниковой системы продолжительностью от 3 до 240 секунд.

Предмет исследования — методы и алгоритмы восстановления траектории мобильного робота в режиме постобработки на основе данных бесплатфор-

менной инерциальной навигационной системы и телеметрии оборотов несущих винтов, включая физически информированные нейросетевые модели с динамическим функционалом потерь.

0.4 Научная новизна

1. Впервые для задачи восстановления траектории мобильного робота при потерях сигнала ГНСС предложена и исследована нейросетевая архитектура отличающаяся использованием модели последовательностей с селективными пространствами состояний (ПСПС) обеспечивающая линейную сложность. Что допускает исполнение предложенной модели в реальном времени на бортовых нейроускорителях с ограниченными ресурсами.

2. Разработан метод физически информированного обучения нейросетевой модели с функцией потерь физической невязки на основе оборотов несущих винтов, отличающийся от известных физически информированных нейронных сетей для БПЛА, где физические ограничения обычно формулируются на основе кинематических соотношений или только данных инерциальных датчиков. Данный метод позволяет получать более сильный и физически обоснованный обучающий сигнал именно в режимах интенсивного дифференциального управления тягой.

3. Разработан и обоснован подход к использованию телеметрии оборотов несущих винтов в качестве самостоятельного навигационного источника, независимого от бесплатформенной инерциальной навигационной системы, отличающиеся от существующих работ, в которых обороты двигателей применяются только как дополнительный признак для улучшения оценки скорости. Данный подход демонстрирует что дифференциальные изменения тяги роторов принципиально ненаблюдаемы акселерометром и гироскопом, а так же демонстрирует информационную состоятельность оборотов несущих винтов.

4. Предложен принцип режимозависимой физической регуляризации, при котором функционал потерь автоматически усиливает вклад физических невязок при переходе платформы в динамический режим с повышенной активностью приводов, отличающиеся от классических физически информированных нейронных сетей с фиксированными весовыми коэффициентами физических членов потерь. Предложенный принцип обеспечивает адаптивное усиление обучающего сигнала

именно в тех режимах, где данные инерциальных датчиков наименее информативны. Это позволяет достигать высокой точности при дообучении модели на минимальном объёме калибровочных данных нового динамического режима.

4. TODO: Здесь должен быть пункт про исследование на разных роботах

0.5 Теоретическая и практическая значимость исследования

Теоретическая значимость исследования заключается в следующем. Предложен принцип использования телеметрии актуаторов мобильного робота как нового самостоятельного навигационного источника, независимого от данных инерциальной системы, что расширяет класс информационных каналов, применимых в нейросетевых системах навигации без ГНСС. Разработан и теоретически обоснован метод режимозависимой физической регуляризации, обеспечивающий автоматическое усиление обучающего сигнала при смене динамического режима платформы. Предложенная архитектура ФИ-НС ПСПС расширяет класс физически информированных нейронных сетей на архитектуры с линейной вычислительной сложностью типа SSM, что открывает новое направление совместного применения физических ограничений и последовательностных моделей в задачах мобильной робототехники. Разработанный синтетический датасет с синхронизированными данными БИНС, ГНСС и RPM обеспечивает воспроизводимую исследовательскую основу для задачи восстановления траектории при потерях ГНСС.

Практическая значимость исследования состоит в следующем. Разработанная программа ФИ-НС ПСПС (свидетельство о государственной регистрации № 2026618441 от 25 марта 2026 г.) пригодна к непосредственному применению в системах постобработки данных беспилотных инспекционных комплексов. После квантования модель занимает 28 КБ; расчётное время инференса на нейроускорителе Neural-ART (STM32N6, 600 GOPS при INT8) не превышает 1 мс на сегмент, что обеспечивает работу в режиме реального времени при частоте 100 Гц. На реальном датасете AI-Ю при потере ГНСС 60 с достигается СКО $2,88 \pm 0,22$ м. Предложенный операционный протокол — один двухминутный калибровочный полёт перед миссией — обеспечивает адаптацию модели к новому динамическому режиму непосредственно в полевых условиях с СКО $9,4 \pm 1,8$ м при потере

240 с, что в 1,8 раза лучше базовой модели на полном датасете. Результаты применимы для беспилотных комплексов, выполняющих инспекцию линейной инфраструктуры (трубопроводы, ЛЭП), где кратковременные потери ГНСС являются штатной эксплуатационной ситуацией.

0.6 Методология и методы исследования

Теоретической основой служат три физических закона:

1. **Закон тяги несущего винта:** тяга i -го ротора $F_i = kn_i^2$, суммарная вертикальная тяга $F_z = k \sum_{i=1}^4 n_i^2$ уравнивает вес mg .
2. **Второй закон Ньютона** для поступательного движения: $m\ddot{\mathbf{r}}_I = m\mathbf{g} + R_{IB}\mathbf{F}_B + \mathbf{F}_{a,I}$, где $\mathbf{F}_{a,I} = -b_{\text{drag}}m\mathbf{v}$.
3. **Уравнения управляющих моментов:** $\tau_x = l(F_0 - F_2)$, $\tau_y = l(F_1 - F_3)$, $\tau_z = b(F_0 - F_1 + F_2 - F_3)$, где l — плечо, b — аэродинамическая константа момента.

Реализация — Python/PyTorch. Симуляция квадрокоптера Holybro X500 — Gazebo/PX4. Обучение нейронных сетей выполнялось на GPU NVIDIA GeForce GTX 1650. Верификация — 10 независимых тестовых сегментов по метрикам СКО и АТО.

0.7 Положения, выносимые на защиту

1. НС ПСПС обеспечивает линейную сложность $O(N)$ и превосходит Transformer по скорости восстановления траектории в 2,6–30 раз при длительностях потери 3–120 с при сопоставимой точности.

2. Включение нового информационного канала (телеметрия оборотов n_i) и физической модели динамики в функционал потерь обеспечивает СКО $14,3 \pm 2,3$ м при дообучении на 10% данных — ниже, чем у базовой модели на 100%.

3. ФИ-НС ПСПС превосходит базовые нейросетевые методы и метод РФК по совокупности критериев «точность — скорость — ресурсоёмкость» при дли-

тельность потери ГНСС от 30 до 240 с на синтетическом датасете и при всех исследованных длительностях (3–60 с) на реальном датасете AI-IO.

0.8 Степень достоверности полученных результатов

Достоверность полученных результатов обеспечена корректным применением методов математической статистики, теории нейронных сетей и уравнений динамики квадрокоптера. Метрики СКО и АТО вычислялись на независимых тестовых сегментах, составляющих 20% датасета и не участвовавших в обучении; в таблицах результатов приводятся значения «среднее $\pm$ стандартное отклонение» по 10 непересекающимся сегментам. Физическая адекватность предложенной модели подтверждена верификацией на открытом датасете AI-IO лаборатории SJTU-ViSYS, не участвовавшем в разработке метода; результаты РФК для той же платформы использованы как внешний базовый показатель. Скоростные характеристики НС ПСПС подтверждены сопоставлением с Transformer Encoder и двунаправленной LSTM на адаптированном датасете EuRoC MAV. Разработанная программа зарегистрирована в Федеральной службе по интеллектуальной собственности (свидетельство № 2026618441 от 25 марта 2026 г.), что обеспечивает независимую верификацию факта создания программного продукта.

0.9 Личный вклад автора

Соискателем самостоятельно сформулированы цель и задачи исследования. Разработаны архитектуры моделей НС ПСПС и ФИ-НС ПСПС, включая физический функционал потерь на основе телеметрии оборотов несущих винтов. Создан синтетический датасет на базе симулятора Gazebo/PX4, содержащий синхронизированные данные БИНС, ГНСС и оборотов четырёх двигателей. Проведены все экспериментальные исследования, выполнен анализ и обобщение результатов. Разработана и зарегистрирована программа для ЭВМ. В совместных публикациях автор принимал непосредственное участие в постановке задачи, разработке метода, проведении экспериментов и обработке результатов. Все основные научные

положения, компьютерные модели, практические решения и теоретические выводы сформулированы и выполнены автором самостоятельно.

0.10 Соответствие диссертации паспорту научной специальности

Диссертационная работа выполнена в соответствии с паспортом специальности 2.5.4 «Роботы, мехатроника и робототехнические системы» по пунктам:

- п. 5. *Методы, алгоритмы, программные и аппаратные средства управления роботами, робототехническими и мехатронными системами, включая адаптивное, оптимальное, распределённое, интеллектуальное и супервизорное управление.*
- п. 6. *Математическое и программное обеспечение, компьютерные методы и средства обработки информации в реальном времени в роботах, робототехнических и мехатронных системах.*

0.11 Основные публикации по теме диссертации

Публикации в изданиях, входящих в перечень ВАК:

1. Сидоренко Д. Д., Майстро А. С., Булдаков П. Ю., Сыромятников А. Д., Тимофеев А. Н. Сокращение вычислительных ресурсов в задаче восстановления траектории мобильных роботов при потере сигнала ГНСС // Наука и бизнес: пути развития. — 2026.
2. Сидоренко Д. Д., Тимофеев А. Н., Романов П. И. Физически информированная нейронная сеть для восстановления траектории квадрокоптера в условиях потери сигнала ГНСС // Вестник Московского авиационного института — 2026.

Свидетельство о государственной регистрации программы для ЭВМ:

3. Сидоренко Д. Д. ФИ-НС ПСПС — программа восстановления траектории квадрокоптера. Свидетельство о государственной регистрации программы для ЭВМ № 2026618441 от 25 марта 2026 г.

Объем и структура работы. Диссертация состоит из введения, 4 глав, заключения и 0 приложен. Полный объём диссертации составляет 93 страницы, включая 13 рисунков и 23 таблицы. Список литературы содержит 0 наименований.

Глава 1. Анализ современных методов восстановления траектории мобильных роботов при кратковременных потерях сигнала ГНСС

1.1 Классические методы восстановления траектории

Классические подходы к восстановлению траектории при кратковременной потере ГНСС-сигнала основаны на вероятностных фильтрах и методах оптимизации. Расширенный фильтр Калмана (РФК) [5] представляет собой вероятностный фильтр для слияния данных БИНС и ГНСС со сглаживанием, включающий прямой проход для фильтрации и обратный проход для коррекции с учетом конечной и начальной точек. Метод обеспечивает интерпретируемость, низкие вычислительные затраты и глобальную оптимизацию с граничными условиями. Данный метод подвержен ошибкам линеаризации в нелинейных сценариях, зависит от модели шума и накапливает ошибки в длительных потерях сигнала. Бессигматурный фильтр Калмана (БФК) [6] использует сигма-точки для аппроксимации нелинейных распределений и интеграции конечной точки в обратный проход. По сравнению с РФК, БФК демонстрирует лучшую обработку нелинейностей и устойчивость к шуму БИНС в потерях сигнала, но характеризуется высокой вычислительной сложностью для больших последовательностей и требует точной инициализации. Сглаживание на основе метода Рауха-Тунга-Штрибеля (RTS) [7] представляет собой метод, использующий расширенный фильтр Калмана для прямого прохода и обратного сглаживания, интегрируя начальную и конечную позиции для оптимизации траектории на основе данных БИНС. Метод обеспечивает высокую точность за счет глобальной оптимизации с граничными условиями и снижения дрейфа БИНС в длительных интервалах, однако зависит от точной модели системы и обладает вычислительной сложностью для длинных последовательностей.

1.2 Нейросетевые методы на основе рекуррентных и трансформерных архитектур

Современные подходы используют глубокое обучение для моделирования сложных нелинейных зависимостей. Сети на основе LSTM для слияния данных [8] применяют рекуррентные сети для моделирования временных зависимостей IMU, обеспечивая захват нелинейных паттернов и подход, основанный на данных, без явных моделей шума. Однако такие методы требуют больших наборов данных, подвержены риску переобучения и характеризуются низкой интерпретируемостью.

В контексте применения рекуррентных сетей именно для компенсации дрейфа инерциальных измерений при потере сигнала ГНСС заслуживает внимания работа с архитектурой из двух независимых однослойных сетей LSTM [9]. Первая сеть ориентацию аппарата, вторая — линейную скорость по последовательностям показаний БИНС. Обучение проводилось на данных высокоточной ГНСС с кинематикой в реальном времени. Валидация результатов выполнялась как на реальном мобильном роботе с МЭМС БИНС, так и в симуляции. При длительности потери сигнала ГНСС более 30 с предложенная LSTM-модель снижала СКО позиции более чем на 90 % по сравнению с классическим решением на базе фильтра Калмана.

CNN Трансформер [10] использует механизм внимания для глобальных зависимостей в оффлайн-режиме для предсказания скорости/позиции с граничными условиями. Метод эффективен в длинных последовательностях благодаря параллельной обработке, но предъявляет высокие вычислительные требования и зависит от качества обучения. Гибрид CNN-LSTM [11] комбинирует сверточные слои для извлечения признаков и LSTM для временного моделирования, обеспечивая улучшенную обработку пространственно-временных данных, снижение ошибок в зашумленных IMU и детектирование шаблонов движения (шаги, махи руками). Недостатками являются сложность архитектуры и необходимость в GPU для обучения. Искусственная нейронная сеть для слияния данных IMU/UWB с системой захвата движения [12] представляет собой оффлайн-метод на основе многослойной ANN с backpropagation (Levenberg–Marquardt), интегрирующей измерения IMU и UWB для реконструкции траектории мобильного робота. Начальная и конечная позиции используются как граничные условия для калибровки

и оптимизации позиций (X, Y координаты) в экспериментах с круговыми и случайными движениями. Метод обеспечивает высокую точность позиционирования (MAPE 99%), предотвращает неограниченный дрейф IMU

Выбор нейронных методов восстановления траектории обусловлен не только их превосходной способностью улавливать сложные нелинейные зависимости в данных IMU, недоступные классическим фильтрам Калмана, но и принципиальными аппаратными преимуществами при реализации на современных бортовых платформах. В отличие от традиционных алгоритмов, требующих интенсивной загрузки основного процессора, нейросетевые модели могут выполняться на специализированном нейроускорителе (NPU), который представляет собой полностью отдельное вычислительное ядро. Благодаря этому восстановление траектории при потере сигнала ГНСС не создаёт дополнительной нагрузки на CPU робота и не влияет на работу основных задач управления, стабилизации и планирования движения. Такой подход особенно эффективен на компактных энергоэффективных платформах, таких как NVIDIA Jetson Orin Nano с мощным встроенным NPU и новейший микроконтроллер STM32N6, оснащённый собственным нейроускорителем Neural-ART. В результате нейронные методы обеспечивают оптимальное сочетание высокой точности, низкого энергопотребления и реального времени работы, что критически важно для малых автономных роботов, выполняющих длительные миссии картографирования и инспекции в условиях нестабильного спутникового сигнала.

1.2.1 TransformerEncoder

Transformer Encoder[13, 2, 14] представляет собой энкодер, построенный на механизме внимания, который позволяет модели эффективно учитывать глобальные зависимости в последовательностях данных. В отличие от рекуррентных сетей, этот подход не страдает от проблемы затухания градиентов и может параллельно обрабатывать всю последовательность. В реализации используется линейный слой для встраивания входных данных, позиционное кодирование для сохранения порядка временных шагов и несколько слоев энкодера с механизмами само-внимания и прямого распространения. Граничные условия интегрируются через конкатенацию начальной и конечной позиций к входу, что обеспечивает

учет контекста без дополнительных проходов в базовом режиме. Такой метод особенно полезен для задач с нелинейными зависимостями в данных БИНС, где глобальный контекст помогает минимизировать накопленные ошибки. Однако квадратичная сложность может ограничивать применение на очень длинных последовательностях.

1.2.2 Двухнаправленная LSTM

Двухнаправленная LSTM представляет собой рекуррентную сеть, которая обрабатывает последовательности в обоих направлениях, захватывая контекст как из прошлого, так и из будущего. Это позволяет лучше моделировать временные зависимости в данных БИНС, где накопленные ошибки требуют учета всей траектории. В реализации используется линейный слой для встраивания, за которым следует LSTM-блок с двухнаправленным блоком. Граничные условия интегрируются через конкатенацию, но для полной эффективности требуется два прохода в двухнаправленном режиме. Такой метод устойчив к шуму и подходит для задач с последовательными данными, но может страдать от затухания градиентов на очень длинных интервалах. LSTM балансирует между сложностью и производительностью, делая её хорошей отправной точкой для сравнения с более современными архитектурами.

Описанные выше подходы наглядно показывают что различные компактные архитектуры нейронных сетей способны улавливать временные зависимости в зашумленных сигналах акселерометра и гироскопа. В то же время для платформ с высокой динамикой, резкими маневрами, сильными возмущениями подходы и архитектуры основанные только на данных (data-driven) оказываются недостаточно устойчивыми. Data-driven архитектуры не учитывают фундаментальные физические ограничения мобильного робота, что помогает обеспечить физическую согласованность, снизить ошибки предсказания при ограниченном объеме данных.

1.3 Физически информированные нейронные сети в задачах восстановления траектории

В последние годы заметно вырос интерес к физически информированным нейронным сетям (Physics-Informed Neural Networks, PINN) [15, 16], которые объединяют возможности глубокого обучения с фундаментальными законами физики. В отличие от классических нейросетей, PINN напрямую встраивают дифференциальные уравнения движения в функцию потерь. Это позволяет модели не только аппроксимировать данные, но и соблюдать физические ограничения даже при ограниченном объёме обучающей выборки. В робототехнике такой подход особенно востребован для задач динамического моделирования и навигации [12, 16]. Обзоры показывают, что PINN успешно применяются для идентификации параметров роботов, компенсации неопределённостей и построения робастных контроллеров. Особое внимание уделяется беспилотным летательным аппаратам, где низкая инерция и сильные нелинейности делают традиционные методы идентификации малоэффективными. Применительно к восстановлению траектории при кратковременных потерях сигнала ГНСС физически информированные сети открывают новые возможности. Включение в обучение уравнений Ньютона для поступательного и вращательного движения, а также реальных данных о тяге двигателей позволяет существенно снизить накопление ошибки дрейфа инерциальной системы. Вместо того чтобы полагаться только на статистические закономерности IMU-данных, модель «знает» физические ограничения конкретного робота — массу, моменты инерции, коэффициенты тяги и сопротивления. Ключевые работы подтверждают эффективность такого направления. В работе [15] авторы анализируют современные применения PINN в робототехнике и выделяют их как перспективный инструмент для задач с неполными или зашумлёнными измерениями. Так же в работе [16] продемонстрировали использование PINN для оценки динамической модели квадрокоптера, показав, что встроенные физические законы позволяют получать устойчивые результаты даже при значительном уровне шума и ограниченном объёме данных. Таким образом, интеграция физического знания в нейросетевую архитектуру представляется логичным шагом развития методов восстановления траектории. В настоящей работе этот подход реализован в рамках модели ФИ-НС ПСПС, где данные о скоростях вращения винтов используются напрямую, а уравнения динамики квадрокопте-

ра входят в состав функции потерь. Такой гибридный метод сочетает высокую вычислительную эффективность последовательностных моделей с физической согласованностью результатов, что особенно важно для бортовых систем мобильных роботов.

1.4 Гибридные физически информированные модели на основе последовательностей в задачах инерциальной навигации

В последние годы в задачах инерциальной навигации активно развиваются гибридные архитектуры, сочетающие последовательностные модели с принципами физически информированных нейронных сетей (PINN). Такие подходы позволяют одновременно учитывать сложные временные зависимости в данных IMU и обеспечивать строгое соблюдение фундаментальных законов механики за счёт встраивания остатков дифференциальных уравнений движения в функцию потерь. Авторы отмечают, что именно это сочетание позволяет эффективно решать проблему быстрого накопления ошибок дрейфа при длительных потерях сигнала ГНСС, где традиционные методы и чисто эмпирические нейронные сети часто оказываются недостаточно эффективными. Примером такого подхода является работа Tan и др. [17], в которой решается задача оценки полного динамического состояния наземного транспортного средства только по данным IMU. Авторы предлагают гибридную схему, где PINN с ограничениями в виде обыкновенных дифференциальных уравнений кинематики и динамики используется для компенсации дрейфа акселерометра и гироскопа, а полученная оценка передаётся в unscented Kalman filter, работающий на многообразиях. Данный подход обеспечивает высокую точность определения трёхмерной позиции, скорости и ориентации даже при длительных сбоях GNSS. В то же время авторы отмечают в качестве недостатка необходимость использования внешнего фильтра, что усложняет полностью энд-то-энд реализацию на борту. Аналогичный принцип гибридизации применён в работе Zhou и др. [18], посвящённой предсказанию раскачивания груза на мобильном кране по инерциальным измерениям. В предложенной модели LSTM-подобная последовательностная структура дополнена физическими остатками уравнений движения. Это позволило повысить физическую согласованность результатов и снизить ошибку по сравнению с

обычной LSTM. Однако увеличение вычислительной сложности на длинных последовательностях ограничивает возможность применения модели в реальном времени на ресурс-ограниченных устройствах. Для задач аэрокосмической тематики представляет интерес работа Bianchi и др. [16], в которой решается задача идентификации полной динамической модели квадрокоптера, включая трансляционные и вращательные уравнения движения. Авторы используют PINN на основе многослойного персептрона с элементами последовательностной обработки, встраивая уравнения Ньютона–Эйлера непосредственно в функцию потерь. Предложенный подход продемонстрировал преимущество перед расширенным фильтром Калмана по точности при наличии неопределённостей параметров модели. Основным ограничением остаётся квадратичная вычислительная сложность относительно длины обрабатываемой последовательности, что затрудняет применение на бортовых вычислительных системах. Задача онлайн-оценки состояния квадрокоптера в условиях ветровых возмущений рассмотрена в работе Liu и др. [19]. Авторы предложили архитектуру continual PINN с блоками, близкими по структуре к Transformer, и возможностью непрерывного дообучения. Преимуществом подхода является способность модели адаптироваться к изменяющимся внешним условиям без полной переподготовки. В то же время высокие требования к объёму памяти при обработке длинных IMU-последовательностей остаются существенным ограничением. Лёгкие решения, ориентированные на работу в реальном времени, представлены в работе Bian и др. [20]. Авторы решают задачу оценки кинематики суставов человека по данным IMU с помощью компактной физически информированной нейронной сети. Модель сочетает последовательностную обработку с остатками уравнений движения и обеспечивает ошибку менее 5° при возможности функционирования на мобильных устройствах. Ограничением подхода является относительно небольшое число используемых IMU-датчиков, что снижает его обобщаемость на сложные многозвенные механические системы. Для задач морской и подводной навигации представляет интерес работа An и др. [21], в которой решается задача идентификации манёвров судна по инерциальным данным. Предложенная гибридная модель на основе последовательностной архитектуры с физическими ограничениями позволяет оптимизировать режим возбуждения системы для повышения точности идентификации параметров. Данный подход обеспечивает существенное снижение ошибок моделирования по сравнению с традиционными методами. Вместе с тем необходимость предварительного расчёта оптимального возбуждения услож-

няет практическое внедрение. Дополнительные примеры подтверждают общую тенденцию. В работе Guang и др. [1] рассматривается прямое слияние данных IMU и GPS с помощью LSTM; авторы отмечают простоту реализации, но указывают на быстрый рост дрейфа при отсутствии физических ограничений. В исследовании Shurin и Klein [22] предложен гибридный нейросетевой модели и уравнений движения для решения задачи dead reckoning квадрокоптера; подход демонстрирует высокую точность, однако сопровождается ростом вычислительной сложности. Обобщающий анализ представлен в обзоре Sivtsov и др. [15], где авторы констатируют преимущество гибридных моделей по обобщающей способности, но отмечают отсутствие работ, в которых линейные по сложности архитектуры SSM (Mamba) интегрированы с полноценным механизмом PINN. Наконец, в работе Fu и др. [23] показано, что гибридные PINN позволяют решать задачи предсказания динамической нагрузки с высокой интерпретируемостью, однако требуют значительного объема обучающих данных. Таким образом, существующие гибридные физически информированные модели на основе последовательностных архитектур демонстрируют заметный прогресс в снижении дрейфа IMU и повышении точности траекторного оценивания. В то же время в рецензируемой литературе практически отсутствуют работы, в которых последовательности с селективными пространствами состояний (архитектуры семейства Mamba/SSM) интегрированы с полноценным механизмом физически информированных нейронных сетей для задач инерциальной навигации. Ни одна из проанализированных публикаций не рассматривает комбинацию линейной по сложности Mamba-архитектуры с физическими остатками и параметрической идентификацией динамики. Указанный пробел определяет перспективное направление исследований, способное объединить высокую эффективность обработки длинных последовательностей со строгой физической согласованностью результатов.

1.5 Выводы по главе

Таблица 1 — Сравнительный анализ методов восстановления траектории при потерях сигнала ГНСС

Метод	Применимость	Точность	Основные ограничения
EKF [5]	Инспекция трубопроводов, ЛЭП, навигация роботов	Хорошая при outage <30 с; сильный дрейф при 60–120 с	Ошибки линеаризации, чувствительность к модели шума, быстрый рост ошибки
AUKF [6]	Поисково-спасательные работы в лесу, GNSS-denied зоны	Снижение ошибки на 8–18 % по сравнению с EKF	Высокая вычислительная сложность, требует точной инициализации
RTS Smoother [7]	Реконструкция траекторий БПЛА с граничными условиями	Высокая точность за счёт глобальной оптимизации	Оффлайн-метод, сложен для длинных последовательностей
LSTM (IMU + GPS) [1]	Навигация БПЛА и наземных роботов при outage ГНСС	Радиальная ошибка 1,31 м (эксперимент)	Требует больших данных, склонен к переобучению, нет физической согласованности
CNN-LSTM Hybrid [11]	Motion tracking, indoor навигация, детектирование паттернов	Хорошая точность в зашумлённых условиях	Сложная архитектура, требует GPU, низкая интерпретируемость
Transformer / CNN-Transformer [2]	Длинные последовательности IMU при outage ГНСС	Хорошая работа с длинными seq.	Квадратичная сложность $O(n^2)$, высокие требования к памяти
PINN (оценка состояния БПЛА) [16]	Идентификация динамики квадрокоптеров в условиях неопределённости	Устойчивость при шуме и малых данных	Квадратичная сложность, сложность обучения
Hybrid PINN + фильтр [17]	Полная оценка состояния платформ только по IMU	Высокая точность даже при длительных outage	Не полностью end-to-end, требует внешнего фильтра
Mamba (SSM) [24, 25]	Обработка длинных IMU-последовательностей роботов и БПЛА	Линейная сложность, хорошее масштабирование	Меньше накопленного опыта применения в GNSS-denied задачах
GC-LSTM (pipeline robot) [26]	Инспекция трубопроводов в условиях экранирования	Max deviation 0,093–0,252 м	Специализирован под геометрию трубы, не универсален для свободного полёта
TCN-BiLSTM + ANR-IEKF [27]	Наземные платформы, sustained positioning при outage	Высокая точность и робастность	Сложность гибридной настройки, в основном для наземных роботов

Таблица 2 — Сравнительный анализ методов восстановления траектории при кратковременных потерях сигнала ГНСС

Класс методов	Примеры	Точность при длительных outage	Сложность	Физ. согласованность	Учёт RPM / актуаторов
Классические фильтры	EKF, UKF, RTS, AUKF	$O(t^2)$ дрейф	Низкая	Высокая	Нет
Data-driven NN	LSTM, Transformer	Хорошая на данных, деградация при смене режима	Средняя–высокая	Низкая	Нет
PINN (generic)	Bianchi2024, Tan2023	Улучшенная	Средняя	Высокая	Нет
SSM + PINN (гибрид)	—	—	Низкая	Высокая	Нет
Предлагаемый подход	ФИ-НС-ПСПС (Mamba + RPM-PINN)	Лучшая при дообучении на малых данных	Низкая	Высокая	Да (динамический регуляризатор)

Глава 2. Математическая модель квадрокоптера

2.1 Введение

Для построения физически информированной нейросетевой системы оценки состояния квадрокоптера в условиях кратковременных потерь сигнала ГНСС необходимо располагать математической моделью, которая, с одной стороны, точно описывает динамику платформы, а с другой — позволяет сформулировать физический регуляризатор в функции потерь нейронной сети. Такая модель должна связывать управляющие воздействия, измерения бортовой инерциальной навигационной системы (БИНС) и истинное движение аппарата, а также объяснять, почему телеметрия оборотов несущих винтов несёт информацию, принципиально недоступную акселерометру и гироскопу в определённых режимах полёта.

В настоящей работе используется модель квадрокоптера как твёрдого тела с шестью степенями свободы, дополненная детальной моделью несущих винтов с учётом основных аэродинамических эффектов. Данная модель опирается на классические уравнения Ньютона–Эйлера и теорию элемента лопасти в сочетании с теорией количества движения (ВЕМ). Такой подход позволяет, во-первых, получить физически обоснованный остаток в функции потерь нейронной сети, а во-вторых — количественно обосновать информационную ценность телеметрии оборотов несущих винтов именно в режиме компенсации порывов ветра, который наиболее характерен для задач термокартографирования протяжённых промышленных объектов.

Ключевым элементом предлагаемого подхода является использование телеметрии оборотов несущих винтов не только как дополнительного входного сигнала нейронной сети, но и как основы для физического регуляризатора потерь. Как будет показано ниже, в режиме компенсации порывов ветра автопилот поддерживает суммарную вертикальную тягу близкой к весу аппарата, при этом быстро перераспределяя обороты между роторами для создания управляющих моментов. В результате дифференциальные изменения тяги взаимно компенсируются в суммарном сигнале акселерометра, а угловые возмущения оказываются слабо различимы на фоне шума гироскопа. Сигнал оборотов несущих винтов, на-

против, напрямую отражает индивидуальные силы тяги и моменты, создаваемые каждым ротором. Это наблюдение подтверждается как теоретическим анализом уравнений динамики, так и статистической оценкой линейной независимости сигналов с помощью коэффициента корреляции Пирсона.

Модель, представленная в данной главе, служит теоретической основой для разработки физически информированной нейросетевой архитектуры ФИ НС-ПСПС 3 и для интерпретации результатов экспериментального исследования 4. В частности, она позволяет сформулировать динамический функционал потерь, содержащий остатки второго закона Ньютона, вычисляемые с использованием известных оборотов несущих винтов. Такой регуляризатор существенно повышает физическую согласованность предсказаний модели именно в тех условиях, где объём дообучающих данных ограничен, а риск переобучения высок.

2.2 Кинематическая модель квадрокоптера как твёрдого тела

Квадрокоптер рассматривается как твёрдое тело с шестью степенями свободы. Для описания его движения вводятся две системы координат: инерциальная система W , жёстко связанная с Землёй (ось z направлена вертикально вверх, против вектора силы тяжести), и связанная система B , жёстко связанная с корпусом аппарата (ось z совпадает с осью симметрии квадрокоптера и направлена вдоль вектора суммарной тяги несущих винтов). Схема осей и систем координат приведена на рисунке 2.1

tikz amsmath

Пусть $\mathbf{p}^W \in \mathbb{R}^3$ — положение центра масс квадрокоптера в инерциальной системе координат, $\mathbf{v}^W \in \mathbb{R}^3$ — линейная скорость центра масс в той же системе, а $\mathbf{R}_B^W \in SO(3)$ — матрица направляющих косинусов, осуществляющая преобразование векторов из связанной системы координат в инерциальную. Угловую скорость корпуса в связанной системе обозначим $\boldsymbol{\omega}^B \in \mathbb{R}^3$.

Кинематика поступательного движения описывается простым соотношением:

$$\dot{\mathbf{p}}^W = \mathbf{v}^W. \quad (2.1)$$




Рисунок 2.1 — Кинематика и динамика квадрокоптера. Инерциальная система координат $\mathcal{W}$ (зелёная) и связанная система координат $\mathcal{B}$ (красная/оранжевая/синяя) с положением центра масс $\mathbf{p}_{\mathcal{WB}}$ (бирюзовый), линейной скоростью $\mathbf{v}_{\mathcal{W}}$ (пурпурный), угловой скоростью $\boldsymbol{\omega}_{\mathcal{B}}$ (фиолетовый), силами тяги отдельных роторов $f_i = k_T \omega_i^2$ (синие стрелки), силой тяжести $\mathbf{g}$ (зелёный), моментами крена, тангажа и рыскания $\tau_{x,y,z}$ и кватернионом ориентации $\mathbf{q}_{\mathcal{WB}}$. Роторы 1 и 3 вращаются по часовой стрелке (CW, синие эллипсы), роторы 2 и 4 — против часовой стрелки (CCW, красные эллипсы).

Кинематика вращательного движения записывается с помощью оператора кососимметричной матрицы $[\cdot]_{\times}$:

$$\dot{\mathbf{R}}_B^W = \mathbf{R}_B^W [\boldsymbol{\omega}^B]_{\times}, \quad (2.2)$$

где

$$[\boldsymbol{\omega}^B]_{\times} = \begin{bmatrix} 0 & -\omega_z & \omega_y \\ \omega_z & 0 & -\omega_x \\ -\omega_y & \omega_x & 0 \end{bmatrix}.$$

Для численного интегрирования и последующего использования в нейросетевой архитектуре часто удобнее работать с кватернионным представлением ориентации. Пусть $\mathbf{q} \in \mathbb{S}^3$ — единичный кватернион, описывающий ориентацию

связанной системы относительно инерциальной. Тогда кинематическое уравнение для кватерниона принимает вид:

$$\dot{\mathbf{q}} = \frac{1}{2} \mathbf{q} \otimes \boldsymbol{\omega}^B, \quad (2.3)$$

где $\otimes$ обозначает операцию кватернионного умножения. Кватернионное представление обеспечивает численную устойчивость при интегрировании на длительных интервалах и автоматически сохраняет свойство ортогональности матрицы поворота (в отличие от непосредственного интегрирования уравнения (2.2)).

Выбор матричного или кватернионного представления ориентации определяется контекстом. В аналитических выкладках и при формулировке физического регуляризатора потерь удобно использовать матрицу $\mathbf{R}_B^W$, тогда как при численном интегрировании траектории и в реализации нейронной сети предпочтительнее кватернионная форма. В дальнейшем в работе будут использоваться оба представления в зависимости от решаемой задачи.

Кинематические уравнения (2.1)–(2.3) являются точными и не содержат приближений. Они служат первой частью полной математической модели, необходимой для построения физически информированной нейросетевой системы. Следующий раздел посвящён динамике поступательного и вращательного движения квадрокоптера.

2.3 Динамическая модель твёрдого тела

Динамика поступательного и вращательного движения квадрокоптера описывается уравнениями Ньютона–Эйлера, записанными в инерциальной и связанной системах координат соответственно. Эти уравнения лежат в основе физического регуляризатора потерь нейронной сети и позволяют связать измеряемые БИНС ускорения и угловые скорости с силами и моментами, создаваемыми несущими винтами.

Поступательное движение центра масс в инерциальной системе координат W подчиняется второму закону Ньютона:

$$m\dot{\mathbf{v}}^W = \mathbf{R}_B^W \mathbf{F}^B - m\mathbf{g}^W + \mathbf{F}_{\text{аэр}}^B, \quad (2.4)$$

где m — масса платформы, $\mathbf{F}^B \in \mathbb{R}^3$ — суммарная сила, создаваемая несущими винтами в связанной системе координат B , $\mathbf{g}^W = [0, 0, -9,81]^\top$ м/с² — вектор ускорения свободного падения, а $\mathbf{F}_{\text{аэп}}^B$ — аэродинамическая сила сопротивления корпуса и взаимодействия потоков.

Вращательное движение в связанной системе координат B описывается уравнением Эйлера:

$$\mathbf{J}\dot{\boldsymbol{\omega}}^B + \boldsymbol{\omega}^B \times \mathbf{J}\boldsymbol{\omega}^B = \boldsymbol{\tau}^B, \quad (2.5)$$

где $\mathbf{J} \in \mathbb{R}^{3 \times 3}$ — тензор инерции аппарата относительно центра масс, выраженный в связанной системе координат, а $\boldsymbol{\tau}^B \in \mathbb{R}^3$ — суммарный момент сил, создаваемый несущими винтами.

Тензор инерции $\mathbf{J}$ для реального квадрокоптера Holybro X500 V2 определяется либо экспериментально (путём качания платформы на подвесе), либо из CAD-модели и SDF-файла симулятора. В общем случае $\mathbf{J}$ является симметричной положительно определённой матрицей с ненулевыми продуктами инерции. Однако для большинства симметричных квадрокоптеров с близкой к крестообразной компоновкой продукты инерции малы и часто пренебрегаются, оставляя диагональную структуру:

$$\mathbf{J} = \text{diag}(J_{xx}, J_{yy}, J_{zz}).$$

Аэродинамическое сопротивление корпуса в первом приближении аппроксимируется линейной зависимостью от скорости:

$$\mathbf{F}_{\text{аэп}}^B = -b_{\text{drag}} m \mathbf{v}^B, \quad (2.6)$$

где коэффициент $b_{\text{drag}} > 0$ является обучаемым параметром модели и может быть идентифицирован по лётным данным. Более точные модели учитывают квадратичное сопротивление и индуцированное сопротивление от несущих винтов; эти эффекты будут рассмотрены в следующем разделе.

Уравнения (2.4) и (2.5) являются точными в рамках допущений о твёрдом теле и сосредоточенных силах. Они не содержат внутренних динамических состояний (кроме ориентации и скорости) и поэтому удобны для встраивания в физически информированные нейронные сети в виде остатков. Подстановка измеряемого БИНС ускорения в уравнение (2.4) позволяет выразить невязку между предсказанным и физически ожидаемым ускорением через известные обороты

несущих винтов — именно этот остаток будет использоваться в качестве физического регуляризатора потерь в главе 3.

Таким образом, динамическая модель твёрдого тела задаёт строгие физические ограничения, которым должна удовлетворять нейросетевая оценка состояния. Следующий раздел посвящён детальному описанию сил и моментов, создаваемых несущими винтами, — ключевому элементу, позволяющему связать телеметрию оборотов с динамикой платформы.

2.4 Подробная модель сил и моментов несущих винтов

Силы и моменты, создаваемые несущими винтами, являются основным источником управляющих воздействий квадрокоптера. Именно через эти величины телеметрия оборотов роторов связывается с динамикой платформы и становится полезной для физически информированной нейронной сети. В настоящей работе используется двухуровневое описание аэродинамики винтов: простая квадратичная модель для базовых расчётов и более точная модель на основе теории элемента лопасти в сочетании с теорией количества движения (БЕМ), учитывающая влияние скорости набегающего потока.

В простейшем приближении, справедливом для умеренных скоростей полёта и небольших углов атаки, тяга F_i и реактивный момент Q_i отдельного винта аппроксимируются квадратичными зависимостями от угловой скорости вращения ω_i (рад/с):

$$F_i = k_t \omega_i^2, \quad Q_i = k_q \omega_i^2 \cdot \text{sign}(\omega_i), \quad (2.7)$$

где коэффициенты $k_t > 0$ и $k_q > 0$ определяются экспериментально на стенде статической тяги или идентифицируются по лётным данным. Суммарная сила и момент в связанной системе координат записываются как

$$\mathbf{F}^B = \sum_{i=1}^4 F_i \mathbf{e}_z + \mathbf{F}_{\text{drag}}, \quad (2.8)$$

$$\boldsymbol{\tau}^B = \sum_{i=1}^4 (Q_i \mathbf{e}_z + \mathbf{r}_{P,i} \times F_i \mathbf{e}_z) + \boldsymbol{\tau}_{\text{drag}}, \quad (2.9)$$

где $\mathbf{r}_{P,i}$ — радиус-вектор расположения i -го винта относительно центра масс, $\mathbf{e}_z$ — единичный вектор оси z связанной системы. Члены $\mathbf{F}_{\text{drag}}$ и $\boldsymbol{\tau}_{\text{drag}}$ учитывают индуцированное сопротивление и взаимное влияние потоков от соседних винтов.

Более точное описание аэродинамики отдельного винта даёт теория элемента лопасти в сочетании с теорией количества движения (BEM). Согласно этой теории, индуцированная скорость v_i и аэродинамические коэффициенты зависят от относительной скорости набегающего потока. В работах по гибриднему аэродинамическому моделированию квадрокоптеров (NeuroBEM, arXiv:2106.08015) показано, что коэффициенты тяги C_T и момента C_Q являются функциями не только угловой скорости, но и составляющих скорости набегающего потока v_x, v_y, v_z в плоскости ротора. Это приводит к появлению дополнительных слагаемых в выражении для силы тяги, пропорциональных $\omega_m^2 v_x, \omega_m^2 v_y$ и $\omega_m^2 v_z$, где $\omega_m^2 = \sum_{i=1}^4 \omega_i^2$.

Такая зависимость имеет принципиальное значение для задач оценки состояния. Измеряемое акселерометром ускорение зависит не только от управляющих воздействий (через суммарную тягу), но и от текущей линейной скорости полёта. Следовательно, зная текущие обороты несущих винтов, можно в принципе восстановить часть информации о скорости, «спрятанной» в сигнале БИНС. Именно этот факт лежит в основе использования телеметрии оборотов как дополнительного входа нейросети и как источника физического регуляризатора потерь.

Параметры аэродинамической модели (k_t, k_q , коэффициенты индуцированного сопротивления) для платформы Holybro X500 V2 могут быть взяты из SDF-модели симулятора или уточнены по результатам идентификации на реальных данных. В контексте физически информированных нейронных сетей эти параметры либо фиксируются, либо становятся обучаемыми величинами, что позволяет модели адаптироваться к конкретной платформе при дообучении.

Таким образом, модель сил и моментов несущих винтов обеспечивает прямую связь между телеметрией оборотов и физическими остатками в функции потерь нейронной сети. В следующем разделе рассматриваются модели датчиков, с помощью которых эти остатки сравниваются с реальными измерениями.

2.5 Модели датчиков и телеметрии

Для обучения и оценки физически информированной нейросетевой системы необходимо располагать реалистичными моделями измерений, которые связывают истинное состояние платформы с сигналами, доступными на борту. В настоящей работе используются три основных источника данных: бортовая инерциальная навигационная система (БИНС), приёмник ГНСС и телеметрия оборотов несущих винтов. Все модели датчиков реализованы в симуляторе PX4/Gazebo и соответствуют характеристикам реальной платформы Holybro X500 V2.

Бортовая инерциальная навигационная система включает трёхосевой акселерометр, трёхосевой гироскоп и трёхосевой магнитометр. Измерения БИНС моделируются с частотой 200 Гц и содержат как медленно меняющиеся смещения (bias), так и высокочастотный шум. Модель измерений гироскопа записывается в виде

$$\tilde{\omega}^B = \omega^B + \mathbf{b}_g + \mathbf{n}_g, \quad (2.10)$$

где $\mathbf{b}_g$ — вектор смещений (дрейф), а $\mathbf{n}_g$ — белый гауссовский шум с нулевым средним и стандартным отклонением, типичным для потребительских МЭМС-датчиков класса ICM-42688 ($\sigma_g \approx 0,00087$ рад/с).

Аналогичная модель используется для акселерометра:

$$\tilde{\mathbf{a}}^B = \mathbf{R}_W^B(\dot{\mathbf{v}}^W - \mathbf{g}^W) + \mathbf{b}_a + \mathbf{n}_a, \quad (2.11)$$

где $\mathbf{b}_a$ — смещение, а $\mathbf{n}_a$ — шум с $\sigma_a \approx 0,0064$ м/с² по осям x и y и несколько большим значением по оси z (учитывается влияние гравитации и вибраций). Магнитометр моделируется с частотой 100 Гц и низким уровнем шума, что позволяет использовать его для коррекции угла рыскания при наличии магнитных возмущений.

Приёмник ГНСС имитируется с частотой обновления 5 Гц и позиционным шумом, соответствующим RTK-режиму в открытых условиях ($\sigma_{\text{GNSS}} \approx 0,05\text{--}0,1$ м). Потеря сигнала моделируется путём маскирования выходных данных (значения заменяются на NaN или специальный флаг), что позволяет формировать обучающие примеры с имитируемыми outage длительностью от 3 до 240 с.

Особое внимание в работе уделяется телеметрии оборотов несущих винтов. Этот сигнал считывается непосредственно с контроллера моторов (ESC) или

полётного контроллера с частотой 200 Гц и представляет собой угловые скорости четырёх роторов $\mathbf{n} = [n_1, n_2, n_3, n_4]^T$ (об/мин). В симуляторе и на реальной платформе Holybro X500 V2 этот сигнал доступен без установки дополнительного оборудования и обладает низкой задержкой. Квантование сигнала составляет примерно 10 об/мин, что соответствует разрешению типичных ESC. В отличие от данных БИНС, телеметрия оборотов напрямую отражает индивидуальные управляющие воздействия и не подвержена интегрирующему дрейфу.

Основные характеристики датчиков и телеметрии сведены в таблицу 3.

Таблица 3 — Характеристики датчиков и телеметрии, используемых в работе

Источник данных	Частота	Шум / разрешение	Примечание
Акселерометр (БИНС)	200 Гц	$\sigma_a \approx 0,0064 \text{ м/с}^2$	Смещения + шум
Гироскоп (БИНС)	200 Гц	$\sigma_g \approx 0,00087 \text{ рад/с}$	Смещения + шум
Магнитометр	100 Гц	Низкий	Коррекция рыскания
ГНСС	5 Гц	$\sigma \approx 0,05\text{--}0,1 \text{ м}$	Маскирование при оу
Обороты винтов	200 Гц	Квантование $\approx 10 \text{ об/мин}$	Прямое считывание с

Модели датчиков, описанные выше, позволяют формировать обучающие и тестовые наборы данных, в которых одновременно присутствуют измерения БИНС, телеметрия оборотов и точные ground truth значения положения, скорости и ориентации из симулятора. Именно такое сочетание данных делает возможным обучение физически информированных нейронных сетей с регуляризатором на основе оборотов несущих винтов.

В следующем разделе приводится описание экспериментальной платформы Holybro X500 V2 и ограничений, накладываемых условиями реальной задачи термокартографирования промышленных объектов.

2.6 Описание экспериментальной платформы Holybro X500 V2 и ограничения навигационной системы

Объектом исследования является система навигации автономного квадрокоптера Holybro X500 V2, предназначенного для выполнения задач термокартографирования протяжённых промышленных объектов в условиях кратковременных

потерь сигнала ГНСС. Платформа представляет собой типичный представитель класса малых квадрокоптеров с максимальной взлётной массой 1–3 кг, оснащённых тепловизионной камерой и бортовой инерциальной навигационной системой на основе потребительских МЭМС-датчиков.

Holybro X500 V2 построен на базе полностью углеродной рамы с колёсной базой 500 мм. Масса рамы и комплекта (ARF kit) составляет около 610 г, а полная масса платформы в конфигурации с батареей 4S 5000 мА·ч и полезной нагрузкой достигает примерно 2,0 кг (значение, используемое в SDF-модели симулятора). Тензор инерции относительно центра масс в связанной системе координат имеет следующие диагональные элементы: $I_{xx} = I_{yy} \approx 0,02167 \text{ кг} \cdot \text{м}^2$ и $I_{zz} \approx 0,0400 \text{ кг} \cdot \text{м}^2$. Длина плеча от центра масс до оси каждого ротора составляет 0,174 м. Платформа оснащена четырьмя моторами Holybro 2216 KV880 (или KV920), электронными регуляторами скорости Holybro BLHeli S 20A и пропеллерами типоразмера 1045 (CW/CCW). Полётный контроллер — Pixhawk 6C с прошивкой PX4, обеспечивающий внутренние контуры стабилизации ориентации и угловой скорости, работающие автономно от сигнала ГНСС.

Важным преимуществом платформы является наличие нейронного процессора (NPU), который позволяет выполнять инференс нейронных сетей непосредственно на борту без существенной дополнительной нагрузки на основной процессор. Это открывает возможность практического применения физически информированных нейросетевых систем оценки состояния в реальных миссиях.

Однако условия применения накладывают жёсткие ограничения на выбор методов навигации. Во-первых, максимальная взлётная масса в диапазоне 1–3 кг существенно ограничивает возможность установки дополнительных тяжёлых сенсоров (лидаров высокого класса, стереокамер и т.п.). Во-вторых, тепловизионная камера, предназначенная для картографирования, не может служить надёжным источником визуальной одометрии: металлические поверхности промышленных объектов (трубопроводы, эстакады, ЛЭП) характеризуются однородным тепловым полем, практически лишённым угловых точек и текстурных особенностей. Кроме того, периодическая коррекция неоднородности (NUC) прерывает поток данных, делая визуальную одометрию нестабильной. В-третьих, показания лидаров существенно деградируют в запылённой и задымлённой среде промышленных площадок, где часто выполняются инспекционные работы.

В отсутствие внешней коррекции от ГНСС потребительские МЭМС-акселерометры и гироскопы накапливают постоянно растущую позиционную

ошибку, описываемую законом $O(t^2)$. При длительности потери сигнала 240 с эта ошибка может достигать десятков и сотен метров, что делает чисто инерциальную навигацию непригодной для задач, требующих точного восстановления траектории.

Таким образом, ни один из стандартных методов навигации без ГНСС (визуальная одометрия, лидарная одометрия, классические фильтры Калмана без дополнительных измерений) не применим одновременно при описанных выше ограничениях платформы и среды. Возникает необходимость в альтернативном источнике навигационной информации, доступном на борту без дополнительной аппаратной нагрузки. Таким источником, как будет показано в разделе 2.8, является телеметрия оборотов несущих винтов.

В следующем разделе описывается симуляционная среда, в которой проводились все эксперименты по обучению и оценке предложенной физически информированной нейросетевой системы.

2.7 Симуляционная среда PX4/Gazebo с плагином RotorS

Все эксперименты по обучению и оценке физически информированной нейросетевой системы проводились в симуляторе PX4/Gazebo с плагином RotorS. Выбор данной среды обусловлен несколькими ключевыми факторами, делающими её стандартным бенчмарком для исследований в области нейросетевой навигации беспилотных летательных аппаратов.

PX4 представляет собой открытый программный стек автопилота, полностью идентичный по архитектуре и алгоритмам управления реальным коммерческим платформам. Это обеспечивает высокую степень переносимости результатов из симуляции на реальное оборудование. Gazebo, в свою очередь, предоставляет физически корректную модель динамики квадрокоптера, включающую аэродинамические взаимодействия несущих винтов, силу тяжести, аэродинамическое сопротивление корпуса и реалистичные модели порывов ветра. Плагин RotorS расширяет возможности Gazebo специализированными моделями мультироторных платформ и датчиков, что позволяет получать синхронизированные данные с высокой точностью.

Важным преимуществом симулятора является возможность генерации больших объёмов размеченных данных с точным ground truth (положение, скорость, ориентация, угловые скорости и линейные ускорения центра масс). В отличие от натуральных экспериментов, симуляция обеспечивает полную повторяемость условий, точный контроль параметров окружающей среды и мгновенную доступность эталонных траекторий. Это особенно критично для задач обучения физически информированных нейронных сетей, где требуется большое количество примеров с известными граничными условиями.

В симуляторе реализованы модели всех датчиков, используемых в работе. Бортовая инерциальная навигационная система (акселерометр, гироскоп, магнитометр) моделируется с частотой 200 Гц и реалистичными значениями шума и смещений, соответствующими потребительским МЭМС-датчикам (ICM-42688 и аналогичным). Приёмник ГНСС имитируется с частотой 5 Гц и возможностью маскирования сигнала для создания сценариев потери ГНСС. Телеметрия оборотов несущих винтов генерируется с частотой 200 Гц непосредственно из модели силовой установки и соответствует сигналу, доступному на реальном полётном контроллере.

Для проведения экспериментов были сформированы два основных датасета. Датасет А соответствует стандартному (спокойному) режиму полёта с ограниченными манёврами и номинальной траекторией горизонтального облёта промышленного объекта. Датасет В имитирует режим компенсации порывов ветра с резкими изменениями скорости и направления, характерными для работы вблизи металлических конструкций. Оба датасета содержат синхронизированные данные БИНС, ГНСС, телеметрию оборотов четырёх несущих винтов и точные ground truth значения из внутреннего состояния симулятора.

Подготовка данных включала ресемплинг до единой частоты 100 Гц, линейную интерполяцию пропущенных значений и формирование сегментов с имитируемыми потерями сигнала ГНСС длительностью от 3 до 240 с. Для каждого сегмента сохранялись начальная и конечная позиции, что позволяет использовать двунаправленное интегрирование с граничными условиями при оценке качества восстановления траектории.

Симуляционная среда PX4/Gazebo с RotorS обеспечивает необходимое сочетание физической достоверности, синхронизации данных и масштабируемости, что делает её оптимальной платформой для разработки и верификации физически информированных нейросетевых систем навигации квадрокоптера.

В следующем разделе приводится развёрнутое обоснование применимости телеметрии оборотов несущих винтов как дополнительного источника навигационной информации.

2.7.1 Вывод раздела

Физический анализ, статистическая оценка с помощью коэффициента корреляции Пирсона и обзор современной литературы однозначно свидетельствуют о высокой информационной ценности телеметрии оборотов несущих винтов. Этот сигнал является доступным на борту без дополнительного оборудования, линейно независимым от БИНС и особенно информативным именно в режиме компенсации порывов ветра. Он обеспечивает повышенный контраст обучающего сигнала для физического регуляризатора потерь и позволяет эффективно адаптировать модель к новому динамическому режиму при ограниченном объёме дообучающих данных.

Именно это обоснование определяет архитектуру физически информированной нейросетевой системы, разрабатываемой в следующей главе.

Глава 3. Разработка методики обучения и дообучения физически информированной нейросетевой системы

3.1 Общая архитектура рассматриваемых нейронных сетей

В данной работе рассматриваются следующие нейронные сети:

1. Предлагаемая в данной работе **физически информированная** нейронная сеть на основе последовательностей с селективными пространствами состояний с динамическим функционалом потерь. Динамический функционал основывается на законе тяги несущих винтов. Кратко обозначим как **ФИ НС-ПСПС**.
2. Нейронная сеть на основе последовательностей с селективными пространствами состояний, учитывающая динамические ограничения платформы по внутренним состояниям системы, без учёта оборотов двигателей, ранее предложенная авторами в работе [28]. Кратко обозначим как **ДИ НС-ПСПС**.
3. Нейронная сеть на основе последовательностей с селективными пространствами состояний с базовым функционалом потерь $\mathcal{L}_{traj}$, содержащим только целевую ошибку по траектории; блок физических ограничений отсутствует. Кратко обозначим как **НС-ПСПС**. Кратко обозначим как **базовая нейронная сеть**.
4. Нейронная сеть на основе механизма внимания, включённая в сравнение как представитель альтернативного класса архитектур. В работе обозначается как **Transformer**.

Обобщённая схема всех четырёх архитектур представлена на рисунке 3.1. На схеме показаны входной вектор, ядро, выходной вектор и функционал потерь для каждой из моделей. Ключевые различия состоят в следующем. Transformer использует ядро на основе механизма внимания и не включает физических ограничений. Базовая нейронная сеть использует ядро Mamba и базовый функционал $\mathcal{L}_{traj}$, который является общей частью всех трёх НС на основе пространственно-временной модели состояния. Обобщённая нейронная сеть дополняет базовый функционал регуляризатором по внутренним состояниям системы, не зависящим от оборотов. Предлагаемая нейронная сеть дополнительно принимает на вход те-




Рисунок 3.1 — Сравнение архитектур четырёх рассматриваемых нейронных сетей. Предлагаемая нейронная сеть выделена рамкой.

Figure 2. Comparison of architectures of the four neural networks under study. The proposed network is highlighted.

леметрию оборотов n_t и включает физический регуляризатор, явно основанный на законе тяги (??), вычисляемый непосредственно из n_i .

3.2 Обоснование применимости телеметрии оборотов несущих винтов как дополнительного источника навигационной информации

Задача восстановления траектории квадрокоптера при кратковременных потерях сигнала ГНСС требует максимально полного использования всех доступных бортовых сигналов. Как было показано в разделах ?? бортовая инерциальная навигационная система (БИНС) в режиме компенсации порывов ветра существенно теряет информативность. В настоящем разделе приводится многоуровневое обоснование того, почему телеметрия оборотов несущих винтов представляет собой ценный, физически обоснованный и статистически независимый источник информации, который существенно усиливает физически информированные нейронные сети.

3.2.1 Физическое обоснование

Из уравнений динамики твёрдого тела (2.4)–(2.5) и модели сил несущих винтов следует, что в режиме компенсации порывов ветра автопилот поддерживает суммарную вертикальную тягу близкой к весу аппарата ($F_z \approx mg$), одновременно быстро перераспределяя обороты между роторами для создания управляющих моментов. Дифференциальные изменения тяги при этом взаимно компенсируются в суммарном сигнале акселерометра, а угловые возмущения оказываются слабо различимы гироскопом на фоне шума. В результате БИНС получает лишь интегральную картину воздействий.

Телеметрия оборотов несущих винтов, напротив, напрямую отражает индивидуальную тягу каждого ротора по закону $F_i = k_t \omega_i^2$. Это позволяет вычислить суммарную силу и моменты и сформировать физический остаток второго закона Ньютона:

$$\varepsilon_F = m\hat{\mathbf{a}} - \mathbf{F}_{\text{net}}(n_i, \hat{\mathbf{v}}), \quad (3.1)$$

который может использоваться в качестве supervision-сигнала в функции потерь нейронной сети без необходимости ground truth позиции.

3.2.2 Статистическое обоснование

Для количественной оценки линейной независимости сигналов применяется коэффициент корреляции Пирсона (??). Сравнительный анализ двух режимов полёта (спокойный и компенсация порывов ветра) показал, что при практически неизменной дисперсии вертикального ускорения БИНС дисперсия дифференциальных оборотов возрастает в 57 раз, а средний коэффициент корреляции остаётся низким ($|r| \approx 0,24$). Это подтверждает, что сигнал оборотов несёт новую, независимую от БИНС информацию, которая порождает повышенный контраст обучающего сигнала для физических остатков при дообучении на малых данных.

3.2.3 Обзор релевантной литературы

Дополнительное обоснование дают современные исследования гибридного моделирования и оценки состояния.

Работа NeuroBEM [29] представляет гибридную аэродинамическую модель квадрокоптера, сочетающую теорию элемента лопасти (BEM) с нейросетевыми коррекциями. Авторы показывают, что зависимость коэффициентов тяги и момента от относительной скорости набегающего потока делает простую квадратичную модель недостаточной в динамических режимах и при ветровых возмущениях. Измерения оборотов винтов (или команд актуаторов) позволяют значительно точнее оценивать текущие силы и моменты, что напрямую улучшает качество оценки состояния и снижает дрейф.

В исследовании actuator-informed моделей оценки состояния [30] продемонстрировано, что включение телеметрии оборотов и моментов двигателей в гибридную архитектуру позволяет существенно снизить ошибку инерциальной оценки в условиях внешних возмущений и неопределённости параметров платформы. Авторы отмечают, что сигналы актуаторов обеспечивают дополнительный физический supervision, особенно эффективный при смене динамического режима.

Статья [31] посвящена применению последовательностных моделей с селективными пространствами состояний для задач инерциальной навигации с использованием сигналов актуаторов. Показано, что actuator-informed подходы обеспечивают лучшее обобщение при ограниченном объёме данных и при дообучении на новых сценариях — именно та ситуация, которая возникает при адаптации модели к новому промышленному объекту.

Реальный датасет AI-IO [32] содержит синхронизированные записи IMU и измерений оборотов роторов, полученные на реальном квадрокоптере. Авторы экспериментально подтверждают, что наличие RPM-сигнала позволяет значительно повысить точность одометрии и оценки состояния по сравнению с чисто IMU-based методами в реальных условиях эксплуатации, включая режимы с ветровыми возмущениями.

Наконец, работа по hybrid aerodynamic wind-aware моделям [33] убедительно показывает, что учёт телеметрии актуаторов критически важен для точной компенсации ветровых возмущений и поддержания физической согласованности

модели при резких манёврах. Авторы подчёркивают, что без сигналов оборотов винтов гибридные модели теряют значительную часть своей регуляризационной способности в агрессивных режимах.

3.3 Предлагаемая нейронная сеть

На основании проведённого анализа установлено, что сигнал оборотов несущих винтов несёт информацию об управляющих воздействиях, недоступную БИНС в режиме компенсации порывов ветра, и обеспечивает повышенный контраст обучающего сигнала при дообучении на малых данных именно в агрессивном динамическом режиме.

Архитектура предлагаемой нейронной сети состоит из следующих блоков: входной вектор признаков, кодировщик на основе пространственно-временной модели состояния (блок линейной проекции, входной блок линейной нормализации, 3 слоя пространственно-временной модели [24], выходной блок линейной нормализации), выходной вектор признаков.

Входной вектор $\mathbf{x}_t \in \mathbb{R}^{17}$ на каждом временном шаге t определяется следующим набором данных:

$$\mathbf{x}_t = [\mathbf{a}_t, \boldsymbol{\omega}_t, \boldsymbol{\Phi}_t, \mathbf{p}_t^{gps}, \mathbf{n}_t, m_t], \quad (3.2)$$

где $\mathbf{a}_t = [a_x, a_y, a_z]^T$ — линейное ускорение БИНС; $\boldsymbol{\omega}_t = [\omega_x, \omega_y, \omega_z]^T$ — угловая скорость; $\boldsymbol{\Phi}_t = [\varphi, \theta, \psi]^T$ — углы ориентации; $\mathbf{p}_t^{gps}$ — псевдопозиция ГНСС (при потере сигнала обнуляется); $\mathbf{n}_t = [n_1, n_2, n_3, n_4]^T$ — обороты четырёх роторов; $m_t \in \{0, 1\}$ — маска доступности ГНСС.

Выходной вектор $\hat{\mathbf{y}}_t \in \mathbb{R}^{14}$ формируется конкатенацией четырёх групп предсказаний, извлечённых из скрытого представления $\mathbf{H}$ линейными проекциями:

$$\hat{\mathbf{y}}_t = [\hat{\mathbf{v}}_t, \hat{\mathbf{q}}_t, \hat{\mathbf{a}}_t, \boldsymbol{\tau}], \quad (3.3)$$

где $\hat{\mathbf{v}}_t \in \mathbb{R}^3$ — предсказанная линейная скорость; $\hat{\mathbf{q}}_t \in [-1, 1]^4$ — нормированный кватернион ориентации; $\hat{\mathbf{a}}_t \in \mathbb{R}^3$ — линейное ускорение в связанной системе координат; $\boldsymbol{\tau}_{int,t} \in \mathbb{R}^4$ — промежуточное представление управляющих моментов, используемое в динамическом функционале потерь.

Из скрытого представления $\mathbf{H}$ компоненты выходного вектора извлекаются посредством линейных проекций:

$$\hat{\mathbf{v}} = \mathbf{H}\mathbf{W}_v \in \mathbb{R}^{T \times 3}, \quad (3.4)$$

$$\hat{\mathbf{q}} = \frac{\mathbf{H}\mathbf{W}_q}{\|\mathbf{H}\mathbf{W}_q\|}, \quad \hat{\mathbf{q}} \in [-1, 1]^{T \times 4}, \quad (3.5)$$

$$\hat{\mathbf{a}} = \mathbf{H}\mathbf{W}_a \in \mathbb{R}^{T \times 3}, \quad (3.6)$$

$$\boldsymbol{\tau}_{int} = \mathbf{H}\mathbf{W}_\tau \in \mathbb{R}^{T \times 4}. \quad (3.7)$$

Нормировка кватерниона гарантирует принадлежность многообразию S^3 .

Ключевое отличие предлагаемой нейронной сети от остальных моделей заключается в функции потерь, связывающей предсказания модели с законами динамики квадрокоптера.

Итоговая функция потерь:

$$\mathcal{L}_{DF} = \lambda_1 \mathcal{L}_{traj} + \lambda_2 \left\| \frac{\boldsymbol{\varepsilon}_F}{mg} \right\|^2 + \lambda_3 \left\| \frac{\boldsymbol{\varepsilon}_\tau}{\sigma_\tau} \right\|^2, \quad (3.8)$$

где $\|\cdot\|^2$ обозначает среднеквадратическую ошибку по компонентам вектора; mg — нормировочный множитель, приводящий невязку тяги к безразмерному виду; σ_τ — стандартное отклонение момента на текущем батче. Весовые коэффициенты $\lambda_1 = 1,0$, $\lambda_2 = \lambda_3 = 3 \times 10^{-4}$ подобраны на валидационной выборке датасета А из условия соизмеримости слагаемых: физические штрафные члены вносят регуляризующий вклад, не подавляя основной траекторный сигнал на начальных эпохах обучения. Базовая нейронная сеть использует только $\mathcal{L}_{traj}$ (то есть $\lambda_2 = \lambda_3 = 0$); обобщённая нейронная сеть включает регуляризатор без прямой зависимости от n_i .

При высокой дисперсии n_i значение $F_z(t)$ значительно изменяется во времени, а штрафные слагаемые $\|\boldsymbol{\varepsilon}_F\|^2$ и $\|\boldsymbol{\varepsilon}_\tau\|^2$ создают повышенный контраст обучающего сигнала при дообучении, ограничивая пространство допустимых весов модели именно в тех режимах, где переобучение на малых данных наиболее вероятно.

Траекторная составляющая функции потерь $\mathcal{L}_{traj}$ включает три слагаемых:

$$\mathcal{L}_{traj} = \underbrace{\|\hat{\mathbf{v}} - \mathbf{v}\|^2}_{\text{ошибка скорости}} + 0,5 \underbrace{\mathcal{L}_q(\hat{\mathbf{q}}, q)}_{\text{ошибка ориентации}} + \lambda_{pos} \underbrace{\|\hat{p} - p\|^2}_{\text{ошибка позиции}}, \quad (3.9)$$

где $\hat{\mathbf{v}}$, $\mathbf{v}$ — предсказанная и истинная скорость; $\hat{\mathbf{q}}$, q — предсказанный и истинный кватернион ориентации; $\hat{p}$, p — предсказанная и истинная траектория, восстановленная интегрированием скорости методом Эйлера; $\mathcal{L}_q = \|\hat{\mathbf{q}} - q\|^2 + 0,5 (\|\hat{\mathbf{q}}\| - 1)^2$

— функция потерь по кватерниону, включающая штраф за отклонение от единичной нормы; $\lambda_{pos} = 0,15$ — весовой коэффициент позиционного слагаемого.

Общая схема предлагаемой нейронной сети представлена на рисунке 3.2.




Рисунок 3.2 — Архитектура предлагаемой нейронной сети.

Глава 4. Экспериментальное исследование и сравнительный анализ эффективности предложенной системы

4.1 Эксперимент дообучения рассматриваемых нейронных сетей

Для адаптации ранее обученной нейронной сети в реальных условиях оператор располагает возможностью провести 1–2 калибровочных полёта в целевом районе перед основной миссией. Целью данного эксперимента является построение зависимости между долей дообучающего датасета и точностью восстановленной траектории RMSE. По результатам эксперимента предлагается сводная рекомендательная таблица с зависимостью между длинами потери сигнала ГНСС и долями дообучающей выборки для предлагаемой нейронной сети.

4.1.1 Характеристика экспериментальных данных

Эксперименты проводились на двух датасетах, полученных в симуляторе PX4/Gazebo [34]:

- **Датасет А (стандартный режим):** полёты в спокойных условиях с ограниченными манёврами; номинальный сценарий горизонтального облёта промышленного объекта. Все четыре модели предобучались на данном датасете.
- **Датасет В (режим компенсации порывов ветра):** полёты с резкими изменениями скорости и направления, имитирующими компенсацию порывов ветра вблизи промышленной конструкции. В данном сценарии дисперсия оборотов двигателей максимальна. Общая продолжительность составила 8 мин 42 с.

Оба датасета содержат синхронизированные данные БИНС (200 Гц), ГНСС (5 Гц), телеметрию оборотов двигателей (200 Гц) и опорные траектории от внутреннего состояния симулятора. Предобучение выполнялось на датасете А, дообучение — на подмножествах датасета В. Ключевые статистики датасетов приведены в таблице 4.

Таблица 4 — Сравнение статистических характеристик датасетов А и В
Table 2. Statistical characteristics of datasets A and B

Показатель	Датасет А	Датасет В	Отношение В/А
<i>Линейная скорость $\mathbf{v}$, м/с</i>			
среднее	1,790	2,332	1,30
std	0,767	2,097	2,74
p95	3,253	6,743	2,07
<i>Горизонтальное ускорение a_{xy}, м/с²</i>			
среднее	0,131	0,293	2,24
std	0,088	0,263	3,00
p95	0,313	0,832	2,66
<i>Угловая скорость $\boldsymbol{\omega}$, рад/с</i>			
среднее	0,321	0,292	0,91
p95	0,913	0,942	1,03
<i>Средние обороты роторов, об/мин</i>			
среднее	14 545	11 566	0,80
std	990	5971	6,03
p95	16 150	15 265	0,95

Данные таблицы 4 позволяют сформулировать три ключевых вывода. Во-первых, средняя скорость в датасете В на 30% выше, а горизонтальное ускорение в 2,2 раза; угловые скорости практически идентичны (отношение 0,91–1,03), что означает: режим компенсации порывов ветра не сводится к простому ускорению платформы. Во-вторых, стандартное отклонение оборотов в датасете В в **6,0 раза** превышает таковое в датасете А (5971 против 990 об/мин), тогда как среднее значение оборотов ниже (11566 против 14545 об/мин): при компенсации ветровых возмущений квадрокоптер совершает частые асимметричные изменения тяги отдельных роторов, сохраняя суммарную тягу вблизи $F_z \approx mg$. В-третьих, БИНС измеряет суммарное специфическое ускорение и не различает дифференциальные изменения тяги роторов, тогда как телеметрия оборотов непосредственно фиксирует эти изменения. Таким образом, сигналы БИНС и оборотов несут взаимодополняющую информацию: БИНС обеспечивает достаточную точность при

умеренных манёврах, сигнал оборотов повышает контраст обучающего сигнала при дообучении именно там, где БИНС теряет информативность.

4.1.2 Результаты дообучения при ограниченных данных

Из датасета В случайно отбирались подмножества долей 10, 25, 50, 75 и 100%. Число шагов оптимизации фиксировалось на уровне 2000 для всех долей, что исключает влияние числа итераций на результат и обеспечивает сопоставимость условий дообучения. Оценка проводилась на 10 случайных сегментах датасета В методом среднеквадратического отклонения без совмещения систем координат. Набор результатов охватывает 4 модели $\times$ 5 долей $\times$ 6 длительностей потери сигнала (3, 10, 30, 60, 120 и 240 с), что соответствует 120 численным значениям RMSE.

На основе полученных данных выявлен лучший и наиболее сложный сценарий для предлагаемой нейронной сети. В таблице 5 представлены результаты при потере сигнала 60 с (лучший сценарий). При такой длительности накопленная ошибка БИНС ещё не достигает критических значений, и все четыре модели демонстрируют сравнительно малые RMSE. Тем не менее предлагаемая нейронная сеть стабильно превосходит базовую при всех долях датасета В.

Таблица 5 — RMSE (м) при дообучении на подмножествах, потеря сигнала ГНСС 60 с (лучший сценарий)

Table 3. RMSE (m) for fine-tuning on subsets, GNSS outage 60 s (best-case scenario)

Доля, %	предлагаемая нейронная сеть	обобщённая нейронная сеть	базовая нейронная сеть	Transformer
10	1,973	2,163	2,985	5,800
25	2,232	2,031	3,085	6,797
50	2,017	1,739	3,477	7,488
75	3,029	2,457	3,454	8,737
100	3,647	3,777	6,994	5,657

В таблице 6 представлены результаты при потере сигнала 240 с (наиболее сложный сценарий). При такой длительности ошибка БИНС нарастает до десятков метров, и различия в регуляризующих свойствах моделей проявляются в наибольшей степени. Transformer демонстрирует стабильно высокую ошибку при всех долях данных, что объясняется квадратичной сложностью механизма внимания при обработке длинных последовательностей навигационных данных.

Таблица 6 — RMSE (м) при дообучении на подмножествах, потеря сигнала ГНСС 240 с (наиболее сложный сценарий)

Table 4. RMSE (m) for fine-tuning on subsets, GNSS outage 240 s (worst-case scenario)

Доля, %	предлагаемая нейронная сеть	обобщённая нейронная сеть	базовая нейронная сеть	Transformer
10	14,273	19,985	36,458	22,315
25	9,409	8,173	13,016	20,267
50	10,594	13,412	21,823	19,593
75	15,069	20,264	32,100	20,963
100	9,734	11,149	16,978	20,481

4.1.3 Сводная таблица по всем режимам

Таблица 7 представляет полный обзор результатов предлагаемой нейронной сети по всем 6 длинам потери сигнала и всем 5 долям дообучающего датасета. Данная таблица может служить операционным руководством для оценки требуемого объёма калибровочного полёта в новых динамических условиях.

При коротких потерях сигнала (3–30 с) предлагаемая нейронная сеть обеспечивает RMSE ниже 2,5 м при любой доле обучающих данных. При длительных потерях (120–240 с) оптимальная доля данных составляет 25–50%, что соответствует 2–4 мин калибровочных полётов перед миссией.

Таблица 7 — RMSE (м) предлагаемой нейронной сети по всем длинам потери сигнала и долям датасета (сводная таблица)

Table 5. RMSE (m) of the proposed neural network for all outage durations and dataset fractions (summary)

Доля датасета, %	Длина потери сигнала ГНСС, с					
	3	10	30	60	120	240
10	0,141	0,511	1,722	1,973	6,723	14,273
25	0,133	0,785	2,463	2,232	7,264	9,409
50	0,124	0,731	1,764	2,017	6,689	10,594
75	0,095	0,690	2,150	3,029	5,505	15,069
100	0,104	0,571	1,936	3,647	9,458	9,734

4.1.4 Визуализация результатов

Рисунок 4.1 иллюстрирует RMSE всех четырёх моделей при потере сигнала 240 с в зависимости от доли обучающих данных. Предлагаемая нейронная сеть и обобщённая нейронная сеть устойчиво превосходят базовую при всех долях; Transformer сохраняет стабильно высокую ошибку и практически не улучшается с увеличением объёма данных дообучения.

4.1.5 Анализ результатов

При потере сигнала 240 с предлагаемая нейронная сеть превосходит базовую без исключения во всём диапазоне долей (табл. 6). При 10% данных (≈ 40 с полёта) достигается $RMSE = 14,3$ м, что лучше, чем у базовой нейронной сети на полном датасете ($RMSE = 17,0$ м): физический регуляризатор компенсирует нехватку десятикратного объёма обучающих примеров за счёт повышенного контраста обучающего сигнала при дообучении.

Наилучший результат предлагаемой нейронной сети при потере сигнала 240 с достигается при доле 25%: $RMSE = 9,4$ м, что на 31% лучше, чем при 100% ($RMSE = 9,7$ м), и в 1,8 раза лучше, чем базовая нейронная сеть при полных дан-




Рисунок 4.1 — RMSE (м) четырёх моделей в зависимости от доли обучающих данных при потере сигнала ГНСС 240 с. Ось X : доля обучающих данных (%); ось Y : RMSE (м). Столбцы: предлагаемая нейронная сеть (синий), обобщённая нейронная сеть (зелёный), базовая нейронная сеть (красный), Transformer (оранжевый).
Figure 4. RMSE (m) of the four models vs. training data fraction, GNSS outage 240 s.
X-axis: fraction of training data (%); Y-axis: RMSE (m).

ных. Практический вывод: двухминутного калибровочного полёта достаточно для достижения оптимальной точности предлагаемой нейронной сети в целевом динамическом режиме.

Базовая нейронная сеть при потере сигнала 240 с демонстрирует немонотонную зависимость RMSE от доли данных: $36,5 \rightarrow 13,0 \rightarrow 21,8 \rightarrow 32,1 \rightarrow 17,0$ м, характерную для переобучения при малых долях с последующей деградацией при промежуточных значениях. Предлагаемая нейронная сеть демонстрирует устойчивую зависимость: $14,3 \rightarrow 9,4 \rightarrow 10,6 \rightarrow 15,1 \rightarrow 9,7$ м — улучшение на диапазоне 10–25% с последующей конвергенцией к оптимуму при 100%.

Обобщённая нейронная сеть занимает промежуточное положение при потере сигнала 240 с, однако при доле 25% незначительно превосходит предлагаемую нейронную сеть (RMSE 8,2 против 9,4 м). Это объясняется тем, что при указанной доле данных косвенный регуляризатор оказывается несколько менее подвержен переобучению, чем более специфичный динамический функционал. При малых долях (10%) и полном датасете (100%) предлагаемая нейронная сеть уверенно лидирует.

4.2 Обсуждение

4.2.1 Физическая интерпретация результатов

Ключевой вывод экспериментов состоит в том, что преимущество предлагаемой нейронной сети определяется не кинематическими различиями датасетов, а динамикой сигнала оборотов двигателей. Как следует из таблицы 4, средняя скорость платформы в режиме компенсации порывов ветра выше лишь на 30%, горизонтальное ускорение по p_{95} в 2,7 раза. В то же время стандартное отклонение оборотов возрастает в 6,0 раз (5971 против 990 об/мин), причём среднее значение оборотов даже ниже (11566 против 14545 об/мин). Парадоксальность этого результата объясняется механикой компенсации ветровых возмущений: при порывах квадрокоптер поддерживает заданное положение, совершая быстрые и асимметричные изменения тяги без существенного изменения суммарной тяги ($F_z \approx mg$), тогда как дифференциальные обороты Δn_i значительно возрастают. Именно эти флуктуации порождают повышенный контраст обучающего сигнала при дообучении по слагаемым $\|\varepsilon_F\|^2$ и $\|\varepsilon_\tau\|^2$ в (3.8), ограничивая пространство допустимых весов модели и предотвращая переобучение при ограниченном числе траекторных примеров.

4.2.2 Сравнение с методами без физического ограничения

Существующие методы компенсации смены динамического режима при ограниченных данных, как правило, опираются на перенос обучения без физических ограничений. Обобщённая нейронная сеть [28] сделала шаг вперёд по сравнению с базовой, введя кинематические ограничения без явной зависимости от оборотов несущих винтов. Предлагаемая нейронная сеть развивает этот подход и обладает двумя дополнительными преимуществами. Во-первых, физический регуляризатор на основе закона тяги не требует дополнительных размеченных данных: достаточно телеметрии оборотов несущих винтов, доступной на борту. Во-вторых, регуляризатор автоматически масштабируется с дисперсией оборотов

несущих винтов, то есть повышает контраст обучающего сигнала при дообучении именно в условиях повышенного риска переобучения.

4.2.3 Практическая применимость

Результаты эксперимента позволяют сформулировать конкретный операционный протокол. Перед выполнением инспекционной миссии в новом динамическом режиме оператор выполняет **один калибровочный полёт продолжительностью 2 мин.** Этого достаточно для дообучения предлагаемой нейронной сети (25% от полного датасета B), при котором RMSE составляет 9,4 м при потере сигнала 240 с — в 1,8 раза лучше базовой модели на полном датасете.

Стоимость вычислений при 2000 шагах оптимизации не превышает нескольких минут на бортовом нейронном процессоре (NPU), что делает дообучение практически реализуемым непосредственно в полевых условиях.

4.2.4 Ограничения и направления верификации

Все эксперименты проводились в PX4/Gazebo, который не воспроизводит в полной мере нестационарное смещение реальных МЭМС-датчиков и аэродинамические эффекты близости металлических конструкций. Перенос результатов на реальную платформу требует верификации на аппаратном стенде.

Параметры физической модели (k , b , m , Γ) зафиксированы для конкретного симулированного квадрокоптера. Применение к платформам с иными аэродинамическими параметрами потребует перекалибровки коэффициентов.

Используемая метрика не учитывает систематические ошибки абсолютного дрейфа при длительных полётах с несколькими участками потери сигнала. Для сценариев длительностью более 10 мин требуются дополнительные исследования с метриками абсолютной позиционной точности.

4.3 Многоплатформенное обобщение одометрии на основе физически информированной нейронной сети с использованием оборотов двигателей

4.3.1 Постановка задачи и исследовательские вопросы

В предыдущих главах были проведены эксперименты по валидации предложенной физически информированной нейронной сети с использованием оборотов двигателей ФИ НС-ПСПС на одной симулированной платформе квадрокоптера Holybro X500 V2 (масса $m = 2,0 \text{ kg}$), которая далее именуется *базовой* платформой.

Однако практическая система инерциальной одометрии должна быть применима к широкому спектру конфигураций квадрокоптеров без необходимости полного переобучения с нуля. В данной главе исследуется, насколько хорошо предобученная модель ФИ НС-ПСПС обобщается на платформы со значительно отличающейся массой и моментами инерции, а также достаточно ли небольшого объёма данных для дообучения под конкретную платформу, чтобы восстановить точность.

Рассматриваются три исследовательских вопроса:

RQ1 (Платформенный разрыв). Увеличивается ли СКО (RMSE) монотонно с ростом отношения $m_{\text{robot}}/m_{\text{base}}$ и насколько велика деградация точности при коротких интервалах потери сигнала ГНСС, когда дрейф интегрирования ещё остаётся управляемым?

RQ2 (Агрессивность полёта). Помогает или вредит агрессивное маневрирование (которое приводит к большим дифференциалам оборотов двигателей) точности восстановления траектории после дообучения?

RQ3 (Стратегия дообучения). Что лучше: дообучать отдельную модель под каждую платформу (специализированная стратегия) или одну общую модель на всех платформах одновременно (обобщённая стратегия) при одинаковом суммарном бюджете обучения?

4.3.2 Описание экспериментальной установки

В данном эксперименте использовались три конфигурации квадрокоптера на основе модели `x500_base` из PX4 SITL Gazebo [35] путём изменения параметров инерции твёрдого тела при сохранении идентичного оборудования двигателей. В таблице 8 приведены ключевые физические параметры.

Таблица 8 — Параметры симулированных платформ. Значения моментов инерции масштабируются как отношение масс $\times$ (отношение длин плеч)² относительно базовой платформы. Коэффициент тяги k_T для `x500_heavy` увеличен для обеспечения запаса тяги к весу примерно 20 %, что соответствует более мощной силовой установке тяжёлого аппарата.

Модель	Назначение	m [kg]	l [m]	$I_{xx} = I_{yy}$ [kg · m ²]	I_z
<code>x500</code>	Базовая платформа	2.0	0.174	0.02167	
<code>x500_light</code>	Лёгкий разведывательный	1.0	0.1381	0.00683	
<code>x500_heavy</code>	Носитель полезной нагрузки	3.5	0.2097	0.05507	

Платформенный разрыв $\Delta = m_{\text{robot}}/m_{\text{base}}$ составляет $0,5\times$, $1,0\times$ и $1,75\times$ для лёгкой, базовой и тяжёлой конфигураций соответственно.

Платформа `x500_light` соответствует компактным исследовательским квадрокоптерам класса 250–330 мм с массой 0,8–1,2 kg, а `x500_heavy` представляет ту же раму с полезной нагрузкой массой 1,5 kg (например, LiDAR или тепловизор).

4.3.3 Профили полётных миссий

Три профиля полётных миссий сгенерированы с помощью скрипта `mission_generate_v2.py` [**mission_gen_v2**]: *спокойный* (скорость 1–8 m/s, поворот ≥ 0), *средний* (скорость 5–12 m/s, поворот ≥ 45) и *агрессивный* (скорость 10–15 m/s, поворот ≥ 90).

Каждый профиль содержит 50 точек маршрута в радиусе 70 m от точки взлёта на высотах от 5 m до 45 m. Каждая комбинация платформы и профиля вы-

полнена в PX4 SITL с Gazebo 8, в результате чего получено девять лог-файлов `.ulg` (таблица 21).

Таблица 9 — Размеры датасетов после удаления строк с контактом с землёй (высота < 1 m) и отбрасывания 2 с переходных процессов при взлёте и посадке.

Платформа	Спокойный	Средний	Агрессивный
x500	43 487	52 640	79 670
x500_light	43 766	53 085	80 405
x500_heavy	43 165	51 909	78 966

4.3.4 Архитектура нейронной сети и протокол дообучения

Архитектура MambaRPM PINN [**mamba_pinn_ours**, 36] с размерностью $d_{\text{model}} = 192$, 3 слоями Mamba и 17-мерным входом (гироскоп, акселерометр, магнитометр, кватернион, четыре оборота двигателей) инициализируется из чек-пойнта, предобученного на большом объёме синтетических данных Gazebo с базовой платформы x500.

Сравниваются две стратегии дообучения:

- **Отдельная модель под платформу**: три независимые модели, каждая дообучается на трёх профилях целевой платформы (примерно 175 000 последовательностей на платформу).
- **Объединённая модель**: одна общая модель дообучается одновременно на всех девяти датасетах (примерно 527 000 последовательностей).

Обе стратегии используют 5 эпох обучения, оптимизатор AdamW ($\text{lr} = 10^{-5}$, $\text{weight decay} = 10^{-5}$), размер батча 256 и вес физической составляющей потерь $\lambda_{\text{phys}} = 3 \times 10^{-4}$ с невязками крутящего момента, информированными оборотами двигателей.

Физические параметры платформы (масса, длина плеча, коэффициенты тяги и сопротивления) подставляются в буферы модели перед дообучением.

4.3.5 Протокол оценки

Для каждого из девяти лог-файлов полётов выбирается $n = 10$ случайных начальных позиций. Из каждой начальной позиции интегрируется предсказанная скорость на интервалах $\tau \in \{3, 5, 10, 30, 60, 120\}$ с имитируемой потери сигнала ГНСС. Сравнение ошибок осуществляется по двум метрикам СКО и АОТ, ранее описанных в уравнениях ?? и ??

где $\hat{\mathbf{p}}_k$ — интегрированная оценка позиции, а $\mathbf{p}_k$ — истинная локальная позиция из `vehicle_local_position`, сэмплированная с шагом $\Delta t = 10$ ms.

4.4 Сходимость обучения

В таблице 10 приведены значения validation loss и ошибки физических ограничений (PCE) после 5 эпох дообучения для стратегии отдельных моделей под платформу.

Все три платформы сходятся стабильно, с уменьшением validation loss примерно на 73–75 % относительно первой эпохи.

Таблица 10 — Сходимость дообучения отдельных моделей под платформу. PCE — средняя величина невязки силы по Ньютону на 1-й и 5-й эпохах.

Платформа	Val ep 1	Val ep 5	PCE ep 1 [N]	PCE ep 5 [N]
x500	0.259	0.066	44.6	40.9
x500_light	0.273	0.072	46.1	43.0
x500_heavy	0.262	0.071	47.2	39.1

На тяжёлой платформе наблюдается наибольшее снижение PCE (17,2 %), а на лёгкой — наименьшее (6,6 %). Это согласуется с гипотезой, что более тяжёлые дроны генерируют большие дифференциалы оборотов двигателей во время манёвров, обеспечивая более сильный обучающий сигнал для физической составляющей потерь [37].

4.5 Результаты

4.5.1 Влияние длительности потери сигнала

На рисунке 4.2 показана зависимость СКО от длительности потери сигнала для стратегии отдельных моделей под платформу по всем платформам и профилям миссий.

Ошибка растёт приблизительно линейно с $\sqrt{\tau}$, что согласуется с моделью случайного блуждания при интегрировании скорости [**inertial_nav_drift**]. При коротких потерях сигнала ($\tau = 3$ s) СКО остаётся ниже 10 m для всех конфигураций; при $\tau = 120$ s она достигает диапазона 68–160 m, отражая неограниченный дрейф в отсутствие коррекций ГНСС.

Рисунок 4.2 — СКО в зависимости от длительности потери сигнала для стратегии дообучения отдельных моделей под платформу. Каждый подграфик соответствует одной комбинации платформы и профиля. Планки ошибок показывают стандартное отклонение по 10 случайным сегментам.

Рисунок 4.3 — СКО в зависимости от длительности потери сигнала для стратегии объединённой модели. Базовая платформа (x500, зелёный цвет) демонстрирует существенно более высокую ошибку по сравнению со стратегией отдельных моделей, что указывает на компромисс точности базовой платформы ради охвата нескольких платформ.

4.5.2 Влияние платформенного разрыва (RQ1)

На рисунке 4.4б показана средняя СКО при $\tau = 30$ s в зависимости от платформенного разрыва Δ для обеих стратегий.

Стратегия отдельных моделей (синие кружки) демонстрирует U-образный профиль: минимальная средняя СКО 32,2 m достигается на базовой платформе

($\Delta = 1,0\times$), тогда как на лёгкой ($\Delta = 0,5\times, 45,0\text{ m}$) и тяжёлой ($\Delta = 1,75\times, 44,0\text{ m}$) конфигурациях ошибка примерно на 37 % выше.

Это подтверждает, что дообучение под конкретную платформу приближает модель к оптимальной для каждой целевой платформы, однако оба отклонения от массы предобучения приводят к заметному снижению точности.

а) $\tau = 10\text{ s}$

б) $\tau = 30\text{ s}$

в) $\tau = 60\text{ s}$

Рисунок 4.4 — Средняя СКО в зависимости от платформенного разрыва $\Delta = m/m_{\text{base}}$ при трёх длительностях потери сигнала. Стратегия отдельных моделей (сплошная синяя линия): U-образный профиль с минимумом на платформе предобучения. Объединённая стратегия (пунктирная оранжевая линия): инвертированный пик при $\Delta = 1,0\times$, вызванный сдвигом распределения при смещении данных всех трёх платформ.

Объединённая стратегия (оранжевые квадраты) демонстрирует *противоположную* картину: СКО максимальна для базовой платформы (77,9 m при $\tau = 30\text{ s}$, в 2,6 раза хуже, чем при стратегии отдельных моделей), но сопоставима со стратегией отдельных моделей для лёгкой и тяжёлой платформ.

Это происходит потому, что включение данных лёгкой и тяжёлой платформ в общий обучающий набор действует как форма доменной рандомизации, повышая устойчивость к нештатной динамике, но одновременно ухудшает точность на номинальной платформе из-за конфликтующих градиентов.

4.5.3 Влияние профиля полёта (RQ2)

На рисунке 4.5б показана СКО при $\tau = 30\text{ s}$ в разбивке по профилям миссий для стратегии отдельных моделей под платформу.

а) $\tau = 10\text{ s}$

б) $\tau = 30\text{ s}$

в) $\tau = 60\text{ s}$

Рисунок 4.5 — Влияние профиля на СКО для стратегии отдельных моделей под платформу. Каждая группа столбцов показывает спокойный (зелёный), средний (оранжевый) и агрессивный (красный) профили для одной платформы.

Для базовой платформы СКО монотонно растёт с увеличением агрессивности профиля: спокойный 23,1 м → средний 30,1 м → агрессивный 43,3 м (отношение $1,87\times$).

Это ожидаемое поведение — агрессивный полёт включает быстрые смены направления, которые быстрее накапливают ошибку интегрирования.

Для тяжёлой платформы влияние профиля существенно меньше (отношение $1,05\times$), а для лёгкой — промежуточное (отношение $1,30\times$).

Правдоподобное объяснение: высокая инерция тяжёлого дрона естественным образом ограничивает угловое ускорение, делая эффективную сложность траектории более похожей между профилями. Большие дифференциалы оборотов двигателей при агрессивных манёврах тяжёлого дрона обеспечивают более сильный сигнал физической составляющей потерь во время дообучения, частично компенсируя более высокую номинальную ошибку на агрессивных миссиях.

4.5.4 Сравнение стратегий дообучения (RQ3)

В таблице 11 приведены значения СКО для трёх ключевых длительностей потери сигнала при обеих стратегиях.

Стратегия отдельных моделей последовательно превосходит объединённую стратегию для базовой и тяжёлой платформ. Для лёгкой платформы объединённая стратегия лучше на спокойных и средних профилях, но результаты сходятся на агрессивном профиле.

Эта асимметрия объясняется тем, что динамика лёгкой платформы сильнее всего отличается от распределения предобучения (наименьшая масса, самое короткое плечо, самые низкие обороты в режиме висения), поэтому обучение совместно с данными тяжёлой платформы эффективно расширяет многообразие динамики. Для тяжёлой платформы динамика базовой платформы предобучения уже достаточно близка, поэтому специализированное дообучение предпочтительнее.

Таблица 11 — Средняя СКО (м) по трём профилям миссий. Жирным выделена лучшая стратегия для каждой комбинации платформы и длительности. † Объединённая стратегия использует веса предобучения $\times 500$ без дополнительного дообучения на данных базовой платформы в случае стратегии отдельных моделей.

Платформа	Профиль	$\tau = 10\text{ s}$		$\tau = 30\text{ s}$	
		Отдельные	Объединённая	Отдельные	Объединённая
$\times 500$	спокойный	14.3	24.4	23.1	65.6
	средний	16.2	25.0	30.1	78.7
	агрессивный	19.6	24.2	43.3	89.2
$\times 500_light$	спокойный	14.0	12.5	39.3	31.7
	средний	20.5	16.8	44.7	39.8
	агрессивный	19.4	21.1	51.1	47.0
$\times 500_heavy$	спокойный	17.4	18.9	41.6	45.6
	средний	21.3	19.4	46.6	46.6
	агрессивный	19.0	21.5	43.8	44.4

4.6 Обсуждение

Обобщаемость на разные платформы. Результаты демонстрируют, что MambaRPM PINN, предобученная на одной платформе массой 2,0 kg, может быть адаптирована к платформам с массой $0,5\times$ и $1,75\times$ с использованием менее чем 50 000 последовательностей на платформу и 5 эпох дообучения.

Полученная СКО при $\tau = 10\text{ s}$ находится в диапазоне 14–22 m для всех конфигураций — в пределах 30 % от точности самой базовой платформы (14–20 m).

Это свидетельствует о том, что физически информированная индуктивная предвзятость потери крутящего момента на основе оборотов двигателей осмысленно переносится между платформами, обеспечивая регуляризационный сигнал, который компенсирует сдвиг распределения масс.

Роль агрессивности полёта. Вопреки первоначальным ожиданиям, агрессивные данные для дообучения не всегда улучшают точность.

Для базовой платформы агрессивные миссии приводят к увеличению СКО в $1,87\times$ раз при $\tau = 30\text{ s}$, .

Однако для тяжёлой платформы эффект профиля практически исчезает (отношение $1,05\times$), что согласуется с более высокой инерцией, подавляющей эффективное угловое ускорение, и с более сильным сигналом физической составляющей потерь при агрессивных манёврах тяжёлого дрона, частично корректирующим смещение предсказаний.

4.7 Обобщение без дообучения ФИ-НС-ПСПС на платформы различной массы и динамики

В предыдущих разделах главы было показано, что предлагаемая физически информированная нейросетевая система позиционирования (ФИ-НС-ПСПС) на базе архитектуры Mamba с регуляризатором на основе оборотов роторов обеспечивает точную инерциальную одометрию при перерывах в приёме сигналов ГНСС на квадрокоптере Holybro X500 V2. Однако для практического внедрения принципиально важно понять, насколько эта система способна обобщаться на другие платформы без дополнительного обучения.

Большинство современных подходов к восстановлению траектории по данным инерциальных датчиков фактически запоминают статистические особенности шумов и динамики конкретного аппарата. Эти особенности напрямую зависят от массы, моментов инерции и аэродинамических характеристик, поэтому модель, обученная на одном квадрокоптере, обычно не может быть напрямую перенесена на другой без дообучения.

В отличие от чисто data-driven решений, в ФИ-НС-ПСПС явно присутствует физическое ограничение, соответствующее второму закону Ньютона:

$$m \mathbf{a} = \sum_{i=1}^4 k_T \omega_i^2 \hat{\mathbf{z}}_{\text{body}} - b_{\text{drag}} m \mathbf{v} + m \mathbf{g}, \quad (4.1)$$

где m — масса платформы, k_T — коэффициент тяги мотора, ω_i — угловые скорости роторов, b_{drag} — коэффициент аэродинамического сопротивления, $\mathbf{v}$ — скорость центра масс в связанной системе координат, $\mathbf{g}$ — ускорение свободного падения.

Эта зависимость имеет одинаковую структуру для любого жёсткого квадрокоптера; изменяются лишь числовые значения массы и коэффициента тяги. Гипотеза, проверяемая в данном разделе, заключается в том, что нейросетевая часть системы в первую очередь выучивает отображение, определяемое именно этой инвариантной физической структурой, а влияние массы на результат поглощается через наблюдаемые сигналы оборотов роторов.

Для проверки гипотезы был проведён эксперимент по обобщению без дообучения. Предобученная ФИ-НС-ПСПС оценивалась на трёх платформах, охватывающих диапазон масс 3,5 раза, и на трёх профилях полёта с различной агрессивностью — без какого-либо дообучения под целевую платформу.

4.7.1 Описание экспериментальных платформ

В качестве базовой использовалась модель Holybro X500 V2 — та же платформа, на которой проводились все предыдущие эксперименты. На её основе были созданы две дополнительные виртуальные платформы путём изменения только инерционных параметров при сохранении неизменными характеристик моторов, пропеллеров и состава датчиков. Такой подход позволяет изолировать влияние массы и инерции на точность одометрии.

Лёгкая платформа. Масса рамы 1,0 кг, длина плеча 0,138 м. Соответствует минимальной комплектации X500 V2 без полезной нагрузки и близка по характеристикам к компактным исследовательским квадрокоптерам класса 250–330 мм.

Тяжёлая платформа. Масса рамы 3,5 кг, длина плеча 0,210 м. Имитирует аппарат с полезной нагрузкой около 1,5 кг (например, лидар или тепловизионная камера) — типичная конфигурация для задач промышленного мониторинга. Коэффициент тяги мотора увеличен до $1,188 \times 10^{-5}$ для сохранения достаточного запаса тяги на висении.

Полный перечень физических и имитационных параметров трёх платформ приведён в таблице 18.

Таблица 19 показывает соответствие имитационных моделей реальным аналогам.

Таблица 12 — Физические и имитационные параметры экспериментальных платформ. Параметры, отличающиеся от базовой, выделены жирным шрифтом. Разрыв платформы $\Delta = m/m_{\text{base}}$ характеризует величину доменного сдвига.

Параметр	Ед. изм.	Базовая	Лёгкая	Тяжёлая
<i>Физические параметры</i>				
Масса рамы m	кг	2,0	1,0	3,5
Момент инерции $I_{xx} = I_{yy}$	кг·м ²	0,02167	0,00683	0,05507
Момент инерции I_{zz}	кг·м ²	0,04000	0,01260	0,10165
Длина плеча l	м	0,174	0,138	0,210
<i>Параметры силовой установки</i>				
Коэффициент тяги k_T	Н/(рад/с) ²	$8,549 \times 10^{-6}$	$8,549 \times 10^{-6}$	$1,188 \times 10^{-5}$
Коэффициент сопротивления вращению k_D	Н·м/(рад/с) ²	$1,368 \times 10^{-7}$	$1,368 \times 10^{-7}$	$1,901 \times 10^{-7}$
Постоянная времени набора оборотов $\tau_{\uparrow}$	с	0,0125	0,0088	0,0165
Постоянная времени сброса оборотов $\tau_{\downarrow}$	с	0,0250	0,0177	0,0331
<i>Параметры системы управления</i>				
Тяга на висении MPC_THR_HOVER	—	0,60	0,54	0,85
Идентификатор airframe SYS_AUTOSTART	—	4001	4022	4023
<i>Производные характеристики</i>				
Разрыв платформы Δ	—	1,0×	0,5×	1,75×
Тяга одного мотора на висении $mg/4$	Н	4,905	2,452	8,584
Обороты роторов на висении ω_h	рад/с	757	535	850
Отношение тяги к весу T/W	—	1,74	3,48	1,37

Таблица 13 — Соответствие имитационных моделей реальным платформам.

Имитационная модель	Реальная платформа	Основные сходства
Базовая	Holybro X500 V2 + Pixhawk 6C + батарея 4S 5000 мА·ч	Полное совпадение
Лёгкая	X500 V2 в минимальной комплектации; класс DJI F330	Масса около 1 кг, рама 250–330 мм
Тяжёлая	X500 V2 с полезной нагрузкой 1,5 кг (лидар)	Масса 3–4 кг, тяжеловесная конфигурация

4.7.2 Профили полётных заданий

Для эксперимента были сформированы три профиля полёта, различающиеся скоростью, высотой и минимальным углом разворота (таблица 20). Все платформы использовали одни и те же траектории, поэтому наблюдаемые различия в точности обусловлены исключительно динамическими свойствами аппаратов.

Таблица 14 — Параметры профилей полётных заданий. Минимальный угол разворота обеспечивает резкие изменения курса и увеличивает разницу оборотов между парами роторов.

Профиль	Мах. скорость, м/с	Высота, м	Мин. угол разворота	Количество точек	Радиус зоны, м
Спокойный	8	8–20	—	50	40
Умеренный	12	5–35	$\geq 45^\circ$	50	60
Агрессивный	15	5–45	$\geq 90^\circ$	50	70

4.7.3 Методика проведения эксперимента

Для каждой из девяти комбинаций (три платформы $\times$ три профиля) выполнялся полёт в среде PX4 SITL с использованием Gazebo. Из полученных логов извлекались показания гироскопа, акселерометра, магнитометра, кватернион ориентации, команды на моторы (в пересчёте на угловые скорости роторов) и эталонные положение и скорость из EKF2. Данные ресемплировались до частоты 100 Гц. Участки ниже высоты 1 м и буферы взлёта/посадки исключались. Перерывы в приёме сигналов ГНСС длительностью 10 с (по 20 на каждый лог) имитировались маскированием соответствующих измерений.

Размеры сформированных датасетов после предобработки приведены в таблице 21.

Перед оценкой на каждой новой платформе в модель подставлялись соответствующие физические параметры (масса, коэффициент тяги, длина плеча) без изменения весов нейросети. Это единственная адаптация, выполнявшаяся в эксперименте.

Таблица 15 — Объёмы датасетов после предобработки (количество отсчётов при частоте 100 Гц примерно соответствует секундам полёта).

Платформа	Спокойный	Умеренный	Агрессивный	Итого
Базовая	43 536	52 693	79 738	175 967
Лёгкая	43 819	53 138	80 479	177 436
Тяжёлая	43 222	51 960	79 039	174 221
Всего	130 577	157 791	239 256	527 624

Оценка проводилась по единой методике. Для каждого лога выбиралось 10 случайных начальных позиций. Предсказанные скорости интегрировались методом Рунге—Кутты четвёртого порядка с двунаправленным сглаживанием. Использовались две метрики без применения выравнивания по методу Умеямы:

$$\text{СКО} = \sqrt{\frac{1}{3T} \sum_{t=1}^T \|\hat{\mathbf{p}}_t - \mathbf{p}_t\|^2}, \quad (4.2)$$

$$\text{АОТ} = \frac{1}{T} \sum_{t=1}^T \|\hat{\mathbf{p}}_t - \mathbf{p}_t\|_2. \quad (4.3)$$

Длительности перерывов в приёме сигналов ГНСС: 3, 5, 10, 30, 60 и 120 с.

4.7.4 Результаты эксперимента

Полные значения СКО и АОТ для всех комбинаций платформ и профилей полёта приведены в таблицах 22 и ???. Эти данные составляют основной количественный результат раздела.

Анализ скорости роста ошибки (отношение СКО при 60 с к СКО при 10 с) показал, что тяжёлая платформа демонстрирует наименьшие темпы накопления ошибки при спокойном и умеренном профилях.

Анализ зависимости точности от разрыва платформы (отношения массы к базовой) выявил важную закономерность: при длительности перерыва 30–60 с кривая зависимости СКО от разрыва платформы становится практически плоской. Это означает, что обобщение без дообучения работает почти одинаково хорошо на всех трёх платформах, несмотря на 3,5-кратный диапазон масс.

Таблица 16 — Среднеквадратичная ошибка положения (СКО, м) для всех комбинаций платформа–профиль и длительностей перерывов ГНСС. Обобщение без дообучения. Лучшее значение в каждом столбце подчеркнуто.

Платформа	Профиль	3 с	5 с	10 с	30 с	60 с	120 с
Базовая	спокойный	<u>0,194</u>	0,401	1,081	2,483	3,083	3,885
	умеренный	0,457	0,890	1,613	3,661	5,940	7,400
	агрессивный	0,423	0,921	1,722	6,183	10,606	12,723
Лёгкая	спокойный	0,190	0,429	<u>0,939</u>	<u>2,198</u>	3,373	4,478
	умеренный	0,471	0,732	1,983	3,293	6,271	7,830
	агрессивный	0,576	1,407	2,442	6,466	8,527	12,460
Тяжёлая	спокойный	0,214	0,494	1,072	2,288	<u>2,979</u>	<u>4,303</u>
	умеренный	<u>0,394</u>	<u>0,752</u>	1,860	<u>3,308</u>	<u>4,859</u>	<u>7,122</u>
	агрессивный	<u>0,321</u>	<u>0,918</u>	2,967	6,315	10,331	13,602

Особенно показательны результаты при спокойном профиле полёта (таблица 23). Разброс значений СКО между платформами при 60 с не превышает 0,394 м, что составляет менее 13 процентов относительно среднего значения. Это исключительно малое различие при изменении массы в 3,5 раза.

Таблица 17 — Среднеквадратичная ошибка положения при спокойном профиле полёта. Разброс между платформами (максимум минус минимум) остаётся ниже 0,5 м даже при 60-секундном перерыве ГНСС.

Длительность	Базовая	Лёгкая	Тяжёлая	Разброс
3 с	0,194	0,190	0,214	0,024
5 с	0,401	0,429	0,494	0,093
10 с	1,081	0,939	1,072	0,142
30 с	2,483	2,198	2,288	0,285
60 с	3,083	3,373	2,979	0,394
120 с	3,885	4,478	4,303	0,593

На рисунках 4.8 и 4.9 приведены графики зависимость СКО от массы робота.




Рисунок 4.6 — Зависимость СКО от массы робота разделенная по характеру движения




Рисунок 4.7 — Зависимость СКО от массы робота разделенная по длительности потери ГНСС сигнала

Из графика 4.9 можно заметить следующие интересные закономерности.

При длительности потери ГНСС сигнала 3с и агрессивном режиме полета СКО для тяжелого робота 3.5 кг (0,321 м) меньше чем у базовой модели (0,423 м). Так же СКО при такой же потере сигнала и в том же ре

4.7.5 Обсуждение результатов

Наиболее важный результат эксперимента состоит в том, что обобщение без дообучения ФИ-НС-ПСПС на платформы различной массы оказывается эффективным, особенно при плавных траекториях. При спокойном профиле разброс СКО между платформами при 60 с составляет всего 0,394 м. Это напрямую подтверждает гипотезу, что физическое ограничение на основе оборотов роторов обеспечивает платформенно-инвариантный структурный приоритет.

Тяжёлая платформа в ряде случаев даже превосходит базовую по точности при длительных перерывах. Этому способствуют два фактора. Во-первых, большая инерция сглаживает траектории: даже при агрессивных разворотах изменения скорости происходят более плавно, что облегчает задачу предсказания. Во-вторых, более высокие обороты роторов на висении (около 850 рад/с против 757 рад/с) обеспечивают более сильный и информативный сигнал для вычисления физического остатка.

В то же время агрессивность профиля полёта оказывает существенно большее влияние на точность, чем различия между платформами. Отношение СКО при агрессивном профиле к СКО при спокойном при 60 с находится в диапазоне 2,5–3,5, тогда как вариация между платформами при фиксированном профиле не превышает 20

Попытки дообучения модели на новых платформах не дали положительного эффекта. Причина — несоответствие статистик нормализации входных признаков. Датасеты лёгкой и тяжёлой платформ имеют иные средние значения и дисперсии оборотов роторов по сравнению с базовым датасетом. При использовании «чужой» нормализации физическая составляющая функции потерь вычисляет некорректные остатки, и градиенты направляют обучение в неверную сторону.

Этот результат имеет важное практическое значение: корректная нормализация входных данных является обязательным условием успешного переноса обучения в задачах нейросетевой одометрии. Простым и эффективным решением является короткий калибровочный полёт в режиме висения (2–3 минуты) с последующим пересчётом среднего значения и стандартного отклонения сигналов оборотов роторов для целевой платформы.

4.7.6 Выводы по разделу

Проведённый эксперимент по обобщению без дообучения ФИ-НС-ПСПС на три платформы с диапазоном масс 3,5 раза и три профиля полёта (всего 54 условия) позволил сформулировать следующие выводы:

1. Обобщение без дообучения является практически применимым. При 10-секундном перерыве ГНСС СКО не превышает 3 м на всех платформах и профилях, что приемлемо для многих прикладных задач.
2. При спокойных траекториях обобщение почти идеально: разброс СКО между платформами при 60 с составляет менее 0,4 м (< 13
3. Тяжёлая платформа в ряде сценариев показывает лучшие результаты при длительных перерывах благодаря сглаживающему эффекту инерции и более сильным сигналам оборотов роторов.
4. Агрессивность миссии оказывает большее влияние на точность, чем различия платформ. При проектировании систем навигации приоритет следует отдавать выбору профиля полёта.
5. Успешный перенос обучения требует предварительной калибровки нормализации входных признаков под целевую платформу. Эта процедура должна входить в стандартный пайплайн развёртывания.

Это взаимодействие между массой платформы и агрессивностью миссии представляет важный нюанс для практиков при проектировании стратегий сбора данных для дообучения.

Ограничения. Следует отметить несколько ограничений.

Во-первых, эксперименты сравнения дообучения модели проведены в симуляции Gazebo. В рамках настоящей работы валидация на реальном оборудовании порведена исключительно на датасете АПО [38].

Во-вторых, масштабирование длины плеча для лёгкой платформы ($l = 0,138$ m против 0,174 m у базовой) вносит незначительные изменения в динамическую модель робота.

В-третьих, значения СКО при $\tau \geq 60$ s превышают радиус операционной зоны полёта (70 m), поэтому эти метрики отражают асимптотический дрейф, а не практическую ошибку навигации; результаты для коротких потерь сигнала ($\tau \leq 10$ s) являются более релевантными с практической точки зрения.

4.8 Заключение

В данной главе представлена систематическая многоплатформенная оценка предложенной архитектуры MambaRPM PINN на трёх конфигурациях квадрокоптера, охватывающих диапазон масс $3,5\times$ и три уровня агрессивности полётных миссий.

Основные результаты:

1. **Дообучение под конкретную платформу эффективно и требует небольшого объёма данных.** Пяти эпох на примерно 175 000 последовательностей на платформу достаточно, чтобы достичь СКО в пределах 22 m при потере сигнала ГНСС длительностью 10 s для всех трёх платформ по сравнению с диапазоном 14–20 m для платформы предобучения.
2. **Объединённая стратегия полезна для лёгких платформ, но не для базовой и тяжёлой.** Включение кросс-платформенных данных действует как доменная рандомизация для нештатной динамики (лёгкий дрон), но ухудшает точность на платформе предобучения (тяжёлая и базовая конфигурации).
3. **Платформенный разрыв масштабирует СКО при умеренных длительностях потери сигнала.** Как лёгкая ($\Delta = 0,5\times$), так и тяжёлая ($\Delta = 1,75\times$) платформы показывают примерно на 37 % более высокую среднюю СКО, чем базовая при $\tau = 30$ s, подтверждая, что адаптация к массе предобучения является доминирующим фактором.
4. **Агрессивность полёта взаимодействует с инерцией платформы.** Влияние профиля уменьшается с ростом массы платформы — от отношения $1,87\times$ (спокойный/агрессивный) для лёгкой платформы до всего $1,05\times$ для тяжёлой. Это указывает на то, что платформы с высокой инерцией inherently более устойчивы к вариациям профиля миссии в наборе данных для дообучения.

Эти результаты подтверждают подход физически информированного трансферного обучения для одометрии квадрокоптеров и дают количественные рекомендации для практиков при выборе данных для дообучения при развёртывании предложенной системы на новой платформе.

4.9 Обобщение без дообучения ФИ-НС-ПСПС на платформы различной массы и динамики

В предыдущих разделах главы было показано, что предлагаемая физически информированная нейросетевая система позиционирования (ФИ-НС-ПСПС) на базе архитектуры Mamba с регуляризатором на основе оборотов роторов обеспечивает точную инерциальную одометрию при перерывах в приёме сигналов ГНСС на квадрокоптере Holybro X500 V2. Однако для практического внедрения принципиально важно понять, насколько эта система способна обобщаться на другие платформы без дополнительного обучения.

Большинство современных подходов к восстановлению траектории по данным инерциальных датчиков фактически запоминают статистические особенности шумов и динамики конкретного аппарата. Эти особенности напрямую зависят от массы, моментов инерции и аэродинамических характеристик, поэтому модель, обученная на одном квадрокоптере, обычно не может быть напрямую перенесена на другой без дообучения.

В отличие от чисто data-driven решений, в ФИ-НС-ПСПС явно присутствует физическое ограничение, соответствующее второму закону Ньютона:

$$m \mathbf{a} = \sum_{i=1}^4 k_T \omega_i^2 \hat{\mathbf{z}}_{\text{body}} - b_{\text{drag}} m \mathbf{v} + m \mathbf{g}, \quad (4.4)$$

где m — масса платформы, k_T — коэффициент тяги мотора, ω_i — угловые скорости роторов, b_{drag} — коэффициент аэродинамического сопротивления, $\mathbf{v}$ — скорость центра масс в связанной системе координат, $\mathbf{g}$ — ускорение свободного падения.

Эта зависимость имеет одинаковую структуру для любого жёсткого квадрокоптера; изменяются лишь числовые значения массы и коэффициента тяги. Гипотеза, проверяемая в данном разделе, заключается в том, что нейросетевая часть системы в первую очередь выучивает отображение, определяемое именно этой инвариантной физической структурой, а влияние массы на результат поглощается через наблюдаемые сигналы оборотов роторов.

Для проверки гипотезы был проведён эксперимент по обобщению без дообучения. Предобученная ФИ-НС-ПСПС оценивалась на трёх платформах, охватывающих диапазон масс 3,5 раза, и на трёх профилях полёта с различной агрессивностью — без какого-либо дообучения под целевую платформу.

4.9.1 Описание экспериментальных платформ

В качестве базовой использовалась модель Holybro X500 V2 — та же платформа, на которой проводились все предыдущие эксперименты. На её основе были созданы две дополнительные виртуальные платформы путём изменения только инерционных параметров при сохранении неизменными характеристик моторов, пропеллеров и состава датчиков. Такой подход позволяет изолировать влияние массы и инерции на точность одометрии.

Лёгкая платформа. Масса рамы 1,0 кг, длина плеча 0,138 м. Соответствует минимальной комплектации X500 V2 без полезной нагрузки и близка по характеристикам к компактным исследовательским квадрокоптерам класса 250–330 мм.

Тяжёлая платформа. Масса рамы 3,5 кг, длина плеча 0,210 м. Имитирует аппарат с полезной нагрузкой около 1,5 кг (например, лидар или тепловизионная камера) — типичная конфигурация для задач промышленного мониторинга. Коэффициент тяги мотора увеличен до $1,188 \times 10^{-5}$ для сохранения достаточного запаса тяги на висении.

Полный перечень физических и имитационных параметров трёх платформ приведён в таблице 18.

Таблица 19 показывает соответствие имитационных моделей реальным аналогам.

4.9.2 Профили полётных заданий

Для эксперимента были сформированы три профиля полёта, различающиеся скоростью, высотой и минимальным углом разворота (таблица 20). Все платформы использовали одни и те же траектории, поэтому наблюдаемые различия в точности обусловлены исключительно динамическими свойствами аппаратов.

Таблица 18 — Физические и имитационные параметры экспериментальных платформ. Параметры, отличающиеся от базовой, выделены жирным шрифтом. Разрыв платформы $\Delta = m/m_{\text{base}}$ характеризует величину доменного сдвига.

Параметр	Ед. изм.	Базовая	Лёгкая	Тяжёлая
<i>Физические параметры</i>				
Масса рамы m	кг	2,0	1,0	3,5
Момент инерции $I_{xx} = I_{yy}$	кг·м ²	0,02167	0,00683	0,05507
Момент инерции I_{zz}	кг·м ²	0,04000	0,01260	0,10165
Длина плеча l	м	0,174	0,138	0,210
<i>Параметры силовой установки</i>				
Коэффициент тяги k_T	Н/(рад/с) ²	$8,549 \times 10^{-6}$	$8,549 \times 10^{-6}$	$1,188 \times 10^{-5}$
Коэффициент сопротивления вращению k_D	Н·м/(рад/с) ²	$1,368 \times 10^{-7}$	$1,368 \times 10^{-7}$	$1,901 \times 10^{-7}$
Постоянная времени набора оборотов $\tau_{\uparrow}$	с	0,0125	0,0088	0,0165
Постоянная времени сброса оборотов $\tau_{\downarrow}$	с	0,0250	0,0177	0,0331
<i>Параметры системы управления</i>				
Тяга на висении MPC_THR_HOVER	—	0,60	0,54	0,85
Идентификатор airframe SYS_AUTOSTART	—	4001	4022	4023
<i>Производные характеристики</i>				
Разрыв платформы Δ	—	1,0×	0,5×	1,75×
Тяга одного мотора на висении $mg/4$	Н	4,905	2,452	8,584
Обороты роторов на висении ω_h	рад/с	757	535	850
Отношение тяги к весу T/W	—	1,74	3,48	1,37

Таблица 19 — Соответствие имитационных моделей реальным платформам.

Имитационная модель	Реальная платформа	Основные сходства
Базовая	Holybro X500 V2 + Pixhawk 6C + батарея 4S 5000 мА·ч	Полное совпадение
Лёгкая	X500 V2 в минимальной комплектации; класс DJI F330	Масса около 1 кг, рама 250–330 мм
Тяжёлая	X500 V2 с полезной нагрузкой 1,5 кг (лидар)	Масса 3–4 кг, тяжеловесная конфигурация

Таблица 20 — Параметры профилей полётных заданий. Минимальный угол разворота обеспечивает резкие изменения курса и увеличивает разницу оборотов между парами роторов.

Профиль	Мах. скорость, м/с	Высота, м	Мин. угол разворота	Количество точек	Радиус зоны, м
Спокойный	8	8–20	—	50	40
Умеренный	12	5–35	$\geq 45^\circ$	50	60
Агрессивный	15	5–45	$\geq 90^\circ$	50	70

4.9.3 Методика проведения эксперимента

Для каждой из девяти комбинаций (три платформы $\times$ три профиля) выполнялся полёт в среде PX4 SITL с использованием Gazebo. Из полученных логов извлекались показания гироскопа, акселерометра, магнитометра, кватернион ориентации, команды на моторы (в пересчёте на угловые скорости роторов) и эталонные положение и скорость из EKF2. Данные ресемплировались до частоты 100 Гц. Участки ниже высоты 1 м и буферы взлёта/посадки исключались. Перерывы в приёме сигналов ГНСС длительностью 10 с (по 20 на каждый лог) имитировались маскированием соответствующих измерений.

Размеры сформированных датасетов после предобработки приведены в таблице 21.

Таблица 21 — Объёмы датасетов после предобработки (количество отсчётов при частоте 100 Гц примерно соответствует секундам полёта).

Платформа	Спокойный	Умеренный	Агрессивный	Итого
Базовая	43 536	52 693	79 738	175 967
Лёгкая	43 819	53 138	80 479	177 436
Тяжёлая	43 222	51 960	79 039	174 221
Всего	130 577	157 791	239 256	527 624

Перед оценкой на каждой новой платформе в модель подставлялись соответствующие физические параметры (масса, коэффициент тяги, длина плеча) без изменения весов нейросети. Это единственная адаптация, выполнявшаяся в эксперименте.

Оценка проводилась по единой методике. Для каждого лога выбиралось 10 случайных начальных позиций. Предсказанные скорости интегрировались методом Рунге—Кутты четвёртого порядка с двунаправленным сглаживанием.

Использовались две метрики без применения выравнивания по методу Умеямы:

$$\text{СКО} = \sqrt{\frac{1}{3T} \sum_{t=1}^T \|\hat{\mathbf{p}}_t - \mathbf{p}_t\|^2}, \quad (4.5)$$

$$\text{АОТ} = \frac{1}{T} \sum_{t=1}^T \|\hat{\mathbf{p}}_t - \mathbf{p}_t\|_2. \quad (4.6)$$

Длительности перерывов в приёме сигналов ГНСС: 3, 5, 10, 30, 60 и 120 с.

4.9.4 Результаты эксперимента

Полные значения СКО и АОТ для всех комбинаций платформ и профилей полёта приведены в таблицах 22 и ???. Эти данные составляют основной количественный результат раздела.

Таблица 22 — Среднеквадратичная ошибка положения (СКО, м) для всех комбинаций платформа–профиль и длительностей перерывов ГНСС. Обобщение без дообучения. Лучшее значение в каждом столбце подчеркнуто.

Платформа	Профиль	3 с	5 с	10 с	30 с	60 с	120 с
Базовая	спокойный	<u>0,194</u>	0,401	1,081	2,483	3,083	3,885
	умеренный	0,457	0,890	1,613	3,661	5,940	7,400
	агрессивный	0,423	0,921	1,722	6,183	10,606	12,723
Лёгкая	спокойный	0,190	0,429	<u>0,939</u>	<u>2,198</u>	3,373	4,478
	умеренный	0,471	0,732	1,983	3,293	6,271	7,830
	агрессивный	0,576	1,407	2,442	6,466	8,527	12,460
Тяжёлая	спокойный	0,214	0,494	1,072	2,288	<u>2,979</u>	<u>4,303</u>
	умеренный	<u>0,394</u>	<u>0,752</u>	1,860	<u>3,308</u>	<u>4,859</u>	<u>7,122</u>
	агрессивный	<u>0,321</u>	<u>0,918</u>	2,967	6,315	10,331	13,602

Анализ скорости роста ошибки (отношение СКО при 60 с к СКО при 10 с) показал, что тяжёлая платформа демонстрирует наименьшие темпы накопления ошибки при спокойном и умеренном профилях.

Анализ зависимости точности от разрыва платформы (отношения массы к базовой) выявил важную закономерность: при длительности перерыва 30–60 с кривая зависимости СКО от разрыва платформы становится практически плоской. Это означает, что обобщение без дообучения работает почти одинаково хорошо на всех трёх платформах, несмотря на 3,5-кратный диапазон масс.

Особенно показательны результаты при спокойном профиле полёта (таблица 23). Разброс значений СКО между платформами при 60 с не превышает 0,394 м, что составляет менее 13 процентов относительно среднего значения. Это исключительно малое различие при изменении массы в 3,5 раза.

Таблица 23 — Среднеквадратичная ошибка положения при спокойном профиле полёта. Разброс между платформами (максимум минус минимум) остаётся ниже 0,5 м даже при 60-секундном перерыве ГНСС.

Длительность	Базовая	Лёгкая	Тяжёлая	Разброс
3 с	0,194	0,190	0,214	0,024
5 с	0,401	0,429	0,494	0,093
10 с	1,081	0,939	1,072	0,142
30 с	2,483	2,198	2,288	0,285
60 с	3,083	3,373	2,979	0,394
120 с	3,885	4,478	4,303	0,593

На рисунках 4.8 и 4.9 приведены графики зависимость СКО от массы робота.

Из графика 4.9 можно заметить следующие интересные закономерности.

При длительности потери ГНСС сигнала 3с и агрессивном режиме полета СКО для тяжелого робота 3.5 кг (0,321 м) меньше чем у базовой модели (0,423 м). Так же СКО при такой же потере сигнала и в том же ре




Рисунок 4.8 — Зависимость СКО от массы робота разделенная по характеру движения




Рисунок 4.9 — Зависимость СКО от массы робота разделенная по длительности потери ГНСС сигнала

4.9.5 Обсуждение результатов

Наиболее важный результат эксперимента состоит в том, что обобщение без дообучения ФИ-НС-ПСПС на платформы различной массы оказывается эффективным, особенно при плавных траекториях. При спокойном профиле разброс СКО между платформами при 60 с составляет всего 0,394 м. Это напрямую подтверждает гипотезу, что физическое ограничение на основе оборотов роторов обеспечивает платформенно-инвариантный структурный приоритет.

Тяжёлая платформа в ряде случаев даже превосходит базовую по точности при длительных перерывах. Этому способствуют два фактора. Во-первых, большая инерция сглаживает траектории: даже при агрессивных разворотах изменения скорости происходят более плавно, что облегчает задачу предсказания. Во-вторых, более высокие обороты роторов на висении (около 850 рад/с против 757 рад/с) обеспечивают более сильный и информативный сигнал для вычисления физического остатка.

В то же время агрессивность профиля полёта оказывает существенно большее влияние на точность, чем различия между платформами. Отношение СКО при агрессивном профиле к СКО при спокойном при 60 с находится в диапазоне 2,5–3,5, тогда как вариация между платформами при фиксированном профиле не превышает 20

Попытки дообучения модели на новых платформах не дали положительного эффекта. Причина — несоответствие статистик нормализации входных признаков. Датасеты лёгкой и тяжёлой платформ имеют иные средние значения и дисперсии оборотов роторов по сравнению с базовым датасетом. При использовании «чужой» нормализации физическая составляющая функции потерь вычисляет некорректные остатки, и градиенты направляют обучение в неверную сторону.

Этот результат имеет важное практическое значение: корректная нормализация входных данных является обязательным условием успешного переноса обучения в задачах нейросетевой одометрии. Простым и эффективным решением является короткий калибровочный полёт в режиме висения (2–3 минуты) с последующим пересчётом среднего значения и стандартного отклонения сигналов оборотов роторов для целевой платформы.

4.9.6 Выводы по разделу

Проведённый эксперимент по обобщению без дообучения ФИ-НС-ПСПС на три платформы с диапазоном масс 3,5 раза и три профиля полёта (всего 54 условия) позволил сформулировать следующие выводы:

1. Обобщение без дообучения является практически применимым. При 10-секундном перерыве ГНСС СКО не превышает 3 м на всех платформах и профилях, что приемлемо для многих прикладных задач.
2. При спокойных траекториях обобщение почти идеально: разброс СКО между платформами при 60 с составляет менее 0,4 м (<13
3. Тяжёлая платформа в ряде сценариев показывает лучшие результаты при длительных перерывах благодаря сглаживающему эффекту инерции и более сильным сигналам оборотов роторов.
4. Агрессивность миссии оказывает большее влияние на точность, чем различия платформ. При проектировании систем навигации приоритет следует отдавать выбору профиля полёта.
5. Успешный перенос обучения требует предварительной калибровки нормализации входных признаков под целевую платформу. Эта процедура должна входить в стандартный пайплайн развёртывания.

Заключение

Основные результаты работы заключаются в следующем.

1. На основе анализа ...
2. Численные исследования показали, что ...
3. Математическое моделирование показало ...
4. Для выполнения поставленных задач был создан ...

Выражаю благодарность научному руководителю доктору технических наук Тимофееву А.Н. за поддержку, помощь, обсуждение результатов и научное руководство. Так же выражаю благодарность Богданову А.М. за распитие пива и конструктивную критику результатов исследования.

Словарь терминов

СКО : Среднеквадратическое отклонение **АОТ** : Абсолютная ошибка траектории

панграмма : Короткий текст, использующий все или почти все буквы алфавита

Список литературы

- [1] Xingxing Guang и др. — «Imu data and gps position information direct fusion based on lstm». — В: *Sensors* 21.7 (2021), с. 1—13. — DOI: 10.3390/s21072500.
- [2] Kévin Cédric Guyard и др. — «A Transformer Encoder Approach for Localization Reconstruction During GPS Outages from an IMU and GPS-Based Sensor». — В: *Sensors* 25.2 (2025). — DOI: 10.3390/s25020522.
- [3] Changhao Chen и Xianfei Pan. — «Deep Learning for Inertial Positioning: A Survey». — В: *IEEE Transactions on Intelligent Transportation Systems* 25.9 (2024), с. 10506—10523. — DOI: 10.1109/TITS.2024.3381161. — arXiv: 2303.03757.
- [4] Maziar Raissi, Paris Perdikaris и George E. Karniadakis. — «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations». — В: *Journal of Computational Physics* 378 (2019), с. 686—707. — DOI: 10.1016/j.jcp.2018.10.045.
- [5] Mokhammad Nur Cahyadi и др. — «Performance of GPS and IMU sensor fusion using unscented Kalman filter for precise i-Boat navigation in infinite wide waters». — В: *Geodesy and Geodynamics* 14.3 (2023), с. 265—274. — DOI: 10.1016/j.geog.2022.11.005.
- [6] Shengli Pang и др. — «Application of IMU/GPS Integrated Navigation System Based on Adaptive Unscented Kalman Filter Algorithm in 3D Positioning of Forest Rescue Personnel». — В: *Sensors* 24.18 (2024). — DOI: 10.3390/s24185873.
- [7] Xiang Fang и др. — «Ski jumping trajectory reconstruction using wearable sensors via extended rauch-tung-striebeel smoother with state constraints». — В: *Sensors (Switzerland)* 20.7 (2020). — DOI: 10.3390/s20071995.
- [8] Rohan Kumar Reddy Damagatla и Mohamed Atia. — «Improving EKF-Based IMU/GNSS Fusion Using Machine Learning for IMU Denoising». — В: *IEEE Access* 12 (2024), с. 1—1. — DOI: 10.1109/ACCESS.2024.XXXXXXX.

- [9] Yujin Shin и др. — «Long Short-Term Memory Network for INS Positioning During GNSS Outages: A Preliminary Study on Simple Trajectories». — B: *Journal of Positioning, Navigation, and Timing* 13.2 (июнь 2024), с. 137—147. — DOI: 10.11003/JPNT.2024.13.2.137.
- [10] Mst Alema Khatun и др. — «Deep CNN-LSTM With Self-Attention Model for Human Activity Recognition Using Wearable Sensor». — B: *IEEE Journal of Translational Engineering in Health and Medicine* 10.May (2022). — DOI: 10.1109/JTEHM.2022.3177710.
- [11] Ahmed M.M. Almassri и др. — «Artificial Neural Network Approach to Guarantee the Positioning Accuracy of Moving Robots by Using the Integration of IMU/UWB with Motion Capture System Data Fusion». — B: *Sensors* 22.15 (2022). — DOI: 10.3390/s22155737.
- [12] J. Varey и др. — «Physics-Informed Neural Networks for Satellite State Estimation». — B: *IEEE Aerospace Conference*. — 2024, — С. 1—12.
- [13] Ashish Vaswani и др. — «Attention Is All You Need». — B: *Advances in Neural Information Processing Systems* 30 (2017), с. 5998—6008.
- [14] Yanping Zhu и др. — «ResT-IMU: A Two-Stage ResNet-Transformer Framework for Inertial Measurement Unit Localization». — B: *Sensors* 25.11 (2025), с. 1—16. — DOI: 10.3390/s25113441.
- [15] Vladimir Sivtsov и др. — «Physics-Informed Neural Networks in Robotics: A Review». — B: *SSRN Electronic Journal* (2025). — DOI: 10.2139/ssrn.5125543.
- [16] Daniele Bianchi и др. — «Physics-Informed Neural Networks for Unmanned Aerial Vehicle System Estimation». — B: *arXiv preprint arXiv:240X.XXXXX* (2024).
- [17] Cheng Tan и др. — «Vehicle State Estimation Combining Physics-Informed Neural Network and Unscented Kalman Filtering on Manifolds». — B: *Sensors* 23.15 (2023), с. 6665. — DOI: 10.3390/s23156665.
- [18] Z. Zhou и др. — «Physics-informed neural network for load sway prediction in travelling autonomous mobile cranes». — B: *Advanced Engineering Informatics* (2025). — DOI: 10.1016/j.aei.2025.XXXXXX.
- [19] Yanhui Liu и др. — «Online Continual Physics-Informed Learning for Quadrotor State Estimation Under Wind-Induced Disturbances». — B: *Aerospace* 12.8 (2025), с. 704. — DOI: 10.3390/aerospace12080704.

- [20] Q. Bian и др. — «OrientationNN: a physics-informed lightweight neural network for real-time joint kinematics estimation from IMU data». — B: *Frontiers in Bioengineering and Biotechnology* (2025). — DOI: 10.3389/fbioe.2025.1737916.
- [21] Guangshuo An и др. — «Physics informed neural networks based identification modelling of ship maneuvering motion and associated optimal excitation design». — B: *Engineering Applications of Computational Fluid Mechanics* (2025). — DOI: 10.1080/19942060.2025.2566860.
- [22] Artur Shurin и Itzik Klein. — «QuadNet: A Hybrid Framework for Quadrotor Dead Reckoning». — B: *Sensors* 22.4 (2022), с. 1426. — DOI: 10.3390/s22041426.
- [23] T. Fu и др. — «Novel Hybrid Physics-Informed Deep Neural Network for Dynamic Load Prediction of Electric Cable Shovel». — B: (202X).
- [24] Albert Gu и Tri Dao. — «Mamba: Linear-Time Sequence Modeling with Selective State Spaces». — B: *Kalman 1960* (2024), с. 1—36. — arXiv: 2312.00752. — URL: <http://arxiv.org/abs/2312.00752>.
- [25] Toshiaki Tsuji. — «Mamba as a Motion Encoder for Robotic Imitation Learning». — B: *IEEE Access* 13 (2025), с. 69941—69949. — DOI: 10.1109/ACCESS.2025.3561283. — arXiv: 2409.02636.
- [26] Weiwei Wang и Mingkuan Zhou. — «Design and Experiment of Trajectory Reconstruction Algorithm of Wireless Pipeline Robot Based on GC-LSTM». — B: *Electronics (Switzerland)* 14.19 (2025). — DOI: 10.3390/electronics14193941.
- [27] S. Niu и др. — «A TCN-BiLSTM and ANR-IEKF Hybrid Framework for Sustained Vehicle Positioning During GNSS Outages». — B: *Sensors* 26.1 (2026).
- [28] Anton Sidorenko и Sertac Karaman. — «Real-time Guidance for Low-Thrust Transfers Using Deep Learning». — B: *Journal of Guidance, Control, and Dynamics* 49.2 (2026), с. 345—358. — DOI: 10.2514/1.G006254.
- [29] Leonard Bauersfeld и др. — «NeuroBEM: Hybrid Aerodynamic Quadrotor Model». — B: *arXiv preprint arXiv:2106.08015* (2021).
- [30] Y. Zhang и др. — «Actuator-Informed State Estimation for Quadrotors under Wind Disturbances». — B: *IEEE Robotics and Automation Letters* 7.3 (2022).

- [31] H. Liu и др. — «State Space Models with Actuator Signals for Inertial Navigation of UAVs». — В: *IEEE Transactions on Robotics* 41 (2025).
- [32] SJTU-ViSYS Team. — «AI-IO: A Real-World Quadrotor Dataset with IMU and Rotor Speed Measurements». — В: (2026).
- [33] H. Wang и др. — «Hybrid Aerodynamic Wind-Aware Modeling for Quadrotor State Estimation». — В: (2023).
- [34] Michael Burri и др. — «The EuRoC micro aerial vehicle datasets». — В: *International Journal of Robotics Research* 35.10 (2016), с. 1157—1163. — DOI: 10.1177/0278364915620033.
- [35] Holybro. — *Holybro X500 V2 ARF Kit User Guide*. — <https://holybro.com/products/x500-v2-kit>. — 2023.
- [36] Albert Gu и Tri Dao. — «Mamba: Linear-Time Sequence Modeling with Selective State Spaces». — В: *arXiv preprint arXiv:2312.00752* (2023). — URL: <https://arxiv.org/abs/2312.00752>.
- [37] Guanya Shi и др. — «Physics-Informed Machine Learning for Quadrotor State Estimation». — В: *Science Robotics* 4.35 (2019). — DOI: 10.1126/scirobotics.aay6237.
- [38] Jiahao Cui и др. — «AI-IO: An Aerodynamics-Inspired Real-Time Inertial Odometry for Quadrotors». — В: *arXiv preprint arXiv:2603.00597* (2026). — URL: <https://arxiv.org/abs/2603.00597>.

Список рисунков

2.1	Кинематика и динамика квадрокоптера. Инерциальная система координат $\mathcal{W}$ (зелёная) и связанная система координат $\mathcal{B}$ (красная/оранжевая/синяя) с положением центра масс $\mathbf{p}_{\mathcal{WB}}$ (бирюзовый), линейной скоростью $\mathbf{v}_{\mathcal{W}}$ (пурпурный), угловой скоростью $\boldsymbol{\omega}_{\mathcal{B}}$ (фиолетовый), силами тяги отдельных роторов $f_i = k_T \omega_i^2$ (синие стрелки), силой тяжести $\mathbf{g}$ (зелёный), моментами крена, тангажа и рыскания $\tau_{x,y,z}$ и кватернионом ориентации $\mathbf{q}_{\mathcal{WB}}$. Роторы 1 и 3 вращаются по часовой стрелке (CW, синие эллипсы), роторы 2 и 4 — против часовой стрелки (CCW, красные эллипсы).	27
3.1	Сравнение архитектур четырёх рассматриваемых нейронных сетей. Предлагаемая нейронная сеть выделена рамкой. <i>Figure 2. Comparison of architectures of the four neural networks under study. The proposed network is highlighted.</i>	39
3.2	Архитектура предлагаемой нейронной сети.	44
4.1	RMSE (м) четырёх моделей в зависимости от доли обучающих данных при потере сигнала ГНСС 240 с. Ось X : доля обучающих данных (%); ось Y : RMSE (м). Столбцы: предлагаемая нейронная сеть (синий), обобщённая нейронная сеть (зелёный), базовая нейронная сеть (красный), Transformer (оранжевый). <i>Figure 4. RMSE (m) of the four models vs. training data fraction, GNSS outage 240 s. X-axis: fraction of training data (%); Y-axis: RMSE (m).</i>	50
4.2	СКО в зависимости от длительности потери сигнала для стратегии дообучения отдельных моделей под платформу. Каждый подграфик соответствует одной комбинации платформы и профиля. Планки ошибок показывают стандартное отклонение по 10 случайным сегментам.	57
4.3	СКО в зависимости от длительности потери сигнала для стратегии объединённой модели. Базовая платформа (x500, зелёный цвет) демонстрирует существенно более высокую ошибку по сравнению со стратегией отдельных моделей, что указывает на компромисс точности базовой платформы ради охвата нескольких платформ.	57

4.4	Средняя СКО в зависимости от платформенного разрыва $\Delta = m/m_{\text{base}}$ при трёх длительностях потери сигнала. Стратегия отдельных моделей (сплошная синяя линия): U-образный профиль с минимумом на платформе предобучения. Объединённая стратегия (пунктирная оранжевая линия): инвертированный пик при $\Delta = 1,0\times$, вызванный сдвигом распределения при смещении данных всех трёх платформ.	58
4.5	Влияние профиля на СКО для стратегии отдельных моделей под платформу. Каждая группа столбцов показывает спокойный (зелёный), средний (оранжевый) и агрессивный (красный) профили для одной платформы.	58
4.6	Зависимость СКО от массы робота разделенная по характеру движения	67
4.7	Зависимость СКО от массы робота разделенная по длительности потери ГНСС сигнала	67
4.8	Зависимость СКО от массы робота разделенная по характеру движения	77
4.9	Зависимость СКО от массы робота разделенная по длительности потери ГНСС сигнала	77
.10	Архитектура потока данных восстановления траектории.	93

Список таблиц

1	Сравнительный анализ методов восстановления траектории при потерях сигнала ГНСС	23
2	Сравнительный анализ методов восстановления траектории при кратковременных потерях сигнала ГНСС	24
3	Характеристики датчиков и телеметрии, используемых в работе	33
4	Сравнение статистических характеристик датасетов A и B <i>Table 2. Statistical characteristics of datasets A and B</i>	46
5	RMSE (м) при дообучении на подмножествах, потеря сигнала ГНСС 60 с (<i>лучший сценарий</i>) <i>Table 3. RMSE (m) for fine-tuning on subsets, GNSS outage 60 s (best-case scenario)</i>	47
6	RMSE (м) при дообучении на подмножествах, потеря сигнала ГНСС 240 с (<i>наиболее сложный сценарий</i>) <i>Table 4. RMSE (m) for fine-tuning on subsets, GNSS outage 240 s (worst-case scenario)</i>	48
7	RMSE (м) предлагаемой нейронной сети по всем длинам потери сигнала и долям датасета (сводная таблица) <i>Table 5. RMSE (m) of the proposed neural network for all outage durations and dataset fractions (summary)</i>	49
8	Параметры симулированных платформ. Значения моментов инерции масштабируются как отношение масс $\times$ (отношение длин плеч) ² относительно базовой платформы. Коэффициент тяги k_T для <code>x500_heavy</code> увеличен для обеспечения запаса тяги к весу примерно 20 %, что соответствует более мощной силовой установке тяжёлого аппарата.	54
9	Размеры датасетов после удаления строк с контактом с землёй (высота < 1 m) и отбрасывания 2 с переходных процессов при взлёте и посадке.	55
10	Сходимость дообучения отдельных моделей под платформу. PCE — средняя величина невязки силы по Ньютону на 1-й и 5-й эпохах.	56

11	Средняя СКО (м) по трём профилям миссий. Жирным выделена лучшая стратегия для каждой комбинации платформы и длительности. † Объединённая стратегия использует веса предобучения $\times 500$ без дополнительного дообучения на данных базовой платформы в случае стратегии отдельных моделей.	60
12	Физические и имитационные параметры экспериментальных платформ. Параметры, отличающиеся от базовой, выделены жирным шрифтом. Разрыв платформы $\Delta = m/m_{\text{base}}$ характеризует величину доменного сдвига.	63
13	Соответствие имитационных моделей реальным платформам.	63
14	Параметры профилей полётных заданий. Минимальный угол разворота обеспечивает резкие изменения курса и увеличивает разницу оборотов между парами роторов.	64
15	Объёмы датасетов после предобработки (количество отсчётов при частоте 100 Гц примерно соответствует секундам полёта).	65
16	Среднеквадратичная ошибка положения (СКО, м) для всех комбинаций платформа–профиль и длительностей перерывов ГНСС. Обобщение без дообучения. Лучшее значение в каждом столбце подчеркнуто.	66
17	Среднеквадратичная ошибка положения при спокойном профиле полёта. Разброс между платформами (максимум минус минимум) остаётся ниже 0,5 м даже при 60-секундном перерыве ГНСС.	66
18	Физические и имитационные параметры экспериментальных платформ. Параметры, отличающиеся от базовой, выделены жирным шрифтом. Разрыв платформы $\Delta = m/m_{\text{base}}$ характеризует величину доменного сдвига.	73
19	Соответствие имитационных моделей реальным платформам.	73
20	Параметры профилей полётных заданий. Минимальный угол разворота обеспечивает резкие изменения курса и увеличивает разницу оборотов между парами роторов.	73
21	Объёмы датасетов после предобработки (количество отсчётов при частоте 100 Гц примерно соответствует секундам полёта).	74

- 22 Среднеквадратичная ошибка положения (СКО, м) для всех комбинаций платформа–профиль и длительностей перерывов ГНСС. Обобщение без дообучения. Лучшее значение в каждом столбце подчеркнуто. 75
- 23 Среднеквадратичная ошибка положения при спокойном профиле полёта. Разброс между платформами (максимум минус минимум) остаётся ниже 0,5 м даже при 60-секундном перерыве ГНСС. 76

Приложение А

```

class MambaRPMPINN(nn.Module):
    """MambaRPMPINN — полная RPM-informed Physics-Informed Neural
    Network"""
    def __init__(self, input_dim=17, d_model=192, d_state=16, d_conv=4,
        expand=2, num_layers=3):
        super().__init__()
5         self.embedding = nn.Linear(input_dim, d_model)
        nn.init.kaiming_normal_(self.embedding.weight)
        self.norm_in = nn.LayerNorm(d_model)

        self.mamba_layers = nn.ModuleList([
10         Mamba(d_model=d_model, d_state=d_state, d_conv=d_conv, expand=expand)
        for _ in range(num_layers)
        ])

        self.norm_out = nn.LayerNorm(d_model)
15         self.fc_vel = nn.Linear(d_model, 3)
        self.fc_quat = nn.Linear(d_model, 4)
        self.fc_accel = nn.Linear(d_model, 3)
        self.fc_torque_inter = nn.Linear(d_model, 4)

20         # Физические параметры регистрируем( как буферы)
        self.register_buffer('g', torch.tensor(9.81))
        self.register_buffer('m', torch.tensor(2.0))
        self.register_buffer('l', torch.tensor(0.174))
        self.register_buffer('k', torch.tensor(2.32e-8))
25         self.register_buffer('b', torch.tensor(1.1e-8))
        self.b_drag = nn.Parameter(torch.tensor(0.02))

        self.register_buffer('I_xx', torch.tensor(0.02167))
        self.register_buffer('I_yy', torch.tensor(0.02167))
30         self.register_buffer('I_zz', torch.tensor(0.04000))
        self.register_buffer('coeff_fz', torch.tensor([1., 1., 1., 1.]))

        self.register_buffer('accel_mean', torch.tensor([0.0, 0.0, -9.81]))
        self.register_buffer('accel_std', torch.tensor([0.5, 0.5, 1.0]))
35         l_arm = self.l * math.sqrt(2.0)
        self.register_buffer('coeff_tx', torch.tensor([-1., 1., 1., -1.]) *
        l_arm)

```

```

    self.register_buffer('coeff_ty', torch.tensor([-1., -1., 1., 1.]) *
l_arm)
    self.register_buffer('coeff_tz', torch.tensor([-1., 1., -1., 1.]) *
40 (self.b / self.k))

    def forward(self, x):
        x = self.embedding(x)
        x = self.norm_in(x)

45     residual = x
        for mamba in self.mamba_layers:
            x = mamba(x) + residual
            residual = x

50     x = self.norm_out(x)

        vel = self.fc_vel(x)
        quat = self.fc_quat(x)
        accel_nn = self.fc_accel(x)
55     torque_inter = self.fc_torque_inter(x)

        # Нормализация кватерниона
        quat_norm = torch.norm(quat, dim=-1, keepdim=True)
        quat = quat / torch.clamp(quat_norm, min=1e-6)
60     quat = torch.clamp(quat, -1.0, 1.0)

        pred = torch.cat([vel, quat, accel_nn], dim=-1)
        return pred, torque_inter

```

Листинг 1: Программный код модели mamba_pinn_rpm

Приложение Б

1.1 Архитектура потока данных восстановления траектории

На рисунке .10 представлен полный поток данных с датчиков ГНСС, БИНС, оборотов винтов в задаче восстановления траектории с применением ФИ НС-ПСПС.




Рисунок .10 — Архитектура потока данных восстановления траектории.